



WISSENSCHAFTLICHE VERTIEFUNG

Der Fortschritt
automatischer Musiktranskriptionssysteme
durch künstliche Intelligenz

Autor:

Benedikt Kolodziej
878007
Medieninformatik (B. Sc.)

Betreuender Professor:

Prof. Dr. Dennis Müller
dennis.mueller@hs-duesseldorf.de

Zeitraum

28.05.2025 - xy

Inhaltsverzeichnis

1	Einleitung	1
1.1	Automatische Musiktranskription	1
1.2	Grundlegende Begriffe in AMT-Systemen	1
1.3	Herausforderungen und Hindernisse	4
1.4	Anwendungsfelder und Vorteile	5
1.5	AMT und Künstliche Intelligenz	5
1.6	Motivation, Zielsetzung und Ablauf	6
2	Geschichtliche Entwicklung von AMT-Systemen	7
2.1	Moorer und das erste AMT-System	7
2.1.1	Grundlegende Probleme	7
2.1.2	Der Aufbau von Moorers AMT-System	8
2.2	Hidden Markov Modelle	8
2.3	Datensätze für AMT-Systeme	9
2.4	Polyphone AMT-Systeme	9
2.4.1	Blackboard-System	10
2.4.2	RASTA-basiertes System	11
2.5	Einbindung von Künstlicher Intelligenz	12
3	Hindernisse Moderner AMT-Systeme	13
3.1	Onset Detection	13
3.2	Polyphonie	14
3.3	Spezielle Instrumente	14
3.4	Notendauer	15
3.5	Reale Audioaufnahmen	15
3.6	Frame-basierte vs Event-basierte AMT-Systeme	15
3.7	Blackbox von KI-Modellen	16
4	KI-Modelle in AMT-Systemen	16
4.1	Convolutional Neural Networks	17
4.1.1	Layer eines CNNs	17
4.1.2	Geschichtliche Einordnung von CNNs	18
4.2	Recurrent Neural Networks	19
4.2.1	Grundstruktur eines RNNs	19
4.2.2	Long Short-Term Memory	21
4.2.3	Gated Recurrent Units	22
4.2.4	Bidirektionale RNNs	23
4.2.5	Geschichtliche Einordnung von RNNs	23
4.3	Transformers	23
4.3.1	Input Embedding und Position Encoding	24
4.3.2	Self-Attention Layer	24
4.3.3	Feedforward Layer	25
4.3.4	Geschichtliche Einordnung von Transformern	25
4.4	Potentielle KI-Modelle	26
5	KI-basierende AMT-Systeme im Vergleich	27
5.1	Omnizart	27
5.2	MT3	29
5.3	Omnizart vs MT3	31
6	Fazit	32
	Literaturverzeichnis	33

Abbildungsverzeichnis

1	Noten Onsets	1
2	Vergleich 4 Spektrogramme	2
3	MIDI-Datensatz	4
4	Systemstruktur nach Martin	10
5	Struktur eines RASTA-basiertem AMT-System	12
6	CNN Struktur	18
7	Entfaltung eines RNN-Blocks	20
8	LSTM Zeitschritt	22
9	GRU Zeitschritt	23
10	Omnizart Pipeline	28
11	MT3 Pipeline	29
12	Verarbeitungspipeline des MT3-Modells	31

Tabellenverzeichnis

1	Übersicht typischer Skalen/Tonleiter verschiedener Weltregionen	5
2	Übersicht populärer Instrumente verschiedener Weltregionen	15

1 Einleitung

1.1 Automatische Musiktranskription

Musik war schon immer ein zentraler Bestandteil unserer Gesellschaft. Während früher musikalische Werke meist mündlich überliefert wurden, entwickelte sich während des Mittelalters die Notenschrift, welche wir auch heutzutage noch nutzen. Diese Notenschrift ermöglichte es, Musikstücke einfacher zu erlernen und Musik einem breiteren Publikum zugänglich zu machen. Durch die Digitalisierung erhielten „Digital Audio Workstations“ zunehmend Einzug in die Musikproduktion, wodurch Notenblätter irrelevant wurden und somit weniger Musikstücke in Notenschrift übersetzt wurden.

Ungefähr gleichzeitig begann zudem die Forschung an AMT-Systemen (Automatic Music Transcription). AMT ist ein Prozess, zur automatischen Transkription von Audiospuren. Als Input wird ein Audiosignal gegeben, welches durch verschiedene Prozesse umgewandelt wird. Diese Prozesse analysieren die Eigenschaften der Noten, zum Beispiel die Frequenz, Lautstärke und vieles mehr. Dadurch entsteht als Output eine MIDI-Datei, ein Notenblatt oder andere Daten, die das gegebene Musikstück in Schriftform darstellen.

1.2 Grundlegende Begriffe in AMT-Systemen

Onsets und Offsets

Onsets beschreiben den exakten Zeitpunkt, an dem eine Note beginnt. Dementsprechend zeigen Offsets den Zeitpunkt, an dem diese endet. Onsets werden in der Signalverarbeitung typischerweise durch plötzliche Änderungen im Audiosignal erkannt. Durch einen starken Anstieg der Amplitude, Änderungen im Spektrum oder plötzliche Energiezunahmen im Frequenzbereich. Offsets markieren den Zeitpunkt, an dem die im Onset erfassten Merkmale nicht mehr vorhanden sind und die Note endet. Die präzise Erkennung von Onsets und Offsets ist essenziell, um die Dauer einer Note korrekt zu bestimmen und eine vollständig korrekte Notenschrift zu erzeugen. Fehler in der Erkennung können zu falscher Notenlänge, fehlenden Noten oder zusätzlichen Phantomnoten führen. In späteren Modellen, wie RNNs, können falsche Onsets und Offsets auch zu Folgefehlern führen.

Die folgende Darstellung verdeutlicht, wie musikalische Ereignisse anhand von Änderungen in der Amplitude erkannt werden können. Ein deutlicher Anstieg der Amplitude markiert den Onset einer Note.




Abbildung 1: 3 Noten Onsets mit Abhängigkeit von Amplitude und Zeit [Brown, S. G. Crewther und D. P. Crewther 2016].

Polyphonie

Polyphonie beschreibt in der Musik die Mehrstimmigkeit. Das bedeutet, dass ein Musikstück mehrere Stimmen gleichzeitig wiedergibt. In der automatischen Musiktranskription muss das System diese gleichzeitig erklingenden Stimmen erkennen, voneinander unterscheiden und den jeweiligen Stimmen zuordnen. Je mehr Stimmen ein Musikstück besitzt, desto schwieriger ist die Transkription. Ein klassisches Beispiel für polyphone Musik sind Klavierstücke, Orchesterwerke oder Chormusik, bei denen oft viele Noten gleichzeitig erklingen.

Spektrogramme

In der automatischen Musiktranskription wird das Input Audiosignal immer zunächst in ein Spektrogramm umgewandelt. Spektrogramme zeigen den zeitlichen Verlauf des Frequenzspektrums eines Audiosignals. Es gibt verschiedene Arten von Spektrogrammen. Zwei Spektrogrammtypen, die häufig genutzt werden, sind CQT-Spektrogramme und Log-Mel-Spektrogramme. CQT steht für Constant-Q Transform und in diesem Spektrogramm werden die Frequenzachsen logarithmisch aufgelöst. Zudem bleibt der Q-Faktor konstant, dieser beschreibt das Verhältnis von Frequenz zu Bandbreite. Das Log-Mel-Spektrogramm wird zunächst mit einer Short-Time Fourier Transform (STFT) gebildet. STFT ist eine Methode, um ein Signal als ein Frequenzspektrum darzustellen. Anschließend wird die lineare Frequenzachse auf eine Mel-Skala projiziert. Das menschliche Gehör kann zum Beispiel 200–400Hz feiner als 5000–5200Hz wahrnehmen. Die Mel-Skala sorgt dafür, dass sich das Spektrogramm dem menschlichen Gehör anpasst. Insgesamt ist ein CQT-Spektrogramm besser für die automatische Musiktranskription, da in diesem die Töne feiner unterschieden werden können. Jedoch werden in neueren KI-Modellen zum Großteil Log-Mel-Spektrogramme genutzt. Diese sind robuster und funktionieren, vor allem in Transformer-basierte KI-Modellen, zuverlässiger.

Im Folgenden sind vier verschiedene Spektrogramme zu sehen, welche alle auf den identischen Ausschnitt aus Bachs WTK I, Nr.5 [Heinemann 1992] basieren. Oben links ist ein normales lineares Spektrogramm zu sehen, welches ausschließlich auf dem STFT basiert und eine lineare Frequenzskala besitzt. Rechts daneben ist ein Log-Spektrogramm, bei dem die Amplitudenwerte des STFT logarithmisch in Dezibel skaliert wurden, wodurch der Dynamikumfang im niedrigen Amplitudenbereich erhöht wird. Das „MelSpec“ steht für Log-Mel-Spektrogramm und unten rechts wird ein CQT-Spektrogramm angezeigt.

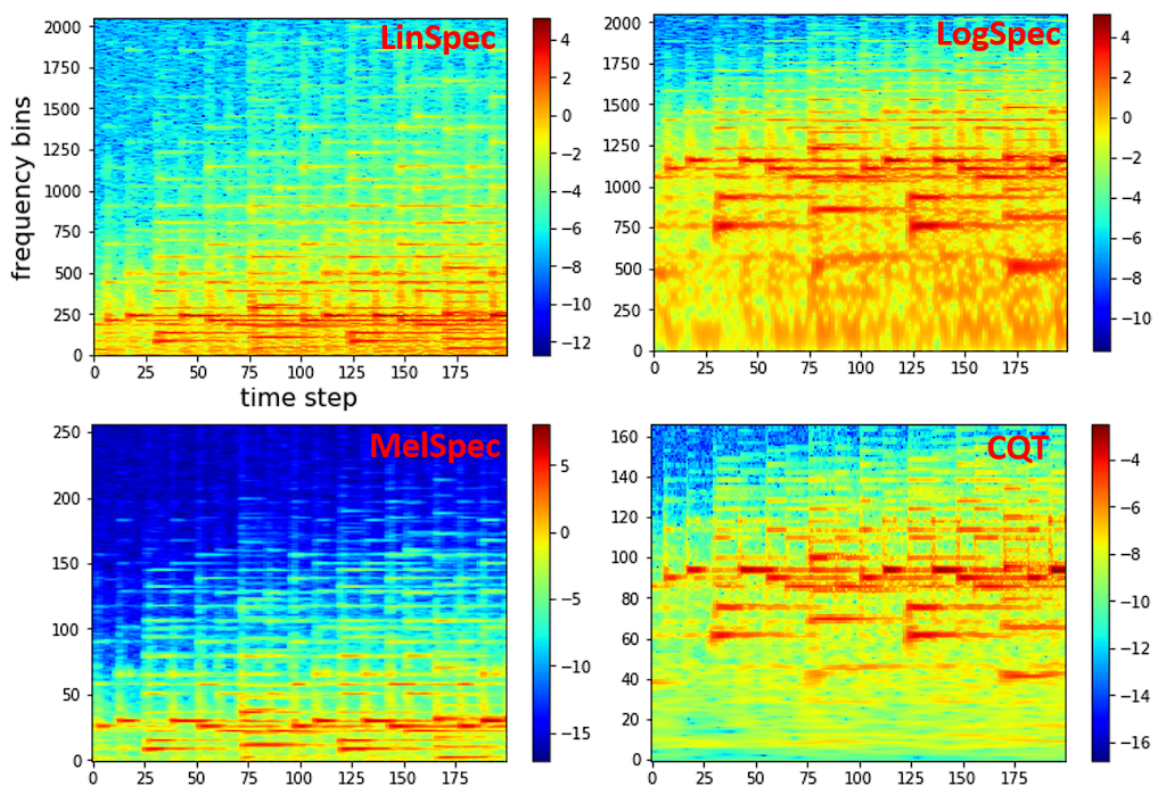


Abbildung 2: Vergleich von vier Spektrogrammen basierend auf [T. Cheuk, Shan und Raphael 2020].

MIDI-Dateien

Notenschrift als Input für ein Computerprogramm, Synthesizer oder ähnliches ist unhandlich. Zunächst müssten die gespielten Noten stets in Notenschrift umgewandelt und anschließend in anderen Programmen analysiert werden. Dieser Prozess ist sehr aufwändig. Eine bessere Lösung wäre eine Datenschreibweise, bei der alle wichtigen Informationen der Noten übersichtlich

aufgeschrieben sind. MIDI-Dateien sind dafür perfekt geeignet.

MIDI (Musical Instrument Digital Interface) ist ein Standardprotokoll zur Kommunikation zwischen elektronischen Musikinstrumenten, Computern und anderen Geräten wie zum Beispiel Synthesizern. Dieses Protokoll wurde erstmals 1983 eingeführt und wurde schnell zu einem Standard in der digitalen Musikindustrie [Dave und Chet 1981]. In MIDI-Dateien werden Daten von Tönen gespeichert, welche zum Beispiel zuvor von einem elektronischen Instrument gespielt wurden oder durch AMTs erfasst wurden.

In MIDI-Dateien werden folgende Daten gespeichert:

1. **MIDI Header-Chunk (MThd):** Enthält grundlegende Informationen zur Struktur der Datei:
 - Dateiformat (Formattyp: 0 = eine Spur, 1 = mehrere synchrone Spuren, 2 = unabhängige Spuren)
 - Anzahl der folgenden MTrk-Blöcke
 - Zeitauflösung (Ticks pro Viertelnote)
2. **MIDI Track-Chunks (MTrk):** Jede Spur enthält eine zeitlich sortierte Liste von MIDI-Events:
 - **MIDI-Events:**
 - Onset / Offset
 - Lautstärkeänderung (Control Change)
 - Angabe des spielenden Instruments (Program Change)
 - Tonhöhenänderung (Pitch)
 - Druckstärke pro Taste (Aftertouch / Polyphonic Key Pressure)
 - **Meta-Events):**
 - Tempo in Mikrosekunden pro Viertelnote (Set Tempo)
 - Taktart (Time Signature)
 - Tonart (Key Signature)
 - Spurname (Track Name)
 - Liedtext (Lyrics)
 - Markierungen (Markers)
 - Ende der Spur (End of Track)
 - **Systemexklusive Ereignisse (SysEx):**
 - Herstellerspezifische Daten wie Synthesizer-Voreinstellungen oder Spezialbefehle
3. **Delta-Time:** Gibt die Zeit in Ticks an, die seit dem letzten Ereignis vergangen ist:
 - Ermöglicht die genaue zeitliche Positionierung jedes MIDI-Ereignisses
 - Grundlage für das Timing und die rhythmische Struktur der Datei

Am wichtigsten sind dabei die MTrk-Blöcke, in denen die Daten der einzelnen Noten gespeichert werden. Dabei stellt ein Track die Eventliste einer ganzen Stimme dar, wie zum Beispiel die Melodiestimme, eine Violine, die Pedalsteuerung eines Klaviers oder Metadaten. Es fällt auf, dass diese vier Beispiele alle sehr unterschiedliche Aufgaben und Bedeutungen haben.

Das liegt daran, dass in MIDI-Dateien zusammenhängende Funktionen gespeichert werden und nicht nur Musiknoten.

MIDI-Dateien kamen auch der Forschung für AMT-Systemen sehr gelegen, da man nun ein standardisiertes Output-Format für diese Programme besaß. Später werden diese zudem sehr essenziell bei dem Training KI basierter AMT-Systeme [Telila, Cucinotta und Bacciu 2025].

Im folgenden Bild wird ein Auszug einer MIDI-Datei, mit zwei Noten, angezeigt. Darunter ist ein Piano-Roll abgebildet, zugehörig zu oben genannten Noten. Ein Piano-Roll ist eine grafische Darstellung von Musiknoten über die Zeit. Dabei gibt die Position die Tonhöhe an und die Länge die Spieldauer.

```
<time 73.1> <vel 61> <pitch 60> <time 73.3>
<vel 82> <pitch 64> <time 73.5> <vel 0> <pitch 60>
```




Abbildung 3: MIDI-Datensatz mit zugehörigem Piano-Roll. Ausschnitt aus der Verarbeitungspipeline des MT3-Modells [Gardner u. a. 2022].

1.3 Herausforderungen und Hindernisse

Anstatt durch sein Gehör selber diese Musikstücke in Notenschrift zu übertragen, würde ein AMT-System diese Aufgabe übernehmen. Dieses Ziel war jedoch schwer zu erreichen, da Musik mehrdimensional, durch Aspekte wie zeitlicher Abfolge, Tonhöhe und Polyphonie, ist. Vor allem bei polyphonen Musikstücken haben herkömmliche Algorithmen häufig Schwierigkeiten. In diesen Fällen müssen AMT-Systeme mehrere verschiedene Stimmen gleichzeitig analysieren und im späteren die jeweiligen Töne voneinander differenzieren um diese dann eindeutig einem Instrument zuzuordnen zu können. Ein weiteres Problem ist die Individualität jedes Musikstückes. In realen Aufnahmen können leichtes Rauschen, kleine Spielfehler oder stilistische Mittel wie Vibrato auftreten, die je nach Interpreten unterschiedlich klingen. Zudem sind die meisten AMT-Modelle auf die westlichen Tonleiter trainiert. Dies kann zu Problemen führen, wenn zum Beispiel arabische oder indische Musikstücke transkribiert werden sollen.

In folgender Tabelle sind einige Regionen aufgelistet und deren Tonleiter, die diese benutzen. Die Tabelle ist nicht vollständig, auf der Welt gibt es noch viele weitere Regionen, welche auch ihre ganz eigenen Tonleiter nutzen.

Region	Typische Skalen
Europa	Dur, Moll, Kirchentonarten, Pentatonik
Arabische Welt	Maqām Rast, Maqām Bayati, Maqām Hijaz, Maqām Kurd, Maqām Nahawand
Türkei	Hicaz, Nihavent, Hüseyini, Segah, Uşşak
Persien / Iran	Shur, Mahur, Segah, Homayun, Nava
Indien	Rāga Yaman, Bhairav, Todi, Kafi, Bhupali
China	Gong, Shang, Jue, Zhi, Yu
Japan	Hirajoshi, In-sen, Yo, Kumoi
Indonesien	Sléndro, Pélog
Afrika	Pentatonik, Hexatonik, Balafon-Skalen

Tabelle 1: Übersicht typischer Skalen/Tonleiter verschiedener Weltregionen

1.4 Anwendungsfelder und Vorteile

AMT kann auch häufig bei anderen Problemen helfen oder in zahlreichen Bereichen „Quality-of-Life-Changes“ bringen. Zum einen kann der Musikunterricht spannender und interaktiver gestaltet werden. Es würde eine breitere Auswahl von Musikstücken geben, die den Schülern angeboten werden können, wodurch diese durch individuell angepasste Musikstücke mehr Spaß und Ehrgeiz beim Lernen entwickeln. Zudem können die gespielten Musikstücke der Schüler während des spiels transkribiert werden, wodurch frühzeitig erkannt wird, wo der jeweilige Schüler noch Verbesserungsmöglichkeiten aufweist und Feedback erhalten muss. Grundsätzlich können deutlich mehr Musikstücke transkribiert werden, wodurch sich große Archive aufbauen lassen. Ein größeres Interesse an Musik wird geweckt, da Musikstücke von beliebten Serien, Filmen oder Spielen leichter für deren Musikbegeisterte Zielgruppe zugänglich sind. Alleine dadurch, dass KI-Modelle Musikstücke besser verstehen, können darauf aufbauend weitere Tools für die Musikproduktion entwickelt werden. Auch andere Anwendungsfelder von künstlicher Intelligenz würden dadurch profitieren. KI-generierte Musik würde verbessert werden, da die KI selber ein besseres Verständnis der Musik entwickelt. Audiobasierte Suchmaschinen könnten gewünschte Musikstücke oder bestimmte Videos präziser finden.

1.5 AMT und Künstliche Intelligenz

Um diese musikalische Vielfalt zu bewältigen, wird heutzutage künstliche Intelligenz und Machine Learning eingesetzt. Im Gegensatz zu Algorithmen ist KI flexibler und kann sich dadurch besser auf kleine Abweichungen in Musikstücken einstellen. Ein Audiosignal kann entweder im Studio produziert oder im Alltag aufgenommen werden. Alltag aufgenommene Signale werden, in dieser Arbeit, als reale Audiosignale bezeichnet. Reale Audiosignale beinhalten immer eine gewisse Menge an Rauschen. Das kann bei der automatischen Musiktranskription für Schwierigkeiten sorgen, da Algorithmen diese als zusätzliche Noten ansehen oder richtige Noten dadurch nicht erkennen können. KIs können sich besser an die fehlerhaften Geräusche von Rauschen anpassen, da neuronale Netzwerke mit genau diesen fehlerbehafteten Audiosignalen trainiert werden können. Somit können AMT-Systeme besser angepasst werden an einen realistischen Alltagsgebrauch.

Auch die Mehrdimensionalität von Musik kann KI deutlich besser bewältigen als Algorithmen. Neuronale Netze besitzen eine mehrdimensionale Struktur, die es ihnen ermöglicht, verschiedene Muster, Stimmen und Eigenschaften zu erlernen [Graves, Fernández und Schmidhuber 2007]. Auf der anderen Seite müssen klassische Algorithmen diese verschiedenen Dimensionen explizit modellieren und sind nicht in der Lage, Muster selbstständig zu erkennen. Sie folgen nur den fest einprogrammierten Anweisungen und sind somit nicht anpassungsfähig.

Es gibt verschiedene KI-Modelle, welche für AMT-Systeme in Frage kommen. In diesem Abschnitt werden die am weitesten verbreiteten KI-Modelle aufgegriffen. Weitere potenzielle KI-Modelle und der heutige „State of the Art“ werden im Abschnitt-(KI-Modelle in AMT-Systemen) ausführlich erläutert. Die meisten AMT-Systeme nutzen Recurrent Neural Networks (RNN) und Convolutional

Neural Networks (CNN) [Böck und Schedl 2012]. Diese Module bilden keine eigenständigen Systeme, sondern lassen sich flexibel innerhalb eines Systems kombinieren. Da es keine objektiv richtigen oder falschen Notenfolgen gibt, ist der Einsatz von Supervised Learning am effizientesten. Dementsprechend ist es notwendig ein zuverlässiges und großes Datenset aus Audiodateien und deren zugehörigen MIDI-Dateien zu besitzen.

CNNs können gut räumliche Strukturen erkennen. Das ist sehr hilfreich bei der Analyse von Spektrogrammen. Da das Input Audiosignal in ein Spektrogramm umgewandelt wird, kann das CNN diese bildliche Darstellung analysieren. Durch die Analyse von dem Spektrogramm können gewisse Frequenzmuster erkannt werden, die darauffolgend einem bestimmten Instrument zugeordnet werden können. Das ist vor allem dabei hilfreich, die verschiedenen Stimmen der jeweiligen Instrumente voneinander zu differenzieren [Han, Kim und K. Lee 2016].

RNNs hingegen spezialisieren sich darauf, mithilfe eines Gedächtnis, zeitliche Abläufe zu verstehen. In Musikstücken werden zahlreiche Noten hintereinander gespielt, welche harmonisch aufeinander aufbauen. Das RNN verarbeitet die jeweiligen Sequenzen und merkt sich die Informationen der schon gespielten Noten, um die darauffolgenden Noten besser einordnen zu können. So lässt sich die harmonische Struktur des Musikstückes analysieren. Auch der Rhythmus und vorhandene Vorzeichen lassen sich dadurch interpretieren [Böck und Schedl 2012].

In den meisten AMT-Systemen werden RNNs und CNNs kombiniert. Zunächst verarbeitet das CNN das Spektrogramm und extrahiert dabei musikalische Merkmale. Darauf folgend verarbeitet das RNN diese Merkmale und bildet konkrete Noten mit deren einzelnen Eigenschaften.

1. CNN

Extrahiert folgende Merkmale aus dem Spektrogramm:

- Frequenzverteilungen und spektrale Muster
- Tonhöhenlage und damit verbundene Obertöne
- Klangfarbe einzelner Instrumente
- Energieverteilung, unter anderem zur Erkennung von Toneinsätzen
- Harmonische Strukturen wie Akkordfolgen

2. RNN

Verarbeitet auf Basis dieser Merkmale die zeitliche Abfolge und erkennt dabei folgende Eigenschaften:

- Reihenfolge und Übergänge musikalischer Ereignisse
- Beginn und Ende einzelner Töne zur Bestimmung der Notendauer
- Rhythmische Muster und zeitliche Gruppierungen
- Musikalische Phrasen mit zusammenhängender Struktur
- Wiederholungen, Themen oder längere Abhängigkeiten im Verlauf

3. Output

Gibt das transkribierte Musikstück in strukturierter Form aus:

- Als MIDI-Datei mit exakten Noteninformationen

Nachdem die KI-Modelle die Daten verarbeitet haben, kann die erhaltene MIDI-Datei mit einem externen Programm zu standardisierten Musiknoten transkribiert werden.

1.6 Motivation, Zielsetzung und Ablauf

Künstliche Intelligenz ist momentan eins der aktivsten Forschungsfelder. Durch KIs wurden und werden noch viele grundlegende Probleme und Algorithmen komplett umstrukturiert, verworfen oder

gelöst. Ein perfektes Beispiel dafür ist AlphaDev von DeepMind [Mankowitz u. a. 2023], welches durch Reinforcement Learning ein neues, effizienteres Sortier- und Hashverfahren entwickelt hat. Ein Forschungsgebiet, das unter anderem auch sehr stark durch die Einführung von KI profitiert hat, ist die automatische Musiktranskription. Während früher noch Modelle und Algorithmen genutzt worden, um AMT-Systeme umzusetzen, werden jetzt überwiegend verschiedene KI-Modelle genutzt, um unter anderem Spektrogramme zu analysieren und um den Aufbau des Musikstückes zu identifizieren.

Durch die Integration von KI in AMT-Systemen rückt die Vorstellung von AMT-Systemen, welche im Alltag genutzt werden auch immer näher. Sobald das erste AMT-System praxisgeeignet ist, werden sich, wie im Abschnitt-Anwendungsfelder und Vorteile angeschnitten, viele neue Einsatzmöglichkeiten ermöglichen. Dadurch werden andere Forschungsgebiete gefördert, momentane Aufgaben vereinfacht und das Bildungswesen verbessert.

Deshalb wird der Schwerpunkt dieser wissenschaftlichen Vertiefung darin liegen, auf die Funktion von KI-Modellen in AMT-Systemen. Diese Analyse wird sich aus drei Teilen zusammenfügen. Zunächst werden die heutigen Schwachstellen moderner AMT-Systeme aufgelistet. Als Nächstes werden die KI-Systeme beschrieben, welche grundlegend in AMT-Systemen genutzt werden und welche Vorteile diese mit sich bringen. Zuletzt werden zwei neuzeitige AMT-Systeme vorgestellt, welche beide eine starke Auswirkung auf dieses Forschungsgebiet haben.

Um das Thema automatische Musiktranskription zu vervollständigen, wird im nächsten Kapitel zunächst auf die Geschichte von AMT-Systemen eingegangen. Außerdem wird erläutert, wie frühere AMT-Systeme funktionierten und aussahen.

2 Geschichtliche Entwicklung von AMT-Systemen

2.1 Moorer und das erste AMT-System

Eine der ersten Arbeiten über automatische Musiktranskription wurde im Jahr 1977 geschrieben [Moorer 1977]. In dieser beschreibt Moorer seinen Ansatz, polyphone Musikaudiospuren direkt über Computerprogramme in Notenschrift zu übertragen. Während dieses Prozesses fallen ihm schon große Probleme auf, die auch in späteren Arbeiten eine ausschlaggebende Rolle spielen.

2.1.1 Grundlegende Probleme

Eines dieser Probleme wird von ihm als das „Cocktail-Party-Problem“ bezeichnet. Dieses stellt die Schwierigkeit dar, auf einer Party bestimmten Stimmen zu folgen, während viele verschiedene Stimmen gleichzeitig erklingen. Das gleiche Problem existiert in der Noten transkription. Die meisten Musikstücke haben mehrere Instrumente, welche gleichzeitig spielen. Oft gibt es auch Musikstücke, bei denen es mehrere Stimmen für ein Instrument gibt. Ein Beispiel dafür ist die Violine, die zum Beispiel in Orchesterstücken oft auf mehrere Stimmen (erste, zweite, dritte) aufgeteilt wird. Dies erschwert die Zuordnung bestimmter Noten zu einer gewählten Stimme. Der Großteil aller Menschen scheitert daran große Musikstücke richtig zu transkribieren. Noch schwieriger wird es für Computerprogramme. Anfangs identifizieren diese bestimmte Töne anhand der Frequenz des Tons. Moorer stellte fest, dass sich allein anhand der Frequenz nicht eindeutig bestimmen lässt, welche Töne zu einem bestimmten Zeitpunkt gespielt werden.

Das nächste Problem ist die Frequenzüberladung durch Obertöne. Jeder Ton hat Obertöne. Diese Obertöne sind jeweils das Vielfache von dem Grundton, den man spielt. Spielt man beispielsweise auf einem Klavier den Ton C3 (130,81 Hz), so entstehen die Obertöne C4 (261,62 Hz), G4 (392,42 Hz) und weitere. Wenn man nur C3 spielt, erklingen für das Computerprogramm auch die jeweiligen Obertöne, was man Frequenzüberlagerung nennt. Diese Frequenzüberlagerung sorgt dafür, dass zum Beispiel ein Klavier anders klingt als eine Violine. Daraus resultiert die Klangfarbe (Timbre) eines bestimmten Instrumentes [Goswami und Velankar 2013]. Moorer konnte das Problem der Obertöne nicht lösen. Zum einen war es ihm aufgrund des damaligen technischen Stands nicht möglich, die Klangfarbe eines Instruments zu erkennen. Zum anderen waren die Algorithmen und Verfahren jener

Zeit nicht in der Lage, die Grundfrequenz von den Obertönen zu trennen. Deshalb fokussierte er sich ausschließlich auf zweistimmige polyphone Musikstücke.

Ein weiteres Problem war Rauschen in unter realen Aufnahmebedingungen erstellten Audiospuren sowie stilistische Mittel in der Musik, wie etwa Vibrato. In real aufgenommenen Audiospuren gibt es immer ein gewisses Hintergrundrauschen [iZotope n.d.]. Dieses kann von einem Computerprogramm auch als Note erkannt werden oder verhindern, dass bestimmte Noten richtig erkannt werden. Moorer nahm das Musikstück selbst analog auf und digitalisierte es anschließend mit einem 14-Bit-A/D-Wandler. Durch die eigene Aufnahme konnte er die Aufnahmeumgebung, die Mikrofonposition und die genutzte Technik kontrollieren, wodurch sich das Rauschen im Vergleich zu unkontrollierten Aufnahmen verringerte. Zudem wies er die Musiker an auf stilistische Mittel zu verzichten. Stilistische Mittel wie Vibrato verursachen kleine, aber kontinuierliche Veränderungen der Frequenz. Dadurch kann das Computerprogramm nicht korrekt erkennen, das eigentlich eine einzelne Note gespielt wurde. Die Folge davon wäre eine falsche Zuordnung des Onsets und Offsets der Noten. Ohne diese erhielt Moorer klarere und besser verwertbare Daten für die Transkription.

Das letzte Problem, was Moorer angesprochen hat, ist die Nutzung von nicht harmonischen Instrumenten wie Trommeln oder einem Schlagzeug. Diese Instrumente haben keinen eindeutigen Pitch. Sie sind abhängig von dem Rhythmus und der Lautstärke. Da Moorers AMT sich jedoch auf das Frequenzmuster der Noten fokussiert, konnten diese Musikinstrumente nicht berücksichtigt werden.

2.1.2 Der Aufbau von Moorers AMT-System

Moorers automatische Musiktranskriptionssystem war eins der ersten seiner Art. Viele weitere AMT-Systeme leiten sich von diesem ab.

Zunächst wird ein analoges Musiksignal mit einem 14-Bit-A/D-Wandler digitalisiert. Dieses digitale Musiksignal wurde anschließend genutzt, um mithilfe von Bandpassfiltern, bestimmte Frequenzbereiche zu isolieren. Ein Bandpassfilter ist ein Filter welcher nur bestimmte Frequenzen durchlässt. Dadurch konnte Moorer die gespielte Note und deren Dauer, wie deren Onset und Offset, feststellen.

Nun mussten die bestimmten Noten einer gewählten Stimme zugeordnet werden. Dies wurde durch melodische Gruppierung verwirklicht. Zunächst wurden Inseln gebildet. Inseln sind Noten die sich zeitlich vollständig überlappen. Wir gehen davon aus dass jede Stimme nur eine Note gleichzeitig spielt, wodurch diese Noten nicht der gleichen Stimme zugeordnet werden können. Als Nächstes müssen die anderen Noten auf verschiedene Kombinationen getestet werden. Je geringer die Frequenzunterschiede zwischen aufeinanderfolgenden Noten sind, desto wahrscheinlicher stammen sie aus derselben Stimme. Dies liegt daran, dass melodische Linien in der Regel durch kleine, schrittweise Intervalle fortgeführt werden, während größere Sprünge häufiger auf einen Wechsel der Stimme hindeuten. Zudem werden Gruppierungen von Noten erstellt, welche am wahrscheinlichsten harmonisch nacheinander gespielt worden.

Zum Schluss ließ Moorer die gewonnenen Daten durch ein Programm laufen, um diese dann mithilfe eines Plotters in eine Notenschrift umzuwandeln.

2.2 Hidden Markov Modelle

Hidden Markov Modelle (HMM) sind statische Modelle, welche sich sehr gut zur Analyse von Musikstücken eignen. Sie wurden erstmals in den 1960er Jahren erfunden [Baum u. a. 1970] und sind ein zentraler bestandteil früher AMT-Systeme. HMMs beschreiben eine Abfolge von „versteckten Zuständen“, welche im Kontext von AMT-Systemen Noten im Audiosignal darstellen. Durch indirekt beobachtbare Daten, wie zum Beispiel die Spektraldaten des Audiosignals, können diese Noten erschlossen werden.

HMMs bestehen aus:

- Zustände (States)

- Übergangswahrscheinlichkeiten (Transition Probabilities)
- Emissionswahrscheinlichkeiten (Emission Probabilities)
- Beobachtungen (Observations)

Nehmen wir das Beispiel eines Klaviers. Ein Klavier hat 88 Tasten, und somit mindestens 88 Zustände. Durch Akkorde können zudem mehr Zustände generiert werden. Die Übergangswahrscheinlichkeit stellt dar, wie wahrscheinlich es ist, von einem Zustand zu einem bestimmten anderen Zustand zu wechseln. Zum Beispiel könnte es wahrscheinlicher sein, dass auf die Note C4 der Ton G3 folgt statt D1, da diese Tonfolge harmonischer und musikalisch plausibler klingt. Dies ist jedoch nur eine Annahme anhand von gesammelten Testdaten, weshalb es nicht als Begründung ausreicht. Deshalb kommt als zweite Instanz die Emissionswahrscheinlichkeit hinzu. Diese gibt an, wie wahrscheinlich ein bestimmter Zustand in der momentanen Beobachtung ist. Die Beobachtung wird dabei zusammengesetzt aus Eigenschaften, wie Frequenzverteilung, Spektrogramm oder anderen Merkmalen die man aus anderen Modulen herleiten kann. Aus den gesammelten Daten kann nun mithilfe von zum Beispiel dem Viterbi-Algorithmus [Takeda u. a. 2002] die wahrscheinlichste Abfolge von Zuständen berechnet werden.

In gewisser Weise lassen sich HMMs auf KI-Modelle übertragen. Beide arbeiten mit versteckten Zuständen und berechnen anhand von Testdaten die wahrscheinlichste Kombination von Zuständen. Natürlich sind moderne KI-Modelle weitaus komplexer, doch HMMs spielten im Kontext automatischer Musiktranskriptionssysteme eine zentrale Rolle dabei, wie KI-Methoden in diesem Bereich später eingesetzt wurden. Sie beeinflussten insbesondere den Umgang mit zeitlichen Abfolgen und Unsicherheiten in der Tonerkennung, was bis heute relevante Konzepte in KI-basierten AMT-Systemen sind.

2.3 Datensätze für AMT-Systeme

Während der Forschung an neuen AMT-Systemen wurden immer wieder neue Datensätze genutzt, um AMT-Systeme zu bespielen oder heutzutage auch zu trainieren. Es ist aufwändig nützliche Datensätze zu generieren, da viele verschiedene Musikstücke genutzt werden müssen und diese alle unter den gleichen Voraussetzungen aufgenommen werden müssen. In der Transkription von Musikstücken sind Datensätze sehr relevant, vor allem mit dem weiteren Einsatz von KI-Modellen werden große Datensätze gebraucht. Die ersten verwendeten Datensätze waren selbst erstellt und enthielten lediglich grundlegende Eigenschaften der Noten. In den AMT-Systemen von Moorer [Moorer 1977] oder auch Martin [Martin 1996] wurde solch ein Ansatz verfolgt. Durch die Einführung von MIDI-Dateien wurde ein Standard entwickelt, welcher jetzt im Großteil der AMT-Systeme eingebaut wird. Auf der Grundlage von MIDI-Dateien wurden auch spezialisierte Datensätze erstellt. Zwei der größten und wichtigsten sind MAPS (MIDI Aligned Piano Sounds) und MAESTRO (MIDI and Audio Edited for Synchronous Tracks and Organization). Dabei ist MAPS ein Datensatz aus künstlich generierten Audiospuren, während MAESTRO ein ungefähr 200 Stunden langer Datensatz von realen isolierten Studioaufnahmen ist. Vor allem bei dem Training neuer KI-Modellen sind solche großen Datensätze sehr hilfreich. Ein weiterer wichtiger Datensatz ist ADTOF (Annotated Drum Transcription Onset Features). Dieser besteht ausschließlich aus unharmonischen Instrumenten. In Moorers und anderen AMT-Systemen ist die Erkennung von unharmonischen Instrumenten ein großes Problem. KI-Modelle können sich mithilfe von dem ADTOF Datensatz auf diese Instrumente spezialisieren. Es gibt auch Methoden schnell seine eigenen Datensätze zu generieren. Eine der neuesten Methoden verwendet HMM- und Viterbi-basierte Alignment-Verfahren, um synthetische Audiosignale zu erzeugen und so zusätzliche Daten für das Training von KI-Modellen bereitzustellen [Joysingh, Vijayalakshmi und Nagarajan 2019].

2.4 Polyphone AMT-Systeme

Die meisten früheren AMT-Systeme befassten sich mit monophonen Musikstücken oder höchstens zweistimmigen Ansätzen. Der Großteil realer Musikwerke ist jedoch polyphon, das heißt, es erklin-

gen mehrere Stimmen gleichzeitig. Die Polyphonie stellte und stellt bis heute eine der größten Herausforderungen der automatischen Musiktranskription dar. Sie bringt zahlreiche Probleme mit sich, etwa komplexere Spektrogrammmuster, höheren Rechenaufwand und überlappende Stimmen. Eine Lösung für polyphone Musikstücke markierte daher einen wichtigen Meilenstein in der Entwicklung von AMT-Systemen. Aus diesem Grund widmeten sich mehrere Forscher dieser Fragestellung und entwickelten innovative Ansätze, wie etwa das Blackboard-System oder RASTA-basierte AMT-Systeme, die in diesem Kapitel vorgestellt werden.

2.4.1 Blackboard-System

Zunächst wird das Martin AMT-System [Martin 1996] vorgestellt. Sein Ansatz, zur Lösung von polyphonen Musikstücken, war ein Blackboard-System. Dieses integrierte er in sein AMT-System mit innovativen Modulen und Ansätzen.

Zur Verarbeitung des Input Audiosignals nutzt Martin ein Correlogram. Im Gegensatz zum Spektrogramm, das die Energieverteilung über Frequenzen zeigt, hebt das Correlogram durch Autokorrelation vor allem periodische Strukturen und Tonhöhen hervor. Nachdem das Input Audiosignal in einem Correlogram verarbeitet wurde, spaltet sich Martins AMT-System, in einen Analysepfad und einen Rhythmuspfad, auf. Dabei konzentriert sich der Analysepfad auf die Zusammenhänge der verschiedenen Noten, während der Rhythmuspfad sich mit der Lautstärke und den Notenanschlägen beschäftigt. Am Ende werden diese Kenntnisse zusammengeführt. Der Output besteht aus dem Onset, der Dauer und der Frequenz jeder gespielten Note. Martins AMT-System gibt nicht explizit zurück, welcher Stimme jede Note zugeordnet ist. Durch das Blackboard-System und insbesondere durch die sequentielle Analyse der Intervalle lassen sich die erkannten Noten nachträglich den einzelnen Stimmen korrekt zuordnen.

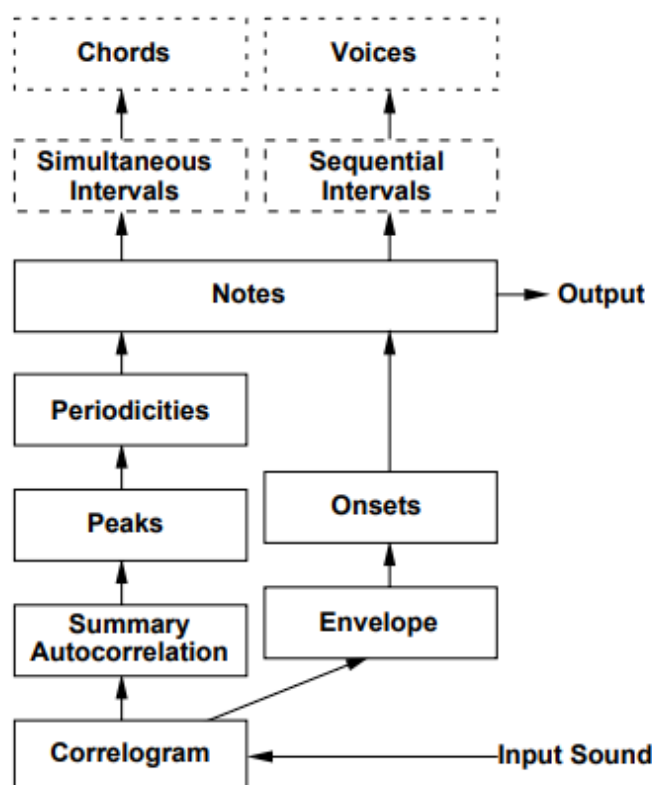


Abbildung 4: Systemstruktur des AMT-Ansatzes von Keith D. Martin (1996), aus [Martin 1996].

Martin nutzt ein Blackboard-System. Dieses besteht aus zwei Hauptbestandteilen. Der erste Teil ist die Sinuskurvenanalyse, mit der die für die Hypothesenbildung notwendigen Daten gewonnen werden. Zu ihr gehören das Correlogram, das Envelope, die Summary Autocorrelation und die Peaks.

Durch diese Verarbeitungsschritte können zentrale Eigenschaften der Noten bestimmt werden, die als Grundlage für weitere Analysen dienen.

Zum zweiten Teil gehören die Module Onsets, Periodicities sowie Simultaneous und Sequential Intervals. Diese Module arbeiten kollaborativ auf einem gemeinsamen Datenraum, indem sie Hypothesen über die ermittelten Noten aufstellen und sich gegenseitig mit zusätzlichen Informationen versorgen. Auf diese Weise lassen sich die erkannten Noten später einzelnen Stimmen zuordnen.

Der Analysepfad beginnt bei dem Correlogram. Hier wird der Input, ein reales Audiosignal, zunächst verarbeitet und dann in einem Correlogram dargestellt. Dieses visualisiert die Korrelation der gegebenen Noten in Abhängigkeit der Zeit, Frequenz und "Lag". "Lag" soll in diesem Fall darstellen, wann sich ein bestimmtes Signal wiederholt. Dabei ist das wiederholte Signal dasjenige, das dem Ursprungssignal maximal ähnelt, was bedeutet, dass der Korrelationswert an dieser Stelle am höchsten ist. Heißt, wenn ein Ton mit der Frequenz x gespielt wird und dieser sich nach beispielsweise 10ms wiederholt, wird das rechnerisch durch den "Lag" dargestellt. Als Nächstes wird mithilfe der Summary Autocorrelation das Correlogram komprimiert und die Datenstruktur normalisiert. Dadurch entsteht eine stabile Grundfrequenz, sodass die weiteren Schritte das Correlogram effizient untersuchen können. Nun werden, basierend auf der normierten Struktur, die Peaks gesucht. Diese Peaks deuten darauf hin, wann periodische Komponenten auftreten. Dabei geben sie nicht den Onset der Noten zurück, sondern nur die generelle Frequenz zu einer bestimmten Zeit. Darauf werden mehrere Peaks, die regelmäßig wiederkehren, gruppiert. So können Muster in der gespielten Musik erkannt werden und kurzzeitige Störfaktoren ausgeschlossen werden.

Im Rhythmuspfad wird wiederum die zeitliche Analyse der Noten durchgeführt. Zunächst wird mit dem Envelope die Lautstärke des Signals zu jedem Zeitpunkt festgelegt. Dies dient als Grundlage, um anschließend die Onsets der Noten zu bestimmen. Jeder Onset wird sehr präzise im Envelope dargestellt durch einen plötzlichen Anstieg der Lautstärke.

Nachdem die beiden Pfade durchgelaufen sind, hat man schon Noten, welche man grundsätzlich in Notenschrift transkribieren kann. Jedoch sind diese Noten musikalisch noch nicht verstanden worden. In der Abbildung-(Systemstruktur nach Martin) gibt es noch die Bestandteile Simultaneous und Sequential Intervals. In dem Modul Simultaneous Intervals wird ermittelt, welche Töne gleichzeitig erklingen. Diese können, wenn sie harmonisch zueinander sind, zu einem Chord gebunden werden. Sequential Intervals analysieren dahingegen, welche Töne nacheinander gespielt werden und möglicherweise eine Melodie bilden könnten. Dies erfolgt durch Tonhöhenverläufe, Pausen und Frequenzunterschiede. Dadurch können Melodien, Basslinien oder Begleitungen voneinander getrennt werden. Zum Schluss werden dadurch die verschiedenen Stimmen, in Martins Modell, aufgetrennt.

2.4.2 RASTA-basiertes System

Ende 1997 publizierte Klapuri seine Masterarbeit „Automatic transcription of Music“ [Klapuri und Eronen 1998]. In seiner Arbeit benutzt er ein neues RASTA-basiertes Verfahren, zur Unterdrückung nicht harmonischer Signalkomponenten. Somit konnten auch Musikstücke mit nicht harmonischen Instrumenten, wie Trommeln, transkribiert werden. Zudem führte er ein Modul ein, zur Schätzung der Anzahl an gleichzeitigen Stimmen, die in dem Musikstück vorkommen. Klapuris AMT-System konzentriert sich, gegenüber Martins AMT-System, viel mehr auf die Robustheit gegenüber echten polyphonen Audioaufnahmen mit Rauschen, Störgeräuschen und nicht harmonischen Instrumenten. Die Struktur des Systems ist linear aufgebaut und sehr präzise in dem Aufgabenfeld, für die es entwickelt wurde.

Klapuris System ist sequentiell aufgebaut und besteht aus sechs Modulen. Als Input wird eine reale Audioaufnahme genutzt, welche in ein Monosignal umgewandelt wird. Dieses Monosignal wird mithilfe von STFT transformiert, sodass durch das entstandene Spektrogramm Zeit, Frequenz und Amplitude der gegebenen Noten ausgelesen werden kann. Anhand dieser Daten werden als Nächstes die Onsets der Noten bestimmt. Klapuri nutzt, zur Onseterkennung, ein Schema von Eric D. Scheirer [Scheirer 1998]. Bei diesem wird das Audiosignal in Frequenzbänder aufgeteilt und auf jedem




Abbildung 5: Eigene Darstellung: Struktur von Klapuris RASTA-basiertem AMT-System

Band die zeitliche Änderung der Energie analysiert. Daraufhin werden die resultierenden Energie-Deviante der verschiedenen Bänder summiert. Die nun entstehenden Peaks werden als Onsets der Noten interpretiert. Als Nächstes werden unharmonische Instrumente und transiente Geräusche, wie zum Beispiel Rauschen, entfernt. Dies erfolgt mithilfe der RASTA-Filterung, welches auf das spektrale Signal, vom gegebenen Spektrogramm, wirkt. Mehr zu der RASTA-Filterung wird im Abschnitt-(RASTA-basiertes System), im Detail, erläutert. Um mehrere Töne, die gleichzeitig im Signal erklingen, zu erkennen wird harmonic matching genutzt. Die Multipitch-Schätzung funktioniert so, dass zu einer bestimmten Zeit immer die dominanteste Tonhöhe, basierend auf der Energieverteilung im Signal, gesucht wird. Sobald man diese ermittelt hat, wird sie vom Signal subtrahiert und dieses Verfahren wird erneut eingesetzt, bis man jeden signifikanten Pitch untersucht hat. Jetzt werden die Stimmenanzahlen geschätzt. Dieses Modul wird im Abschnitt-(RASTA-basiertes System) detailliert wiedergeben. In dem Modul Note-Formation werden jetzt die gegebenen Daten zusammengeführt und in eine MIDI-Datei zusammengefasst. Diese MIDI-Datei wäre jetzt bereit in Notenschrift transkribiert zu werden.

RASTA-Filterung

Die RASTA-Filterung ist eine der neuen Module von Klapuri. Sie bewirkt, dass nicht-harmonische Störsignale, wie Rauschen, unharmonische Instrumente und vom Musikstück unabhängige Geräusche ausgefiltert werden. Dadurch werden die harmonischen Komponenten des Stückes mehr herausgehoben, wodurch folgende Module einfacher weitere Eigenschaften den gegebenen Noten zuordnen können. Zudem stärkt dies die Robustheit der Multipitch-Schätzung, in der mehrere Töne zur gleichen Zeit im Audiosignal erkannt werden müssen. Dieses Verhalten wird erzielt, indem ein Filter gesetzt wird, der schaut, wie Laut jede Frequenz zu jedem Moment ist. Nach der Berechnung gibt der Filter eine Lautstärke-Kurve zurück. Alle Frequenzanteile, die entweder zu kurzzeitig sind, wie etwa Claps oder Hi-Hats, oder zu langanhaltend, wie dauerhaftes Rauschen, werden durch einen Bandpassfilter aus dem Audiosignal herausgefiltert. Dadurch bleiben vor allem die zeitlich stabilen, musikalisch relevanten Komponenten erhalten.

Multipitch-Schätzung

Auch die Stimmenanzahlerkennung ist, von Klapuri, ein neu eingefügtes Modul. Vor allem bei der Multipitch-Schätzung ist dieses sehr wichtig, da das System dadurch ein Bild davon bekommt, wie viele Töne gleichzeitig erklingen können, zu einer bestimmten Zeit. Die Multipitch-Schätzung zieht den spektralen Abdruck eines Tons von dem Audiosignal ab, wenn dieser erkannt wurde. Jedoch kann diese nicht einschätzen, wann genau sie aufhören soll die Töne zu erkennen. Da hilft die Stimmenanzahlschätzung. Diese analysiert das neue Audiosignal nach jeder Multipitch-Schätzung und gibt aus, ob in der spektralen Energie noch Noten zu erkennen sind. Dies ordnet die Stimmenanzahlschätzung durch drei Eigenschaften ein. Gibt es in der spektralen Energie noch typische Muster von harmonischen Klängen? Wie viele Stimmen wurden schon erkannt? Tragen die weiteren extrahierten Stimmen noch groß etwas zur Erklärung des gesamten Musikstückes bei? Dadurch extrahiert die Multipitch-Schätzung nur die nötigen Noten und unnötig Störfaktoren werden ausgelassen. Zudem kann man eine ungefähre Einschätzung bekommen, wie viele Stimmen in dem jeweiligen Musikstück erklingen.

2.5 Einbindung von Künstlicher Intelligenz

Für eine lange Zeit basierten AMT-Systeme größtenteils auf signal verarbeitenden Algorithmen, wie zum Beispiel HMMs (Hidden Markov Modelle). Doch auch diese Systeme waren nicht verschont

durch den stetigen Anstieg von KI basierten Lösungswegen. 2010 bis 2012 wurden die ersten Ansätze von AMT-Systemen erstellt, welche maschinelles Lernen nutzten [Eyben u. a. 2010]. Oft wurden KI-Modelle nur für bestimmte Teilprobleme genutzt wie Onset Detection, pitch estimation oder instrument classification. Dieser Trend zog sich durch, wodurch heutzutage so gut wie jedes AMT-System eine Art von KI-Modell nutzt.

Einige AMT-Systeme nutzen auch mehrere KI-Modelle gleichzeitig. Solch ein AMT-System wird auch einer 2016 veröffentlichten Arbeit beschrieben [Sigita, Benetos und Dixon 2016]. Es ist eins der ersten KI basierenden Ent-to-End AMT-Systeme, welches polyphone Musikstücke transkribieren kann. Der KI-Ablauf des AMT-Systems ist folgendermaßen aufgebaut. Ein CNN bekommt als Input ein Log-Mel-Spektrogramm des Audiosignals bereitgestellt und entzieht diesem bestimmte Merkmale der Noten. Diese Merkmale werden einem RNN weitergegeben, welches dadurch die zeitlichen Abhängigkeiten herausfiltert. Als Nächstes wird durch Frame-wise Multi-Label Classification vorhergesagt, welche Noten zu welcher Zeit aktiv sind. Somit bekommt man als Output eine Binärmatrix, wo der Pitch mit Abhängigkeit der Zeit angezeigt wird. Das System wird mit dem MAPS Datensatz durch Supervised Learning trainiert. Diese Arbeit stellt den drastischen Übergang von heuristischen, regelbasierten AMT-Systemen zu selbstlernenden AMT-Systemen dar. Heutzutage sind CNNs und RNNs, oder ähnliche KI alternativen, kaum wegzudenken aus der Struktur von AMT-Systemen.

Viele intelligente und erfindungsreiche Personen haben sich über die Jahre mit AMT-Systemen beschäftigt. Dadurch konnten nachfolgende Arbeiten neue Module und Ansätze für sich nutzen, um deren Entwicklung weiter voranzutreiben. Auch heutzutage ist dies immer noch der Fall, wodurch es stets neue AMT-Systeme mit neuen Ansätzen gibt. Diese neuen, auf KI basierenden Systeme, haben alle jeweils ihre eigenen Stärken und Schwächen. Auch wenn die Forschung von AMT-Systemen in den letzten Jahren zahlreiche Fortschritte erfuhr, gibt es trotz dessen noch große Baustellen und ungelöste Aufgaben. Im folgenden Kapitel wird genauer der momentane Stand von AMT-Systemen behandelt. So werden anhand einiger unterschiedlichen Beispiele, verschiedene AMT Strukturen dargestellt. Zudem werden die relevantesten Hindernisse in der heutigen automatischen Musiktranskription aufgegriffen.

3 Hindernisse Moderner AMT-Systeme

Trotz der Einführung von KI-Modellen bestehen weiterhin zahlreiche Probleme, die bislang ungelöst oder nur unzureichend gelöst sind. Zudem agieren KIs völlig anders als normale Algorithmen. Dadurch entstehen einige zusätzliche Herausforderungen die behandelt werden müssen. In den folgenden Abschnitten werden die größten und wichtigsten Probleme, mit der sich die AMT Forschung momentan auseinandersetzt, aufgezählt.

3.1 Onset Detection

Die On-/Offset Erkennung von Noten wurde schon ausgiebig in zahlreichen Arbeiten behandelt. Trotzdem ist diese noch nicht komplett akkurat. Das liegt daran, dass On-/Offsets an Lautstärke sprüngen und spektralen Änderungen erkannt werden. Bei polyphonen Musikstücken mit vielen verschiedenen Noten ist es schwieriger diese Unterschiede zu erkennen. Lautstärke sprünge werden ungenauer, da häufig mehrere Noten während des Onsets einer bestimmten Note spielen. Spektrale Änderungen stehen für Veränderungen der Energieverteilung. Einer der ausschlaggebendsten Anteile ist die Spektrale Fluktuation. Diese stellt den plötzlichen Anstieg von Energie in bestimmten Frequenzbändern dar. Wenn mehrere einzelne Töne hintereinander, auf einem Klavier, gespielt werden, kann der Onset der gespielten Noten leicht ermittelt werden. Bei Instrumenten, wie einer Geige, können dabei Probleme entstehen. Auf Geigen können Noten gebunden gespielt werden, was zu einem Unterschied in der Frequenz, jedoch nicht in dem Energie level führt, da die Stärke des Bogenstrichs gleichmäßig bleibt. Zudem kann eine Note, durch Crescendo, zunächst leise gespielt werden und mit der Zeit an Lautstärke zunehmen. Dieser Onset hat keinen Energie-Peak und somit erkennt das System hier auch nur schwierig eine scharfe Kante. So welche Töne, welche keinen starken Einschlag haben, werden

als nicht-perkussiv bezeichnet. Ein weiteres Problem der Onset Erkennung sind nachwirkende Geräusche oder Störgeräusche. Bleiben wir bei dem Beispiel einer Geige. Wenn ein Ton gespielt wird und der Bogen von der Geige abgehoben wird entsteht eine Resonanz des Tons. Das führt zu einem nachklingen des Tons, was sehr natürlich passieren kann, jedoch meist kein beabsichtigtes Merkmal eines Tons ist. Das KI-Modell sieht dieses nachklingen aber noch als der gespielte Ton und erkennt nicht perfekt das Offset des Tons. Zudem könnten Töne von anderen Instrumenten verdeckt werden, wodurch das System den Onset nicht erkennt. Ähnlich kann dies auch ein Problem darstellen, wenn im Audiosignal ein starkes Rauschen besteht.

3.2 Polyphonie

Durch die Nutzung von polyphonen Musikstücken sind, wie schon bei der Onset Erkennung angemerkt, einige Probleme schwerwiegender und deutlicher geworden. Ein weiteres Problem, das gezielt von diesen Anwendungsfällen abhängt, ist die Verwechslung von Noten im Audiosignal. Einige Noten haben sehr ähnliche Frequenzen. Wenn diese Noten gleichzeitig gespielt werden, ist es schwieriger für das System, die korrekten Noten herauszuhören. Neuronale Netzwerke helfen hierbei deutlich, da diese nicht nur das Spektrum zur analyse einbeziehen, sondern auch auf einer zeitlichen und harmonischen Ebene den Kontext zuordnen können und somit die wahrscheinlichsten nächsten Noten zurückgeben können. Trotz dessen scheitert auch KI an der Einordnung der richtigen Noten, wenn die gespielten Noten eine sehr ähnliche Frequenz besitzen oder die Akkorde zu unterschiedlich zu den Trainingsdaten sind. In der Referenzierten Arbeit [martak2022balancing](#) werden diese Probleme nochmals deutlicher aufgegriffen.

3.3 Spezielle Instrumente

Oft ist die Qualität der Transkription auch abhängig von den vertretenen Instrumenten in dem Audiosignal. Ethnische Instrumente zum Beispiel sind Instrumente die einer bestimmten Kultur angehören und in der westlichen Kultur weniger vertreten sind. Dadurch gibt es auch weniger Datensätze, welche diese Instrumente beinhalten. KIs brauchen Trainingsdaten und ohne diese können sie bestimmte Instrumente nicht richtig zuordnen. Die meisten Datensätze zur Musiktranskription bestehen hauptsächlich aus Klavier und Geigen Noten. Instrumente wie Flöten oder Orgeln können von diesen Noten gut abgeleitet werden, da sich deren Struktur deutlich ähnelt. Eine weitere Gruppe von Instrumenten die Probleme bei der Transkription bereitet sind elektronische Instrumente. Wenn zum Beispiel eine E-Gitarre gespielt wird, kann diese Effekte nutzen, welche nicht üblich in klassischen Klavier Datensätzen vorkommen. Somit kann die KI diese Töne nicht korrekt erkennen. Ein weiteres Instrument welches Schwierigkeiten bringt, ist der Gesang. Jede Stimme ist einzigartig und vor allem nicht konstant. Wenn ein Ton auf einem Klavier gespielt wird, besitzt dieser, wenn das Klavier richtig gestimmt ist, immer die gleiche Frequenz. Ein Mensch kann jedoch nicht jeden Ton immer komplett perfekt singen, wodurch eine große Varianz an Tönen entsteht. Zudem verläuft der Klang einer Stimme von einer Note zur nächsten. Es gibt nicht immer starke Peaks zur Onset Erkennung. Gesang ist auch, wie die vorher genannten Instrumentgruppen, nicht sonderlich vertreten in größeren Datensätzen. Die folgenden Paper konzentrieren ihren Fokus speziell auf das Thema des Gesangs in der Musiktranskription [gu2023deep](#), [gu2024automatic](#). Somit wurde eine Onset Erkennungsgenauigkeit von ungefähr 80% festgestellt, für Gesang.

Die folgende Tabelle stellt einige traditionelle Instrumente aus verschiedenen ethnischen Gruppen dar. Diese Tabelle ist nicht vollständig und dient ausschließlich dazu, die Vielfalt der Instrumente in unserer Welt zu veranschaulichen.

Region	Instrumente
Europa	Klavier, Violine, Gitarre, Flöte
Arabische Welt	Oud, Qanun, Nay, Darbuka
Türkei	Bağlama (Saz), Kemençe, Zurna, Davul
Persien / Iran	Tar, Setar, Santur, Tombak
Indien	Sitar, Tabla, Harmonium, Bansuri
China	Guzheng, Erhu, Pipa, Dizi
Japan	Koto, Shamisen, Shakuhachi, Taiko
Indonesien	Gamelan, Kendang, Suling, Rebab
Afrika	Kora, Djembe, Balafon, Mbira

Tabelle 2: Übersicht populärer Instrumente verschiedener Weltregionen

3.4 Notendauer

Neben dem Onset einer Note muss auch erkannt werden, wie lange eine bestimmte Note gespielt wird. Eine Schwierigkeit dabei ist der, im Abschnitt-(Onset Detection) angesprochenen, Nachhall einer Note. Dieser muss auseinandergehalten werden von der wirklichen Notendauer. Es gibt jedoch bei einigen Instrumenten, wie zum Beispiel dem Klavier, ein spezielles Problem. Wenn während des Spielens einer Note das Dämpferpedal eines Klaviers gedrückt wird, gibt es keinen klaren Punkt, an dem der Übergang zwischen der Note und dem Nachhallen eindeutig eingeordnet werden kann. Die Lautstärke sinkt dabei nicht abrupt, sondern nur langsam ab. Natürlich ist dieses Problem in polyphonen Musikstücken deutlich stärker, da sich dort die verschiedenen Nachhallphasen überlappen. Dies ist eins der grundlegendsten Probleme, zusammen mit der Onset Erkennung jamshidi2024machine.

3.5 Reale Audioaufnahmen

Ein perfektes AMT-System sollte sogar auf realen Audioaufnahmen 100% Genauigkeit besitzen. In der Realität funktioniert dies jedoch noch nicht, da Live-Audioaufnahmen Hintergrundrauschen enthält. Dies war schon vor der Einführung von KI ein Problem und wurde durch die Einbindung von KI-Modellen nicht sonderlich verbessert. Das liegt daran, dass KIs mit isolierten Studioaufnahmen, wie es im MAESTRO Datensatz der Fall ist, trainiert werden. Natürlich gibt es auch Datensätze mit realen Audioaufnahmen, jedoch bräuchte es dafür viel mehr Trainingsdaten und vor allem auch eine große Anzahl von unterschiedlichen Hintergrundgeräuschen, damit die KI auf alle Möglichkeiten trainiert wird. Um dem entgegenzuwirken, können Studio-Datensätze wie MAESTRO durch Data-Augmentation variiert werden, wodurch realistischere Audioaufnahmen erstellt werden können. So wurden auch die Trainingsdaten in folgender Arbeit erzeugt kusaka2024mobile. Es wird Timber, Reverb, Noise variiert und die Qualität des Aufnahmegerätes angepasst. So werden zahlreiche neue Datensätze kreiert, die passend auf die gegebenen Anwendungsfälle ausgelegt sind.

3.6 Frame-basierte vs Event-basierte AMT-Systeme

Die meisten AMT-Systeme sind Frame-basiert und nicht Event-basiert. Frame-basiert bedeutet, dass die Analyse des Audiosignals in Zeitfenster, von ungefähr 20ms, aufgeteilt wird. Ein KI-Modul, wie zum Beispiel ein RNN, analysiert diese Zeitfenster einzeln, in Abhängigkeit von den vorherigen Zeitfenstern. Falls nun zum Beispiel ein Onset einer Note genau zwischen zwei Zeitfenstern liegt, wird dieser verschoben oder verzerrt, sodass das Onset klar in einem der gegebenen Zeitfenster liegt. Event-basierte AMT-Systeme hingegen fragen immer ab, was das nächste musikalische Ereignis im Audiosignal ist und reagieren dementsprechend. Somit müssen keine musikalischen Merkmale verschoben werden, da sie ihre eigene Position besitzen und nicht abhängig von Zeitfenstern (Rastern) sind. Dadurch entspricht der Output viel mehr dem Input, in relation zu der zeitlichen Abfolge. Im Ergebnis sind Event-basierte AMT-Systeme somit Frame-basierten AMT-Systemen überlegen. In der Realität sind die meisten AMT-Systeme trotzdem Frame-basiert. Das liegt daran, dass Event-basierte AMT-Systeme eine sehr neue Entwicklung sind und zudem auch schwerer zu implementieren sind.

Frame-basierte Methoden wurden ungefähr im Jahre 2000 entwickelt und haben sich seitdem in zahlreichen Arbeiten durchgesetzt (Martin 1996, Klapuri 1998, Automatic). Dahingegen sind Event-basierte Methoden erst ungefähr 15 Jahre später entwickelt worden (Performance, 2017, Event). Dadurch waren Frame-basierte Methoden länger der Standard für AMT-Systeme. Zudem ist die Umsetzung von Event-basierten AMT-Systemen komplizierter als Frame-basierte. Das System muss jedes Event korrekt einschätzen, basierend auf dem System wird eine Notiz nur einmal für die nachfolgenden Frames, in denen sie klingt, vorhergesagt. Modellen oder anderen Algorithmen entnommen wird. Bei der Frame-basierten Transkription hingegen wird eine Event-basierte AMT-Systeme nicht parallel verlaufen, sondern muss tokenweise abgearbeitet werden. Deswegen ist eine Event-basierte AMT-Systeme eine größere Herausforderung. Sie führt deutlich mehr Risiken mit sich, gebend auf das System steht es sollte der Übergang von Frame zu Event mit der Zeit unausweichlich, das mit der Inhalt von M-basierten Transkriptionen nicht möglich wäre. Die Forschung im Bereich der Event-basierten Transkription hat

3.7 Blackbox von KI-Modellen

Das letzte Problem betrifft KI im generellen. Ein neuronales Netz arbeitet mit sehr hochdimensionalen Räumen, die für uns Menschen nicht begreifbar sind. Selbst wenn sich jemand alle Gewichtungen in einem neuronalen Netz anschauen würde, würde dieser keinen Zusammenhang feststellen können. Dies stellt auch ein Problem in der Musiktranskription dar, da somit nicht erfasst werden kann, welche Einstellungen eine AMT-KI genau braucht, damit sie alle Musikstücke perfekt transkribieren kann. Um dieses Problem zu lösen, gibt es Methoden, welche die Blackbox ein wenig umgehen. Das Forschungsgebiet der Explainable AI befasst sich damit, KI-Modelle zu entwickeln, welche für den Menschen nachvollziehbar und verständlich sind. Dies geschieht durch verschiedene Methoden und Darstellungen, welche den Denkfluss einer KI veranschaulichen sollen. Einige von diesen Methoden finden ihre Anwendung auch in KI-basierten AMT-Systemen wieder. Methoden die zur Nutzung in AMT-Systemen diskutiert werden, sind Concept Activation Vectors, Layer-wise Relevance Propagation und Surrogat-Modelle. Diese wurden jedoch noch in keinem AMT-System richtig implementiert. Musikalische Konzepte wie Akkorde oder Onsets sind nicht direkt labelbar, wie zum Beispiel Katzen oder Hunde, da diese stark abhängig von spektralen und zeitlichen Mustern sind. AMT-Systeme sind zeitlich-sequenziell und besitzen pro Zeitfenster mehrere Outputs. Viele lokale Änderungen auf ein bestimmtes Zeitfenster, wie den dB-Wert ändern, haben einen globalen Einfluss. Methoden, welche in AMT-Systemen angewendet werden, haben dahingegen Eigenschaften, die durch die Struktur von AMT-Systemen profitieren. Methoden die schon in AMT-Systemen eingesetzt werden sind Saliency Maps, Feature-Visualisierung und Attention-Mapping. Saliency Maps stellen dar, wie stark jedes Zeitfenster beeinflusst, das ein bestimmter Ton erkannt wurde. Dies basiert auf dem Gradienten und ist besonders hilfreich bei CNN-basierten Modellen. Feature-Visualisierung beobachtet konkret die einzelnen Neuronen jeder Ebene im neuronalen Netzwerk. Es wird geschaut, welche Neuronen sehr stark bei bestimmten Inputs reagieren. So kann erkannt werden, welche Teile des Netzes für welche Aufgaben verantwortlich sind und ob vielleicht bestimmte Stellen des Netzes gar nicht genutzt werden. Attention-Mapping nimmt den gegebenen Input und gewichtet diesen, je nachdem welche Teile davon wichtig für eine bestimmte Vorhersage sind. So wird erkannt, welche Zeitfenster den meisten Einfluss auf einen bestimmten Onset hatten. Vor allem bei polyphonen Musikstücken können relevante zeitliche Zusammenhänge erkannt werden. Ein gutes Beispiel von Attention-Mapping kann in folgender Arbeit gefunden werden (Cheuk 2021 revisiting).

4 KI-Modelle in AMT-Systemen

KI-Systeme haben, in den letzten Jahren stark an Beliebtheit gewonnen. AMT-Systeme bilden da keine Ausnahmen. Vor allem durch die Integration von CNNs und RNNs konnten AMT-Systeme zahlreiche Prozesse deutlich verbessern und neue Errungenschaften in dem Forschungsgebiet erzielen. Es gibt jedoch auch weitere wichtige KI-Modelle die in AMT-Systemen häufig genutzt werden oder zur Integration in Planung stehen. In diesem Kapitel werden genau diese KI-Modelle stärker behandelt und deren Aufgaben in der automatischen Musiktranskription weiter erläutert.

4.1 Convolutional Neural Networks

CNNs sind neuronale Netze, welcher besonders gut räumlich strukturierte Daten analysieren können. Deshalb werden diese vor allem in der Analyse von Bildern genutzt. Sie können zum Beispiel erkennen, was auf einem Bild genau passiert oder welche Objekte in einem Bild zu erkennen sind. Auch KIs wie ChatGPT nutzen eine verbesserte Form von CNNs, um Bilder zu analysieren. Im Fall der Musiktranskription wird als Input Bild ein Spektrogramm verwendet. Spektrogramme können ähnliche wie zweidimensionale Bilder gehandhabt werden, da auf diesen auch alle wichtigen Daten des Inputs Audiosignals zu finden sind. CNNs bestehen aus mehreren verschiedenen Layern. Einfache CNN Modelle bestehen nur aus 2 bis 5 Layern, wobei komplexere CNNs aus über tausende Layern bestehen können. In AMT-Systemen haben die meisten CNNs etwa drei bis zehn Layer. Diese Layer sind Convolutional Layer (Faltungsschicht), Activation Layer (ReLU), Pooling Layer, Batch Normalization, Dropout Layer und Upsampling. Mit jedem Layer kann ein CNN immer abstraktere Merkmale erkennen. Außer dem Convolutional Layer und Activation Layer sind die anderen Layer jedoch nicht unbedingt notwendig. Eine Arbeit, welche die Stärke, von CNN-Modellen in AMT-Systemen, sehr gut darstellt, heißt „Onsets and frames“ [Hawthorne u. a. 2017]. In dieser Arbeit werden direkt zwei verschiedene spezialisierte Teilnetzwerke für Onsets und Sustain der Noten. Mit diesem System wird die Entwicklung des Forschungsgebietes illustriert. Insbesondere für polyphone Klaviertranskription ist dieses AMT-System ausgezeichnet. Im Folgenden werden die verschiedenen Layer eines CNNs, in einem AMT-System, erläutert.

4.1.1 Layer eines CNNs

In dem Convolution Layer werden Filter verwendet. Filter sind 2D-Matrizen, die aus trainierbaren Gewichten bestehen. Ein Filter deckt jeweils einen 3x3 Pixel Eingabebereich des Inputbildes ab. Jeden Filter, den man auf das Bild anwendet, wird über das gesamte Bild gezogen und analysieren dadurch erstmal jeden Eingabebereich einzeln. Ein Skalarprodukt aus Filter und Eingabebereich beschreibt dann einen Aktivierungswert. Aus allen Aktivierungswerten eines Filters entsteht eine Feature Map. Wenn man Aktivierungswerte miteinander vergleicht, können somit Patterns und Eigenschaften erkannt werden. In der Musiktranskription filtert man somit Onsets, Sustains oder harmonische Verläufe heraus. Zum Beispiel Onsets werden erkannt, wenn es eine plötzliche Energieänderung gibt. Am Ende bekommt man einen 3D-Tensor raus, welcher alle Feature Maps beinhaltet.

Die Batch Normalization sorgt dafür, dass die Aktivierungswerte normalisiert werden. Jede Feature Map wird dabei einzeln normalisiert. Dadurch wird Rechenleistung eingespart. Zudem kann man im Training durch Mini-Batches mehrere Spektrogramme gleichzeitig durch die CNN Struktur leiten. Dadurch wird das Training schneller und man kommt früher an Ergebnisse.

Es kann passieren, dass die Summe eines Convolution Layers negativ ist. Dies kann passieren, wenn stärker gewichtete Filter einen negativen Aktivierungswert herausgeben. Negative Werte können zu Informationsverlust, von Eigenschaften des Musikstückes, führen. Um das zu vermeiden werden im Activation Layer, meistens mit der ReLU Funktion, alle negativen Aktivierungswerte auf 0 gesetzt. So kann das Netz nichtlineare Beziehungen modellieren.

Als Nächstes wird mit dem Pooling Layer der Rechenaufwand verringert. Dieser nimmt jede Feature Map einzeln und reduziert deren Matrix zu einer kleineren, standardmäßig eine 2x2, Matrix. Das erfolgt, indem sich der Pooling Layer zunächst eine gesamte Feature Map nimmt und diese dann in kleinere Blöcke aufteilt. Es gibt entweder Max-Pooling oder Average-Pooling. Je nachdem welche Methode man wählt, wird immer der höchste Wert oder der durchschnittliche Wert extrahiert. Der extrahierte Wert von jedem Block wird nun in die reduzierte Feature Map zurückgeführt. Dadurch reduziert man nicht nur Rechenaufwand, sondern vermeidet auch Überanpassung. Wenn das System jeden kleinsten Wert berücksichtigt passt es sich zu sehr an den Trainingsdaten an und kann womöglich andere Daten nicht mehr richtig analysieren.

Der Dropout Layer ist, im Gegensatz zu den anderen Layern, nur im Training relevant. Er schaltet zufällig bestimmte Neuronen aus, sodass sich Neuronen nicht ausschließlich auf bestimmte andere

Neuronen verlassen können. Somit wird das gesamte neuronale Netzwerk robuster und vielseitiger.

Upsampling ist das Gegenteil von dem Pooling Layer. Anstatt die Feature Maps zu reduzieren, werden diese wieder hochskaliert. Dadurch kann man bestimmte Features wieder zeitlich präziser bestimmen, da die Zeitfenster wieder genauer zum originellen Audiosignal sind. Meist wird dieser Layer jedoch weggelassen, da er häufig nicht sehr relevant für AMT-Systeme ist.

Ein CNN gibt als letzte Ausgabe einen 3D-Tensor zurück, welcher aus den Zeitfenster (Frames / T), der Frequenzachsenlänge (F) und der Anzahl der Filter (C) besteht.

$$\text{CNN-Ausgabe} \in \mathbb{R}^{T \times F \times C}$$

Meist schließt sich nach einem CNN, in einem AMT-System, ein RNN als Nächstes an. Dieses kann jedoch nur 1D-Vektoren verarbeiten und nicht einen 3D-Tensor. Dieser 3D-Tensor wird deshalb vor der Übergabe durch eine Flattening-Operation zeitschrittweise in 1D-Vektoren umgewandelt. Dabei wird der Vektor mit einer Dimension von $F \times C$ erhalten. Diese Vektoren werden dann an das folgende RNN weitergeleitet.

In der folgenden Darstellung wird ein CNN dargestellt, mit deren gegebenen Layern. Als Input wird beispielhaft ein CQT-Spektrogramm verwendet. Durch die Convolution- und Pooling-Schichten werden die Merkmale extrahiert. Darauf folgend werden diese Merkmale vektorisiert und durch ein Fully Connected Layer klassifiziert. In diesem Beispiel werden als Output Tönhöhen vorhergesagt. Das gleiche CNN könnte aber auch andere musikalische Merkmale extrahieren, je nachdem wie dieses trainiert wurde.




Abbildung 6: Visualisierung einer CNN Struktur zur automatischen Musikttranskription. Eigene Darstellung in Anlehnung an [Shahriar 2020].

4.1.2 Geschichtliche Einordnung von CNNs

CNNs finden ihren Ursprung im Jahre 1979. Die erste richtige Architektur für CNNs wurde, unter dem Namen „Neocognitron“, veröffentlicht [Fukushima 1980]. Dies sollte als Vorreiter für spätere CNN Modelle gelten. Es dauerte weitere 10 Jahre bis das erste richtige Convolutional Neural Network veröffentlicht wurde [LeCun, Boser u. a. 1989]. Dieses CNN Modell unterscheidet sich speziell in drei bestimmten Punkten zu dem Vorgänger Neocognitron. In diesem wurde Gradientenlernen durch Backpropagation integriert, wodurch das gesamte Netzwerk erstmals auf ein gemeinsames Ziel zu trainieren konnte. Neocognitron besaß zudem, im Gegensatz zu LeCuns CNN, keine Gewichtsverteilung mithilfe von Filtern, wie es in heutigen CNN Modellen standard ist. Zudem hatte Fukushima keine praktische Anwendung. Er hatte die Idee und wie man diese umsetzt, doch durch damalige Verhältnisse war es für ihn schwierig diese umzusetzen. Für AMT-Systeme wurde CNN jedoch erst ungefähr im Jahre 2015 relevant [Sigitia, Benetos und Dixon 2016]. In dieser Arbeit wurde erstmals

polyphone Musikstücke mithilfe von CNNs, und weiteren KI-Modelle, transkribiert. Seitdem sind CNNs ein wichtiger Bestandteil der modernen automatischen Musiktranskription.

4.2 Recurrent Neural Networks

RNNs sind neuronale Netze, welche entworfen wurden um Daten mit zeitlicher Struktur zu verarbeiten. Dabei ist die Besonderheit von RNNs das diese ein Gedächtnis haben. Wenn jetzt in einem AMT-System eine bestimmte Tonabfolge gespielt wurde, kann sich das RNN diese merken und dementsprechend die fortlaufenden Ausgaben anpassen. Dies passiert dank den Hidden States. Dieser stellt das Gedächtnis des RNNs dar und ist einer der wichtigsten Faktoren in einem RNN. Die Hidden States werden im nächsten Abschnitt ausführlicher beschrieben. Dieses Prinzip ist in der Musiktranskription sehr hilfreich, da jede Note stark von den vorherigen gespielten Noten abhängt. Takt, Rhythmus, Harmonie und die Melodie eines Musikstückes sind alles gute Beispiele, warum diese sequenzielle Abfolge so passend in AMT-Systemen ist.

RNNs haben in der automatischen Musiktranskription mehrere Aufgabenfelder. Je nachdem wie man das RNN trainiert bewältigt dieses alle Aufgaben oder nur einen Teil. Diese Aufgaben bestehen aus Frame-Glättung (Temporal smoothing), Kontext-Modellierung (Temporal context modeling), Feature-Zusammenführung (Sequential integration of acoustic features) und Ausgabevorbereitung (time-distributed output classification). Diese Aufgaben werden auf jedes Zeitfenster, auf jeden 1D-Vektor des CNNs, angewendet. Doch bevor man sich auf diese einzelnen Aufgaben konzentrieren kann, muss man noch wissen, was Hidden States sind.

Hidden States

Hidden States sind das grundlegende Prinzip, warum RNNs funktionieren. Sie stellen praktisch das Gedächtnis des RNNs dar und helfen somit anderen Modulen Vorhersagen über bestimmte musikalische Eigenschaften zu treffen. Für jeden 1D-Vektor, den das CNN liefert, wird ein Hidden State erstellt. Diese werden sequenziell nacheinander, mit Abhängigkeit des vorherigen Hidden States, definiert.

$$\mathbf{h}_t = f(\mathbf{x}_t, \mathbf{h}_{t-1})$$

In Hidden States ist das Wissen der vorherigen Zeitfenster über zeitliche Muster, wie Sustain und Akkordstruktur. Sie alleine können jedoch noch keine eigene Entscheidung über bestimmte Noten fällen. Dafür müssen andere Module die Informationen der Hidden States später richtig verwerten. Jeder Hidden State hat eine Anzahl von Dimensionen, welche gleich der Anzahl der Neuronen in einem RNN ist.

4.2.1 Grundstruktur eines RNNs

Bei der Frame-Glättung bekommt das RNN als Input die Aktivierungswerte des Zeitfensters. Es betrachtet diese mit Kontext zu den vorherigen Zeitfenstern, um falsche Vorhersagen auszuschließen. Das CNN hat dem RNN schon Vorhersagen für bestimmte Noten gegeben. Diese könnten jedoch fehlerhaft. Zum Beispiel kann die Note C4 für den Frame 6 und 8 aktiv sein, aber bei dem Frame 7 hat das CNN diese Note nicht als aktiv angesehen. Es ist sehr unwahrscheinlich, dass eine Note für nur einen Frame ausfällt. Solche Arten von Fehlern verarbeitet das RNN über mehrere Zeitfenster hinweg, mithilfe seiner wiederkehrenden Struktur. Dieser Vorgang wird auch als zeitliche Entfaltung bezeichnet. Dadurch ist der Ton C4 auch im Frame 7 aktiv.

Die folgende Abbildung zeigt die Entfaltung eines einzigen RNN-Blocks über mehrere Zeitpunkte hinweg. In der Abbildung steht „x“ für den 1D-Inputvektor eines CNNs, „h“ für den Hidden State und dem somit verbundenen Gedächtnis des RNNs und „o“ für den Outputvektor, mit dem weiter gerechnet wird. Die Buchstaben „W, U und V“ stellen dabei die verschiedenen Gewichte „Input-Gewicht, Recurrent-Gewicht und Output-Gewicht“ dar.




Abbildung 7: Entfaltung eines RNN-Blocks [Wikimedia Commons contributors 2016].

Diese Abbildung ist beschreibbar durch folgende Formel. Dabei steht „b“ für den Bias-Vektor des Hidden Layers und „c“ für den Bias-Vektor des Output-Layers.

$$h_t = \tanh(W \cdot x_t + U \cdot h_{t-1} + b)$$

$$o_t = \sigma(V \cdot h_t + c)$$

Die Kontext-Modellierung ist etwas komplizierter als die Frame-Glättung. Als Input bekommt diese auch die 1D-Vektoren des CNNs. In der Kontext-Modellierung werden größere zeitliche Zusammenhänge betrachtet. So kann die Kontext-Modellierung, mithilfe des Hidden States, den Notenverlauf oder auch die Länge einer Note vorhersehen. Je nach den Trainingsdaten ist es zum Beispiel üblicher, dass auf C4 ein D3 folgt, was durch die Kontext-Modellierung angepasst wird. Dies ist aber immer stark von der Musikrichtung und Musikern abhängig, welche in den Trainingsdaten vorhanden sind. Jazz und Pop oder Bach und Taylor Swift unterscheiden sich der Style der Tonabfolge extremst. Zudem wird Onset, Sustain und Offset stabilisiert. Durch vorherige Beispiele weist die Kontext-Modellierung, wie lange eine bestimmte Note andauern wird und kann so das Offset der Note einschätzen. Als Output bekommt man kontextabhängige Vektoren. Sie haben die gleiche Struktur wie die 1D-Vektoren vom CNN, sind aber entsprechend dem Kontext angepasst.

Die Feature-Zusammenführung ist der letzte wichtige interne Schritt eines RNNs. Bei diesem werden aus lokalen alleinstehenden Informationen eines Zeitfensters konkrete musikalische Ereignisse. Dadurch schreibt das RNN Ereignisse, wie Akkorde, Noten, Onsets und vieles mehr, heraus. Dafür muss die Feature-Zusammenführung sich die einzelnen 1D-Vektoren als eine Folge von Events anschauen. Dies passiert wiederum über den Hidden State. Das wird vor allem wichtig, wenn man später eine MIDI-Datei ausgeben möchte, da in dieser auch die einzelnen musikalischen Ereignisse aufgeschrieben sind. Als Output bekommt man kontextreiche Vektoren. Diese Vektoren sind, durch die vorherigen Module angepasste und verbesserte, Hidden States.

Die Ausgabevorbereitung ist der letzte Schritt des RNNs, wodurch nun die gesammelten Daten zu echten musikalischen Ereignissen zusammengefügt werden. Als Input werden die, durch die Feature-Zusammenführung verbesserten, Hidden States genutzt. Zunächst werden diese durch ein Fully Connected Layer geschickt.

$$z_t = W \cdot h_t + b$$

Ein Fully Connected Layer ist ein Klassifikator, welcher den Hidden States auf eine gewünschte Dimension bringt. Wenn man zum Beispiel Klaviertasten vorhersagen möchte, werden alle Hidden States auf mit 88 Dimensionen ausgestattet. Bei MIDI-Dateien wären es 128 Dimensionen. Die Werte, welche aus dem Fully Connected Layer stammen, sind jetzt noch nicht richtig interpretierbar. Um diese als konkrete und normalisierte Wahrscheinlichkeiten darstellen zu können, wird eine Aktivierungsfunktion eingesetzt. Mit, zum Beispiel, der Sigmoid-Funktion als Aktivierungsfunktion, können alle Werte normiert in einem Bereich zwischen 0 und 1 gebracht werden. Sagen wir, wir wollen jetzt die gespielten Klaviertasten vorhersagen. Dann hat jeder Hidden State jetzt für alle Klaviertasten einen

eigenen Wert mit einer Wahrscheinlichkeit, das diese Taste zu dem gewählten Moment gespielt wurde. Zu guter Letzt muss jetzt ein Threshold bestimmt werden. In polyphonen Musikstücken können immer mehrere Noten gleichzeitig erklingen, weshalb man nicht einfach die Note mit der höchsten Wahrscheinlichkeit auswählen kann. Deshalb nutzt man einen Threshold, zum Beispiel bei 50%, welcher bestimmt wie viel Prozent eine Note braucht um als aktiv zu gelten. Durch Postprocessing können einige Eigenschaften wie Rauschen noch herausgefiltert werden. Postprocessing ist jedoch nicht relevant für den KI-Ablauf. Wenn man zufrieden mit dem Ergebnis ist, kann man dieses jetzt in das gewünschte Output-Format, standardmäßig MIDI-Dateien, einfügen.

Heutzutage sind RNNs nur die grundlegende Struktur. Basierend auf dieser gibt es einige verbesserte Systeme, welche Aktiv in AMT-Systemen und anderen KI-Systemen genutzt werden. Zwei dieser Systeme sind Long Short-Term Memory's (LSTM) und Bidirektionale RNNs (BiRNN). Diese werden im jetzt folgendem Abschnitt ausführlicher erklärt.

4.2.2 Long Short-Term Memory

LSTMs sind verbesserte RNNs. Diese kontrollieren durch Gates besser, welche Daten sie wirklich in den Hidden State speichern möchten. Dadurch kann man das neuronale Netz noch weiter an seine gewünschten Ansprüche anpassen. Ein normales RNN berechnet einen Hidden State mit folgender Formel:

$$h_t = \tanh(Wx_t + Uh_{t-1} + b)$$

Dabei werden alle Daten, egal ob sinnvoll oder nicht, miteinander kombiniert. Somit kann sich das RNN langfristig schwieriger Information merken. Wenn zum Beispiel im Hidden State ein Onset erkannt wurde, kann der Hidden State sich das schlechter merken, da ganz viele andere Informationen mitgeschrieben wurden. LSTMs lösen dieses Problem mit Forget, Input und Output Gates und dem Cell State. Der Cell State stellt das Langzeitgedächtnis des LSTMs dar. Er berechnet sich aus den 3 Gates. Das Forget Gate bestimmt, welche Informationen aus dem vorherigen Cell State gelöscht werden sollen. Das Input Gate bestimmt, welche neuen Inhalte aus dem neuen Zeitfenster aufgenommen werden. Dabei ist der Cell-candidate die Datenmenge, welche zum Speichern, durch das Input Gate, vorgeschlagen wird. Das Output Gate bestimmt, welcher Teil des Cell States zu dem neuen Hidden State hinzugefügt wird.

$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$	(Forget Gate)
$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i)$	(Input Gate)
$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o)$	(Output Gate)
$\tilde{c}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$	(Cell-candidate)
$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$	(Cellstate)
$h_t = o_t \odot \tanh(c_t)$	(Aktueller Hidden State)

Dadurch kann sich ein LSTM die verschiedenen musikalischen Ereignisse, über das gesamte Audiosignal, besser im Zusammenhang merken.

Folgende Abbildung zeigt einen Zeitschritt in einem LSTM. Dabei sind die Komponenten gleich benannt wie in der Abbildung-(Entfaltung eines RNN-Blocks). Das „c“ steht für den Cell-State. Intern in der „LSTM Unit“ stehen die Buchstaben „F, I und O“ für die Gates: „Forget Gate, Input Gate und Output Gate“.




Abbildung 8: Zeitschritt eines LSTMs [Wikimedia Commons contributors 2016].

4.2.3 Gated Recurrent Units

GRUs sind, neben LSTMs, eine weitere spezielle Art von RNNs [Chung u. a. 2014]. Sie wurden erfunden, um bestimmte Probleme von RNNs zu lösen. Insbesondere das Problem des „Vanishing Gradients“ sollten GRUs lösen. GRUs steuern mithilfe von Gates, welche Informationen gemerkt und welche vergessen werden sollen. Sie sind, im Gegensatz zu LSTMs, eher für kleinere Aufgaben geeignet. Dafür sind sie weniger fehleranfällig und haben ein schnelleres Training.

Ein GRU besitzt zwei Gates. Sie haben, genau wie bei LSTMs, die Aufgabe das Gedächtnis des KI-Modells zu verwalten. Das Reset Gate schaut sich den alten Hidden State an und entscheidet, wie viel von diesem Wissen in den neuen Hidden State mit einfließt. Das Update Gate hingegen sieht den aktuellen Hidden State und überlegt, welche Informationen davon in das Langzeitgedächtnis mit einbezogen werden. Danach führt das Update Gate die beiden überarbeiteten Hidden States zusammen zum neuen Hidden State.

Das Problem des Vanishing Gradients bezieht sich auf das Gedächtnis des KI-Modells. Das Problem tritt in den Trainingsphasen von neuronalen Netzen auf. Die Gradienten werden bei der Backpropagation immer kleiner, wodurch die betroffenen Schichten im Netzwerk fast gar nichts lernen. Die Gradienten werden kleiner, da eine Aktivierungsfunktion immer einen Wert zwischen 0 und 1 zurückgibt. Ein Gradient wird mit der Ableitung der Aktivierungsfunktion multipliziert, wodurch er gleichzeitig kleiner wird. Desto tiefer das Netzwerk ist, desto mehr Schichten müssen die Gradienten durchlaufen. Mit jeder Schicht wird der Gradient somit exponentiell kleiner. Die führt dazu, dass das betroffene KI-Modell sich keine Informationen Langzeitig merken kann. Bei GRUs wird das Problem des Vanishing Gradients durch die Gates gelöst. Sie stellen eine gewichtete Mischung aus altem und neuen Hidden State dar. Dadurch wird der Gradient nicht ständig verkleinert und wichtige Informationen können über einen langen Zeitraum gespeichert werden.

Folgende Abbildung zeigt einen Zeitschritt in einem GRU. Die Komponenten sind gleich benannt wie in der Abbildung-(Entfaltung eines RNN-Blocks). Intern in der „GRU Unit“ stehen die Buchstaben „R und Z“ für die Gates: „Reset Gate und Update Gate“.




Abbildung 9: Zeitschritt eines GRUs [Wikimedia Commons contributors 2016].

4.2.4 Bidirektionale RNNs

Um ein noch besseres Ergebnis zu erhalten, kann man auch ein Bidirektionales RNN nutzen. Dieses besteht aus zwei RNNs. Eines liest die Zeitfenster von vorne und das andere von hinten ab. Dadurch bekommt man die doppelte Menge Hidden States und die gesamte Vorhersage wird sehr viel robuster.

$$\mathbf{h}_t = \left[\vec{\mathbf{h}}_t ; \overleftarrow{\mathbf{h}}_t \right]$$

Auch in AMT-Systemen sind Bidirektionale RNNs sehr hilfreich, da musikalische Ereignisse auch eine klar verständliche Abhängigkeit, von der Zukunft in die Vergangenheit aus, haben. Das gleiche Prinzip kann man auch auf LSTMs oder GRUs einsetzen. Bidirektionale RNNs sind noch robuster, aber dafür ist der Rechenaufwand bei weitem höher. Ein Bidirektionales RNN kann man auch in folgender Arbeit finden [Hawthorne u. a. 2017].

4.2.5 Geschichtliche Einordnung von RNNs

Die Geschichte von Recurrent neural networks reicht bis in das Jahr 1990 zurück [Elman 1990]. In dieser Arbeit wurde erstmals die Idee der Rückkopplung eingebaut, wodurch der Output eines Neurons als zusätzliche Eingabe im nächsten Zeitfenster genutzt wird. Das resultierte später in den Hidden States. Diese Arbeit baute den Grundstein für alle weiterführenden RNNs. Eine weitere wichtige Arbeit über RNNs ist die folgende [Jordan 1997]. Diese Arbeit über RNNs wurde, offiziell im Jahre 1997, publiziert, obwohl sie schon 1986 als ein technischer Bericht veröffentlicht war. Zudem wurde, im Jahre 1997, das erste Bidirektionale RNN [Schuster und Paliwal 1997] und das erste LSTM erfunden [Hochreiter und Schmidhuber 1997]. Erst über ein Jahrzehnt später wurde das erste GRU entwickelt [Chung u. a. 2014]. RNNs fanden ihren Weg in die automatische Musiktranskription, fast zeitgleich zu CNNs, im Jahre 2015 [Sigitia, Benetos, Boulanger-Lewandowski u. a. 2015]. Für LSTMs dauerte die Einbindung in AMT-Systeme etwas länger. Erst im Jahre 2016 wurde ein LSTM in einem AMT-System eingefügt [Sigitia, Benetos und Dixon 2016]. Dahingegen wurde das erste Bidirektionale RNN erst Ende 2017 in ein AMT-System integriert [Hawthorne u. a. 2017]. Noch ein Jahr später wurde das erste Mal auch ein GRU in einem AMT-System genutzt [Jung, H. Lee und Tani 2018].

4.3 Transformers

Transformer sind eine, von Google entwickelte Deep-Learning Architektur, die mit dem Prinzip der Self-Attention, zur natürlichen Sprachverarbeitung (NLP) genutzt wird. Auch Transformer verarbeiten die Daten, wie ein LSTM, sequentiell. Jedoch wurde zu dieser Verarbeitung noch der Attention-mechanismus hinzugefügt, welcher der grundlegende Baustein eines Transformer-Modells ist. Die

Architektur eines Transformers besteht grundlegend aus 3 Bausteinen. Diese 3 sind Input Embedding + Position Encoding, der Self-Attention Layer und der Feedforward Layer. Input Embedding und Position Encoding nur einmalig am anfang des Transformers durchgeführt. Dahingegen werden Self-Attention und Feedforward mehrmals hintereinander aufgerufen. Dies passiert grundsätzlich 6-, 12- oder 24-mal, wodurch das Transformer-Modell an Layer gewinnt. Dieser Schritt wird so oft wiederholt, damit der Transformer immer komplexere musikalische Strukturen erkennen kann. Als Nächstes werden die einzelnen Schritte eines Transformers näher erläutert.

4.3.1 Input Embedding und Position Encoding

Zunächst müssen die Daten, welche der Transformer verarbeiten soll in das richtige Format für diesen umgewandelt werden. Dafür ist das Input Embedding zuständig. Tokens sind einzelne Datenpunkte wie zum Beispiel kleine Wörter wie „hallo“. Wenn man zum Beispiel bei ChatGPT die Anfrage stellt, „Wie alt sind die Planeten unseres Sonnensystems“, dann wird zwar das Wort „alt“ als ein Token gespeichert, aber längere Wörter wie „Sonnensystem“ werden aufgeteilt in „Sonn“ und „ensystem“. Je nach Tokenizer-Version, die der jeweilige Transformer nutzt, kann dies jedoch abweichen. Unser Beispielsatz nutzt, alleine für die Wörter, 9 Tokens. Tokens können auch einzelne Satzzeichen oder Symbole sein. Für verschiedene Transformer Modelle gibt es immer eine maximale Tokenanzahl, bei GPT-3.5 sind es um Beispiel ungefähr 4000 Tokens. Diese Tokens sind für den Input und Output. Heißt, wenn der Input zu viele Tokens nutzt, gibt es weniger Tokens für den Output. Dies ist jedoch häufig, wie man an der Menge der Tokens für unseren Beispielsatz sehen kann, kein größeres Problem. In AMT-Systemen stellen Tokens Zeitfenster (Frames) oder Musik-Events (Onsets etc.) dar. Jedoch können diese von einem Transformer nicht verarbeitet werden, weshalb sie durch Input Embedding erstmals in Vektoren umgewandelt werden. Dies passiert über eine Embedding-Matrix, welche die einzelnen Tokens in den Vektorraum einbettet.

$$\text{Embedding} - \text{Matrix} \in \mathbb{R}^{\text{MaximaleTokenanzahl} \times \text{Embedding-Dimension}}$$

Tokens, welche ähnliche musikalische Eigenschaften speichern, werden im Vektorraum näher beieinander gespeichert. Das Modell kann die Tokens richtig einordnen durch die gesammelten Daten im Training.

Nun sieht der Transformer die Tokens trotzdem nur als zahlreiche Vektoren, ohne Reihenfolge, an. Um den Tokens einen Sinn zu geben, müssen diese eine explizite Position erhalten. Das wird durch Position Encoding gemacht. Durch zwei Funktionen, eine Sinus und eine Cosinus, wird für jeden Token ein Positionsvektor berechnet. Dadurch kann der Transformer die relative Position, verschiedener Tokens, gut miteinander vergleichen und zugleich wiederkehrende Muster erkennen. Danach wird der Positionsvektor dem Tokenvektor aufaddiert. Moderne Transformer besitzen manchmal auch gelernte Position Embeddings, wodurch die Positionen schon durch das Training bekannt sind. Diese Vektoren werden, als Input, weiter an den Transformer geleitet.

4.3.2 Self-Attention Layer

Jeder Input-Vektor wird einzeln behandelt. Durch Self-Attention kann sich jetzt jeder Vektor merken, welche anderen Vektoren für sich selber relevant sind. Zunächst wird jeder Input-Vektor in 3 verschiedene Vektoren umgewandelt. Diese Vektoren heißen Query, Key und Value.

- **Query (Q):** Bestimmt, auf welche Informationen aus anderen Tokens das Modell aktuell achten möchte.
- **Key (K):** Zeigt anderen Tokens, was dieser Input-Vektor anderen Tokens, für Informationen, anbieten kann.
- **Value (V):** Enthält die tatsächlichen Informationen des Input-Vektors.

Als Nächstes wird der Attention Score berechnet. Durch diesen wird die Kompatibilität zu anderen Tokens berechnet. Als Ergebnis bekommt man, für jeden Token, eine Matrix. Jeder Wert in dieser

Matrix steht für die Ähnlichkeit zwischen zwei verschiedenen Tokens. Diese Werte sind die Attention Weights. Durch Softmax werden diese Werte normalisiert. Als Letztes werden diese Attention Weights mit den Value-Vektoren verbunden.

$$\text{Output} = \text{Attention Weights} \times \text{Value Vektoren}$$

Nun können die einzelnen Tokens sich besser auf die Tokens fokussieren, welche wirklich wichtig für deren Ergebnis sind.

4.3.3 Feedforward Layer

Der Feedforward Layer stammt von der Idee eines Feedforward neuronalen Netzwerks (FNN). Dieses neuronale Netz verläuft immer nur in eine Richtung und hat keine Rückkopplung. Das heißt jeder Token wird für sich alleine, nacheinander, umgeschrieben. Das funktioniert so, da die jeweilige Gewichtung schon im Self-Attention Layer stattgefunden hat. Im Feedforward Layer passiert dann folgendes. Zunächst werden die Vektoren, welche aus dem Self-Attention Layer stammen, mit einer Gewichtsmatrix auf eine höhere Dimension transformiert. Durch die Erhöhung der Dimension bekommt das Netzwerk mehr Freiraum Informationen voneinander zu trennen und komplexere Zusammenhänge zu modellieren. Durch eine Aktivierungsfunktion, zum Beispiel ReLU, erlernt das Modell jetzt nichtlineare Abhängigkeiten. Diese Aktivierungsfunktion gehört zu dem Hidden Layer des FNN. Ein FNN kann mehrere Hidden Layer besitzen, welche alle die Input-Werte in irgendeiner Form verändern. Als Nächstes wird der Vektor wieder auf seine ursprüngliche Dimension zurückprojiziert, wodurch nur die wichtigsten Informationen erhalten bleiben. Mathematisch sieht der Feedforward Layer folgendermaßen aus:

$$y_t = \text{FFN}(x_t) = (x_t W_1 + b_1) \xrightarrow{\text{ReLU}} W_2 + b_2$$

- x_t : Eingabevektor des Tokens.
- W_1, W_2 : Gewichtsmatrizen, zuständig für Dimensionserweiterung und -reduktion.
- b_1, b_2 : Bias-Vektoren der jeweiligen linearen Projektionen.
- $(x_t W_1 + b_1)$: Ergebnis der ersten linearen Projektion.
- ReLU: Aktivierungsfunktion zur Einführung von Nichtlinearität.
- y_t : Ausgabewert des Feedforward Layers für das Token.

4.3.4 Geschichtliche Einordnung von Transformern

Das erste Transformer-Modell wurde im Jahre 2017 erfunden [Vaswani u. a. 2017]. Durch den Self-Attention Layer wurde die sequenzielle Modellierung von Daten revolutioniert. Leider dauerte es noch lange bis der erste Transformer auch in AMT-Systemen genutzt wurde. Das liegt an mehreren Gründen. Einerseits gibt es im Gegensatz zu Natural Language Processing (NLP) viel weniger Datensätze zum Lernen. Transformer trainieren auf einem globalen Level und brauchen daher eine große Menge an Datensätzen. Die Rechenkosten von Transformer sind auch weitaus höher als andere Systeme wie CNN und RNN. Zudem lag der Fokus bei AMT-Systemen für eine sehr lange Zeit überwiegend bei CNN und RNN basierenden Systemen, da diese Anwendungsfälle bekannter waren in AMT-Systemen. Das größte Problem war jedoch wahrscheinlich die Anpassung. Transformer Modelle waren einfach nicht dafür ausgelegt musikspezifische Daten zu verarbeiten. In der Musiktranskription wird immer mit langen Sequenzen, ein gesamtes Musikstück, gearbeitet. Spezielle Transformer Modelle für diesen Anwendungsfall mussten noch programmiert werden. Die ersten Ansätze für Transformer in AMT-Systemen wurden zwischen den Jahren 2021 und 2023 erstellt. Eine der ausschlaggebendsten Modelle war der Music Transcription Transformer MT3, welcher von Magenta/Google Brain erstmals im Jahre 2022 veröffentlicht wurde [Gardner u. a. 2021]. Dieses spielt eine große Rolle in der Transformer-basierten automatischen Musiktranskription, da es das erste weit verbreitete Multi-Task-Transkriptionsmodell ist. Eine der Letzten bedeutenden Errungenschaften zu

Transformern und Musiktranskription ist das YourMT3+ Modell, indem die MT3-Architektur noch weiter verbessert wurde [chang2024yourmt3].

4.4 Potentielle KI-Modelle

CNNs und RNNs oder Transformer Modelle wie MT3 werden überwiegend in AMT-Systemen eingebunden, wenn es sich um KI integration handelt. Jedoch gibt es noch andere KI-Modelle, die auch ab und zu in AMT-Systemen integriert werden. Diese gehen, bei der Musiktranskription, ganz anders vor als die vorgestellten Module. Je nach KI übernehmen sie auch eine ganz andere Aufgabe. Im folgenden Abschnitt werden einige von diesen, eher experimentellen, KIs vorgestellt. Wir fangen dabei bei der am meisten erprobten KI an, sodass die letzte KIs nur theoretisch, für die Musiktranskription, besprochen werden.

Variational Autoencoder

Variational Autoencoder (VAE) ist ein KI-Modell, welches komplexe Daten in eine verdichtete Form überführt und durch Wahrscheinlichkeiten bestimmte Muster vorhersagen kann [Kingma, Welling u. a. 2019]. Dabei ist wichtig das VAE kein alleinstehendes KI-Modell ist, sondern eher als zusatz gilt um bestimmte Bereiche zu verbessern. In der Musiktranskription könnte ein VAE zum Beispiel bei der Mehrdeutigkeit von Musik helfen. Wenn mehrere Instrumente spielen ist es schwer die genauen Noten herauszuschreiben. Da VAEs, anders als CNNs oder RNNs, als ausgabe keine eindeutigen Noten herausgeben, sondern eine Wahrscheinlichkeit, könnte dies helfen die entscheidung, welche Note gerade spielt, robuster zu gestalten. Dadurch das sich VAEs nur eine wahrscheinliche Version der Musik, aus den Daten, extrahieren könnte man auch kreative Variationen des Musikstückes damit bilden. Die Methode, welche in VAEs genutzt wird, fand Ihren Ursprung in folgendem Paper [Kingma, Welling u. a. 2013].

Graph Neural Network

Graph Neural Network (GNN) ist ein KI-Modell, welches dazu dient Daten, mit abhängigkeit von-einander, zu verarbeiten. Diese Daten werden in einem Graphen aus Knoten und Kanten gespeichert. Dabei hat jeder Knoten seine eigenen Daten, die er in jedem Rechenschritt mit seinen benachbarten Knoten austauscht. Knoten sind benachbart, wenn sie durch Kanten verbunden sind. Dadurch wird jeder Knoten im Netzwerk schlauer. Natürlich machen RNNs und Transformer etwas Ähnliches wie ein GNN, mit zum Beispiel Backpropagation. Der Unterschied ist hier, das GNNs keine bestimmte Reihenfolge, wie Wissen weitergeleitet wird, haben. Es ist ein anderer Ansatz harmonische Abhängigkeiten miteinander zu kombinieren [Z. Wu u. a. 2020].

Diffusion Model

Diffusion Models arbeiten mit Rauschen. Aus komplettem rauschen bauen sie Schritt für Schritt ein sauberes Musikstück zusammen. Dabei entscheiden sie pro Rechenschritt nur einen kleinen Teil des Musikstückes, wodurch mehrdeutige Passagen in Musikstücken auch noch später im Transkriptionsprozess behandelt werden können. In dem Projekt DiffRoll, aus dem Jahre 2022, wurde ein Diffusion Model auf ein AMT-System angewendet [K. W. Cheuk u. a. 2023].

Reinforcement Learning

Reinforcement Learning (RL) benutzen ein Belohnungssystem, damit der Agent sich beim training richtig anpasst. Sobald der Agent ein bestimmtes Ziel erreicht oder eine Handlung ausführt, wird dieser dafür belohnt. Die Agenten, welche am meisten Belohnungen erzielen werden kopiert und in der nächsten iteration eingesetzt, bis man einen Agenten besitzt, welche die gewünschte Aufgabe erfüllt. Dieses Prinzip wird vor allem in Videospielen, wo es grundlegend eindeutige Ziele gibt, eingesetzt. In der Musiktranskription könnte man dieses Prinzip folgendermaßen umsetzen. Man gibt dem Agenten als Input eine Audiodatei. Danach lässt man ihm Noten nacheinander erzeugen. Durch eine andere

KI oder vorgefertigte MIDI-Dateien besitzt man einen Vergleichsdatensatz. Falls die gewählten Noten vom Agenten gleich dem Vergleichsdatensatz sind, bekommt der Agent Belohnungen. So kann er sich selber Musikalisches wissen aneignen und Transkriptionen von anderen KIs nochmal korrekturlesen [Li u. a. 2018].

Energy-Based Model

Der letzte Ansatz ist ein Energy-Based Model (EBM). Ein EBM arbeitet mit Energie anstatt von Wahrscheinlichkeiten [LeCun, Chopra u. a. 2006]. Die verschiedenen Arten, wie das EBM das Musikstück transkribieren kann haben alle jeweils ihre eigene Energie. Dabei haben die besten Möglichkeiten immer die niedrigste Energie, wie bei dem Gradientenabstiegsverfahren. Dies ist für AMT-Systeme interessant, da das EBM somit zahlreiche verschiedene Transkriptionsraten wählen könnte. In mehr improvisierten Musikrichtungen, wie Jazz, bildet das eine größere Vielfalt. Man kann auch Musiktheorie in das Modell mit einbauen, wodurch aus einem Musikstück unendlich an Remixen kreiert werden können. Der Ansatz von EBMs in AMT-Systemen ist, von den zusätzlich vorgestellten KI-Modellen, wahrscheinlich einer der interessantesten. Leider sind EBMs sowohl schwer zu trainieren, als auch sehr rechenintensiv. AMT-Systeme ohnehin schon recht anspruchsvoll, weshalb noch kein EBM-Modell in der automatischen Musiktranskription zum Einsatz kam.

5 KI-basierende AMT-Systeme im Vergleich

Im Laufe der Forschung zu AMT-Systemen wurden schon einige verschiedenen Architekturen eingesetzt und verbessert. Jedes neue System hat, unabhängig des KI-Modells, eine komplett eigene Struktur und vorgehensweise. Im Verlauf dieser wissenschaftlichen Arbeit wurde die Geschichte von AMT-Systemen behandelt und die wichtigsten Konzepte der automatischen Musiktranskription dargestellt. Deshalb wird sich jetzt dieses Letzte große Kapitel um die state of the art AMT-Systeme handeln. Dafür werden zwei verschiedene AMT-Systeme vor. Diese sind das CNN + GRU basierte Omnizart und das Transformer-basierte MT3-Modell. Diese nutzen unterschiedliche KI-Modelle. Deren Architektur, sowie deren Stärken und Schwächen, werden in dem folgenden Kapiteln ausgiebig erläutert.

5.1 Omnizart

Zum einen haben wir Omnizart, welches CNNs und RNNs als KI-Modelle nutzt [Y.-T. Wu u. a. 2021]. Der Name Omnizart setzt sich aus den Wörtern Omni (alles) und Mozart zusammen, da ihr Ziel darin liegt, so viele Arten von Musik wie möglich zu transkribieren. Je nach Anwendungsfall werden verschiedene KIs benutzt. Dabei ist der Aufbau dieser KIs meistens gleich. Alle KI-Modelle bestehen aus einem CNN und einem bidirektionalen GRU. Der Anwendungsfall, zum Beispiel Drums oder Melody, hat dabei nur Einfluss auf die Trainingsdaten und dem Output. Omnizart ist ein Open-Source-Toolkit für AMT. Dadurch kann man, je nach Bedarf, ein KI-Modell auswählen was perfekt auf eine bestimmte Aufgabe ausgelegt wurde. Omnizart findet ihren Ursprung im Jahre 2020 am Music and Culture Technology Lab, National Taiwan University. Omnizart hat seit seiner Gründung keine ausschlaggebenden weiteren Technologien, in der Richtung KI, hinzugefügt. Dafür gibt es für jeden vertretenen Anwendungsfall verschiedene CNNs und RNNs und einen open source code, welchen man gut zur eigenen Forschung an AMT-Systemen nutzen kann.

Omnizart ist ein modulares AMT-System, welches auf einer Deep-Learning-Architektur basiert. Der Trainingssatz besteht aus CQT-Spektren. Die KI-Modelle lernen dabei durch Supervised Learning.

Die Pipeline von Omnizart kann man in drei Schritte aufteilen:

Der erste Schritt ist die Vorverarbeitung und Merkmalsextraktion (Preprocessing). Dadurch wird die Inputaudiodatei in ein CQT-Spektrogramm umgewandelt. Zunächst wird das gegebene Audiosignal durch folgende Methoden standardisiert:




Abbildung 10: Eigene Darstellung der Omnizart Pipeline

1. **Mono-Konvertierung:** Die KI benötigt keine räumlichen Informationen, weshalb der linke und rechte Kanal von Stereosignalen in ein Monosignal addiert werden.
2. **Normalisierung:** Der Wechsel von zu großen und kleinen Amplituden kann die KI überfordern und ungenaue Ergebnisse liefern, weshalb das Audiosignal durch Normalisierung auf einen einheitlichen Lautstärkebereich gebracht wird.
3. **Resampling:** Unterschiedliche Abtastraten führen zu Verzerrung und Frequenzverschiebung, deshalb wird diese auf eine einheitliche Rate, passend zu dem genutzten Modul, gebracht.
4. **Trimming:** Falls am Anfang oder Ende des Audiosignals Stille ist, wird diese durch Trimming entfernt, sodass das KI-Modell nicht unnötig verwirrt wird.

Danach wird das standardisierte Audiosignal umgeformt zu einem CQT-Spektrogramm.

Im zweiten Schritt werden die KI-Modelle genutzt, um die Merkmale des Audiosignals vorherzusagen und zu extrahieren. Die meisten AMT-Systeme, welche im Laufe dieser Arbeit vermerkt wurden, besitzen eine ähnliche Architektur wie Omnizart [Hawthorne u. a. 2017]. Der Unterschied zu diesen AMT-Systemen ist das Omnizart, je nach Anwendungsfall, verschiedene Module nutzt. Omnizarts Module sind:

- **Chord:** Akkorderkennung
- **Drum:** Drum-Transkription
- **Melody:** Melodietranskription
- **Vocal:** Gesangsmelodietranskription
- **Piano:** Polyphone Klaviertranskription
- **Multi-Pitch:** Mehrstimmige Tonhöschätzung
- **Beat/Downbeat/Chord-Labeling:** Rhythmus, Takt & Akkorde

Jedes Modul bekommt als Input ein CQT-Spektrogramm. Dieses wird durch ein CNN verarbeitet, welches die Eigenschaften und Merkmale der Musik extrahiert. Mit diesen Daten modelliert dann ein GRU die zeitliche Abhängigkeit. Durch den Dense Layer werden die Ergebnisse des GRUs in zum Beispiel Onsets, Beats und zahlreiche weitere musikalischen Attribute, umgewandelt.

Im dritten Schritt wird der Output der KI-Modelle nochmals aufbereitet. Fehler werden zunächst durch folgende Methoden verbessert:

1. **Noten-Segmentierung:** Wenn derselbe Ton in zwei nacheinander folgenden Frame ein Onset hat, wird der zweite Onset gelöscht und der Note hinzugefügt, sodass keine Notendopplungen entstehen.

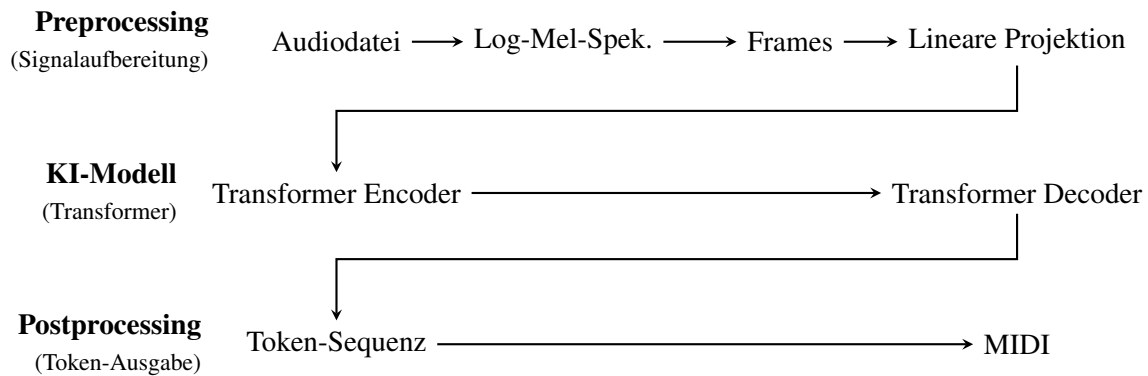


Abbildung 11: Eigene Darstellung der MT3 Pipeline

2. **Onset-Korrektur:** Falls ein Onset zeitlich nicht zur richtigen Zeit erfasst wurde, wird der Einschwingzeitpunkt des Onset an seinen Frame genau angepasst.
3. **Thresholding:** Noten, die nicht einen bestimmten Wahrscheinlichkeits-Threshold überschreiten, werden aussortiert.
4. **Quantisierung:** Je nach Taktstruktur können Noten zeitliche angepasst werden, sodass diese besser in zum Beispiel einen 3/4-Takt passen und das Stück rhythmischer ist.

Je nach Modul, welches man gerade nutzt, werden nur paar oder alle dieser Methoden eingesetzt. Auch deren Parameter unterscheiden sich je nach Modul. So hat das Drums-Modul ein viel kleineren Schwellwert als das Melodien-Modul bei Thresholding. Danach werden die Vorhersagen in vollständige Noten (Onset/Sustain/etc.) zusammengefasst und in das gewünschte Format übertragen. MIDI ist dabei das wichtigste Format, da dieses relevant für Musiksoftware ist, es gibt aber auch noch drei andere Formate die, je nach Modul, ausgegeben werden. Fast immer wird auch eine CSV-Datei ausgegeben. Darin befinden sich die Transkriptionsdaten, welche zur Analyse oder Forschung genutzt werden können. JSON-Dateien werden in den Chord- und Beat-Modulen ausgegeben. Dies liegt daran, dass JSON-Dateien verschachtelte Daten, wie Akkordfolgen über mehrere Takte, besser speichern können. In ihnen werden vor allem Takt-Informationen und Daten für Akkorde gespeichert. TXT-Dateien werden dahingegen nur wahlweise in Modulen genutzt. Sie sind ausschließlich für Debugging da, weshalb sie für die meisten Nutzer nicht relevant sind. Die Daten werden, in einer TXT-Datei, in einer unstrukturierten Liste ausgegeben.

5.2 MT3

Das Transformer-Modell, welches jetzt näher erläutert wird, heißt MT3. MT3 steht für „Multi-Task Multitrack Music Transcription“. MT3 ist gleichzeitig der Name für das Transformer-basierte KI-Modell, als auch für das überliegende AMT-System. Diese beiden sind untrennbar voneinander, da sie zu einer End-to-End-Architektur gehören. Das MT3-Modell bildet einen wichtigen Meilenstein für die Transformer-basierte automatische Musiktranskription. MT3 ist das erste weit verbreitete Multi-Task-Transkriptionsmodell, das heißt verschiedene Transkriptionsaufgaben werden von einem einzigen Modell gelöst. Frühere Modelle brauchten zum Beispiel für Drums und die Melody, wie es bei Omnizart der Fall ist, verschiedene KI-Modelle. Durch die Communityversion YourMT3+ wird dieses KI-Modell immer weiter gepflegt und verbessert.

MT3 ist ein Transformer-Modell, welches spezifisch für Musiktranskription entwickelt wurde. Es besteht grundlegend aus folgenden Bereichen:

Als Input wird eine Audiodatei bereitgestellt. Meistens geht man mit dem Datentyp WAV (Waveform Audio File Format), da dieser verlustfrei und standardisiert ist. Das Audiosignal wird dann mit STFT analysiert und als Spektrogramm ausgegeben. Mithilfe von Librosa wird aus diesem ein Log-

Mel-Spektrogramm erzeugt. Librosa ist ein Python Paket, welches wichtige Methoden für Musik und Audio analyse bereitstellt. Dieses Log-Mel-Spektrogramm wird nun in Frames aufgeteilt. In dem MT3-Modell sind diese Frames meist 32ms lang. jeder Frame besitzt N Mel-Frequenzbänder, welche die Dimensionsgröße dieses Frames bestimmen. Um jetzt für jeden Frame eine einheitliche Dimension zu bekommen, mit der die KI Arbeiten kann, wird lineare Projektion genutzt. Lineare Projektion ist ein Matrix-Multiplikator, welche ein Frame auf eine, für das KI-Modell, normalisierte Dimension bringt, zum Beispiel 512 oder 1024. Daraus entstehen Input Embeddings, mit denen die KI nun arbeiten kann.

Jetzt folgt der Encoder, welcher das normale Prinzip eines Transformers, mit Self-Attention Layer und Feedforward Layer, ausführt. In dem MT3-Modell werden, vor der ausführung der Layer, die Positionen der Frames durch Positional Embeddings festgelegt. In MT3 besteht der Encoder aus 6 vollständigen Transformer-Layern. Der Inhalt jedes Frames wird jetzt zusammenhängen mit allen anderen Frames gesetzt. Daraus resultieren Vektoren, welche kontextreiche Informationen des Musikstückes besitzen. Diese Vektoren werden weiter an den Decoder geleitet

Aus den gegebenen Vektoren extrahiert der Decoder die wichtigen Daten. Neben den Encoder Vektoren als Input bekommt dieser zudem autoregressive Tokens. Autoregressive Tokens sind bereits generierte Tokens, die im Training meist aus den echten Daten stammen (Teacher Forcing) und beim Einsatz vom Modell selbst generiert werden. Dadurch bekommt der Decoder mehr Kontext für die zu generierenden Tokens. Neben den normalen Tokens bekommen auch die autoregressiven Tokens Positional Embeddings aufaddiert. Bevor der Decoder nun durchläuft, kann man mithilfe von Task-Conditioning, einen Task-Token hinzufügen. Das MT3-Modell transkribiert immer polyphon, jedoch kann man durch den Task-Token trotzdem den Output auf einen bestimmten Task, wie zum Beispiel Klavierstücke oder Trommelnoten, auslegen. Durch vorheriges Lernen ist das MT3-Modell darauf ausgelegt, nach einem Task-Token die folgenden Tokens in einer bestimmten Art und Weise zu transkribieren. Der Ablauf des Decoders sieht folgendermaßen aus:

1. **Self-Attention:** verarbeitet den Kontext der autoregressiven Tokens
2. **Cross-Attention:** extrahiert relevante Informationen aus dem Encoder-Output
3. **Feedforward Layer:** verfeinert die Repräsentationen der Tokens lokal
4. **Lineare Layer:** wandelt den Vektor in ein konkretes Token um

Dabei besteht der Decoder, im MT3-Modell, auch aus 6 vollständigen Transformer-Layern. Jeder Token stellt einen Teil eines musikalischen Events dar. Diese heißen zum Beispiel „Note-On C4“ oder „Shift +10 ms“. Ein musikalisches Event wäre somit eine volle Note, mit Notennamen, Onset und Offset, Sustain und weiteren musikalischen Eigenschaften, die man auf einer Note anwenden kann. Als Output gibt der Decoder jeden einzelnen Token zurück.

Jetzt werden im Post-Processing die Tokens zu Sequenzen (musikalischen Events) zusammengesetzt. Durch einige weitere Tools werden die Noten zudem noch bereinigt und verbessert.

- **Zeitberechnung:** Die Shift-Tokens werden aufsummiert, sodass alle Noten zur richtigen Zeit abgespielt werden.
- **Noten validierung:** Jede Note wird darauf geprüft, ob sie ein On- und Offset besitzt.
- **Velocity Korrektur:** Manche Noten haben keine oder eine fehlerhafte Anschlagstärke, welche bei diesem Schritt im Nachhinein hinzugefügt oder überschrieben wird.
- **Fehlerbereinigung:** Unlogische Notenfolgen, wie zwei Shifts hintereinander, werden entfernt.

Am Ende werden die bereinigten Noten in einem standardisierten Musikformat, als MIDI-Datei, ausgegeben.

In der folgenden Darstellung ist der transkriptions Ablauf des MT3-Modells dargestellt. Für den Input wird ein Audiosignal angegeben, welches in ein Spektrogramm umgewandelt wird. Als nächstes

gewichtet der Encoder, mithilfe der Self-Attention Layer, die Tokens und transformiert dann diese, mithilfe des Feedforward Layer, um nicht-lineare Merkmale pro Token zu extrahieren. Daraufhin wandelt der Decoder, die vom Encoder gegebenen Vektoren, in einzelne Tokens mit musikalischen Merkmalen um. Im Output sieht man oben einen Ausschnitt einer MIDI-Datei mit zwei Noten und darunter diese dargestellt als Piano-Roll.

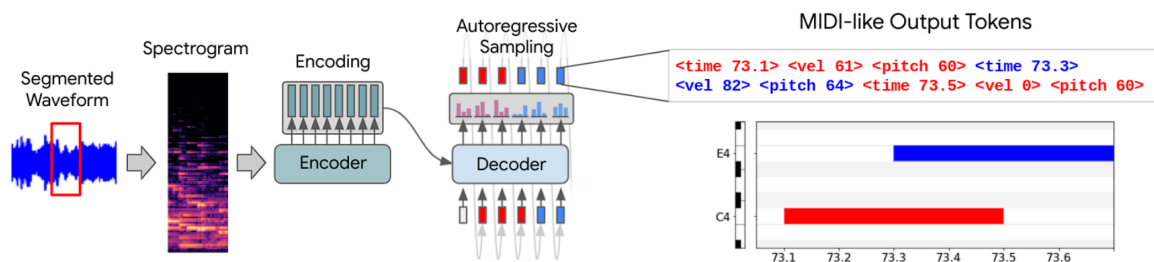


Abbildung 12: Verarbeitungspipeline des Transformer-basierenden MT3-Modells [Gardner u. a. 2022].

5.3 Omnizart vs MT3

Die beiden vorgestellten AMT-Systeme sind grundlegend verschieden aufgebaut. Jetzt ist die Frage, welche dieser beiden Systeme ist besser geeignet und unter welchen Voraussetzungen sollte man sich für welches System entscheiden.

Der größte Unterschied in der Architektur liegt darin, dass Omnizart verschiedenen KI-Modelle für unterschiedliche Aufgaben besitzt, während MT3 ein einziges leistungsstarkes KI-Modell besitzt. Somit kann man bei Omnizart leichter einen bestimmten Task verbessern oder analysieren. Das ist vor allem gut, wenn man sich auf monophone Musikstücke konzentriert und einen einfacheren Einstieg in die automatische Musiktranskription bekommen möchte. Zudem gibt Omnizart eine größere Menge an Outputdaten zurück als MT3, bei dem nur eine MIDI-Datei ausgegeben wird. MT3 hingegen besitzt ein einziges KI-Modell, wodurch man nicht gezielt einen speziellen Task umstrukturieren kann. Dafür eignet sich das KI-Modell direkt wissen der verschiedenen Tasks an und kombiniert dieses. Somit können polyphone Musikstücke deutlich besser transkribiert werden. Durch YourMT3+ gibt es zudem weiteres Ausbaupotential, dahingegen entwickelt sich Omnizart nicht sonderlich weiter.

Bei den KI-Modellen hat MT3 einen klaren Vorsprung. CNNs und GRUs sind schon seit längerem in AMT-Systemen vertreten. Sie wurden ausgiebig angepasst und verbessert für diesen Anwendungsfall. Hingegen zu diesen KI-Modellen ist das MT3 erst seit paar Jahren im Rennen. Durch YourMT3+ wird es immer weiter entwickelt, wodurch es in der nahen Zukunft zu einem Standard der automatischen Musiktranskription werden könnte. Zudem ist das MT3-Modell deutlich besser auf polyphone Musikstücke ausgelegt. In der Mehrheit von Audiosignalen gibt es mehrere Stimmen. Die meisten Menschen möchten auch lieber eine einfache Lösung, die wenig eigenaufwand benötigt. Deshalb wäre ein zentrales KI-Modell, zur Transkribierung von allen verschiedenen Audiosignalen, die populärste Lösung. Ein Schwachpunkt des MT3-Modells ist der Rechenaufwand. Da alles über ein KI-Modell läuft, muss dieses umso mehr Rechenschritte durchführen und braucht exponentiell mehr GPU auslastung und Speicherkapazität.

Omnizart ist empfehlenswert, falls man sich gerade mit dem Forschungsgebiet neu auseinandersetzt. Man sieht viel schneller Fortschritte und kann sich erstmals auf kleiner KI-Modelle konzentrieren. In den meisten anderen Fällen wäre jedoch das MT3-Modell, oder das Nachfolgermodell YourMT3+, empfohlen. Dieses ist der State of the Art und wird auch noch in einigen Jahren Support erhalten. Zudem ist man bei diesem Modell in keiner Weise eingeschränkt und kann jegliche Musik transkribieren. Dieses Modell geht jedoch auch mit viel Rechenaufwand und einem guten Verständnis des Forschungsgebiets einher. Deshalb sollte man sich, bevor man das MT3-Modell nutzt, gut damit auseinandergesetzt haben.

6 Fazit

Automatische Musiktranskription entwickelt sich stetig weiter. Besonders in den letzten Jahren hat dieses Forschungsgebiet erhebliche Fortschritte gemacht. Verantwortlich dafür ist vor allem die rasant Entwicklung Künstlicher Intelligenz. In nur wenigen Jahren wurden unzählige KI-Modelle entwickelt, die im Monatsrhythmus beachtliche Fortschritte zeigten. Fast jedes Problem, was vorher durch Algorithmen gelöst wurde, konnte durch ein schnelleres und besseres KI-Modell ersetzt werden. Dies gilt auch für Algorithmen und Architekturen in AMT-Systemen. CNNs und RNNs entwickelten sich in kürzester Zeit zum neuen Standard innerhalb der AMT-Forschung.

Dieses Phänomen ist jedoch erst der Anfang von Künstlicher Intelligenz und deren Anwendung in AMT-Systemen. So schnell wie CNNs und RNNs die automatische Musiktranskription beeinflusst haben, ebenso schnell etablieren sich bereits neue, verbesserte KI-Modelle. Mit dem Transformer-basierten KI-Modell MT3 wurde erneut ein neuer Stand der Technik erreicht, der die alten KI-Modelle ersetzen sollte. Es ist zu erwarten, dass sich dieser Zyklus noch vielfach wiederholen wird, da wir uns noch am Anfang der KI-Forschung befinden.

Trotz dieser großen Meilensteine gibt es in der automatischen Musiktranskription noch einige offene Probleme, welche gelöst werden müssen. Datensätze sind unzureichend, transkribierte Noten sind fehlerhaft oder unvollständig und rauschende Audioaufnahmen verwirren die KI-Modelle zu stark. KI-Modelle haben zahlreiche Probleme und Fehler beseitigt. Gleichzeitig öffneten sie neue Fehlerquellen, die zuvor nicht existierten. Ein Beispiel dafür ist das Blackbox-Verhalten moderner KI-Modelle. Dadurch wird unklarer, was an dem Datensatz oder direkt in dem KI-Modell verändert werden muss, um ein besseres Ergebnis zu erzielen.

Eine der größten Herausforderungen bleibt jedoch die Überführung in lesbare Notenblätter. Tatsächlich gibt es einige Tools und Firmen die diese Aufgabe mithilfe eines AMT-System schon versuchen zu lösen. Häufig sind die daraus resultierenden Notenblätter jedoch kaum brauchbar. Die Noten werden nicht den richtigen Stimmen zugeordnet und musikalische Regeln werden nicht beachtet. Das führt dazu, dass die Musiknoten nicht intuitiv spielbar sind. Eine Lösung dafür wäre zum Beispiel ein weiteres KI-Modell, das sich mithilfe einer MIDI-Datei systematisch damit auseinandersetzt, wie Musiknoten platziert werden müssen und wann Vorzeichen, Dynamikangaben sowie Artikulationszeichen gesetzt werden.

Im Ganzen ist die Einbindung von Künstlicher Intelligenz ein großer Fortschritt für die automatische Musiktranskription. In naher Zukunft werden AMT-Systeme kontinuierlich weiterentwickelt und in nicht allzu langer Zeit könnten diese auch im Alltag eingesetzt werden.

Literaturverzeichnis

- Baum, Leonard E u. a. (1970). „A maximization technique occurring in the statistical analysis of probabilistic functions of Markov chains“. In: *The annals of mathematical statistics* 41.1, S. 164–171.
- Böck, Sebastian und Markus Schedl (2012). „Polyphonic Piano Note Transcription with Recurrent Neural Networks“. In: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. Zugriff am 19.05.2025, S. 121–124. URL: https://www.cp.jku.at/people/schedl/Research/Publications/pdf/boeck_schedl_icassp_2012.pdf.
- Brown, Benjamin, Sheila G. Crewther und David P. Crewther (2016). „Pattern-onset and pattern-offset visual evoked potentials: normative data and clinical applications“. In: *Documenta Ophthalmologica* 133, S. 141–156. DOI: 10.1007/s10633-016-9554-y. URL: https://www.researchgate.net/figure/A-typical-pattern-onset-offset-VEP-Note-that-with-a-300-ms-sweep-only-the-pattern-onset_fig2_305480881.
- Cheuk, Kin Wai u. a. (Apr. 2023). „DiffRoll: Diffusion-based Generative Music Transcription with Unsupervised Pretraining Capability“. In: *ICASSP*. arXiv preprint arXiv:2210.05148, Oct 2022.
- Cheuk, Tom, Kai Shan und Chris Raphael (2020). „The Impact of Audio Input Representations on Neural Network Based Music Transcription“. In: *arXiv preprint arXiv:2001.09989*. URL: <https://arxiv.org/abs/2001.09989>.
- Chung, Junyoung u. a. (2014). „Empirical evaluation of gated recurrent neural networks on sequence modeling“. In: *arXiv preprint arXiv:1412.3555*.
- Dave, Smith und Wood Chet (Okt. 1981). „the 'usi', or universal synthesizer interface“. In: *journal of the audio engineering society* 1845.
- Elman, Jeffrey L (1990). „Finding structure in time“. In: *Cognitive science* 14.2, S. 179–211.
- Eyben, Florian u. a. (2010). „Universal onset detection with bidirectional long-short term memory neural networks“. In: .
- Fukushima, Kunihiko (1980). „Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position“. In: *Biological cybernetics* 36.4, S. 193–202.
- Gardner, Josh u. a. (2021). „MT3: Multi-task multitrack music transcription“. In: *arXiv preprint arXiv:2111.03017*.
- (2022). *Music Transcription with Transformers - MT3 Colab Notebook*. Zugriff am 27.07.2025. URL: https://colab.research.google.com/github/magenta/mt3/blob/main/mt3/colab/music_transcription_with_transformers.ipynb.
- Goswami, AP und Makarand Velankar (2013). „Study paper for Timbre identification in sound“. In: *International Journal of Engineering Research & Technology (IJERT)* 2.10.
- Graves, Alex, Santiago Fernández und Jürgen Schmidhuber (2007). „Multi-dimensional recurrent neural networks“. In: *International conference on artificial neural networks*. Springer, S. 549–558.
- Han, Yoonchang, Jaehun Kim und Kyogu Lee (2016). „Deep convolutional neural networks for pre-dominant instrument recognition in polyphonic music“. In: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 25.1, S. 208–221.
- Hawthorne, Curtis u. a. (2017). „Onsets and frames: Dual-objective piano transcription“. In: *arXiv preprint arXiv:1710.11153*.
- Heinemann, Ernst-Günter, Hrsg. (1992). *Das Wohltemperierte Klavier I, BWV 846–869. Nr. 5 in D-Dur. BWV 850*. München.
- Hochreiter, Sepp und Jürgen Schmidhuber (1997). „Long short-term memory“. In: *Neural computation* 9.8, S. 1735–1780.
- iZotope (n.d.). *What is the Noise Floor?* Zugriff am 19.05.2025. URL: <https://www.izotope.com/en/learn/what-is-the-noise-floor.html>.
- Jordan, Michael I (1997). „Serial order: A parallel distributed processing approach“. In: *Advances in psychology*. Bd. 121. Elsevier, S. 471–495.
- Joysingh, S, Johanan, P, Vijayalakshmi und T Nagarajan (2019). „Development of large annotated music datasets using HMM based forced Viterbi alignment“. In: *TENCON 2019-2019 IEEE Region 10 Conference (TENCON)*. IEEE, S. 1298–1302.

- Jung, Minju, Haanvid Lee und Jun Tani (2018). „Adaptive detrending to accelerate convolutional gated recurrent unit training for contextual video recognition“. In: *Neural Networks* 105, S. 356–370.
- Kingma, Diederik P, Max Welling u. a. (2013). *Auto-encoding variational bayes*.
– (2019). „An introduction to variational autoencoders“. In: *Foundations and Trends® in Machine Learning* 12.4, S. 307–392.
- Klapuri, Anssi und Antti Eronen (1998). „Automatic transcription of music“. In: *Proceedings of the Stockholm Music Acoustics Conference*, S. 6–9.
- LeCun, Yann, Bernhard Boser u. a. (1989). „Backpropagation applied to handwritten zip code recognition“. In: *Neural computation* 1.4, S. 541–551.
- LeCun, Yann, Sumit Chopra u. a. (2006). „A tutorial on energy-based learning“. In: *Predicting structured data* 1.0.
- Li, Juncheng u. a. (2018). „Music theory inspired policy gradient method for piano music transcription“. In: *Advances in Neural Information Processing Systems* 31.
- Mankowitz, Daniel J u. a. (2023). „Faster sorting algorithms discovered using deep reinforcement learning“. In: *Nature* 618.7964, S. 257–263.
- Martin, Keith D. (1996). *Automatic Transcription of Simple Polyphonic Music: Robust Front End Processing*. Techn. Ber. Technical Report 399. Zugriff am 19.05.2025. MIT Media Lab. URL: <https://www.media.mit.edu/publications/automatic-transcription-of-simple-polyphonic-music-robust-front-end-processing-2/>.
- Moorer, James A. (1977). „On the Transcription of Musical Sound by Computer“. In: *Computer Music Journal* 1.4. Zugriff am 19.05.2025, S. 32–38. URL: <https://www.jamminpower.org/PDF/JAM/Transcription%20of%20Musical%20Sound%20-%20CMJ%201977.pdf>.
- Scheirer, Eric D (1998). „Tempo and beat analysis of acoustic musical signals“. In: *The Journal of the Acoustical Society of America* 103.1, S. 588–601.
- Schuster, Mike und Kuldip K Paliwal (1997). „Bidirectional recurrent neural networks“. In: *IEEE transactions on Signal Processing* 45.11, S. 2673–2681.
- Shahriar, Nafiz (2020). *What is Convolutional Neural Network (CNN) — Deep Learning*. Zugriff am 27.07.2025. URL: <https://nafizshahriar.medium.com/what-is-convolutional-neural-network-cnn-deep-learning-b3921bdd82d5>.
- Sigtia, Siddharth, Emmanouil Benetos, Nicolas Boulanger-Lewandowski u. a. (2015). „A hybrid recurrent neural network for music transcription“. In: *2015 IEEE international conference on acoustics, speech and signal processing (ICASSP)*. IEEE, S. 2061–2065.
- Sigtia, Siddharth, Emmanouil Benetos und Simon Dixon (2016). „An end-to-end neural network for polyphonic piano music transcription“. In: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 24.5, S. 927–939.
- Takeda, Haruto u. a. (2002). „Hidden Markov model for automatic transcription of MIDI signals“. In: *2002 IEEE Workshop on Multimedia Signal Processing*. IEEE, S. 428–431.
- Telila, Yohannis, Tommaso Cucinotta und Davide Bacciu (2025). „Automatic music transcription using convolutional neural networks and constant-q transform“. In: *arXiv preprint arXiv:2505.04451*.
- Vaswani, Ashish u. a. (2017). „Attention is all you need“. In: *Advances in neural information processing systems* 30.
- Wikimedia Commons contributors (2016). *Recurrent neural network unfold.svg*. Zugriff am 27.07.2025. URL: https://commons.wikimedia.org/wiki/File:Recurrent_neural_network_unfold.svg.
- Wu, Yu-Te u. a. (2021). „Omnizart: A general toolbox for automatic music transcription“. In: *arXiv preprint arXiv:2106.00497*.
- Wu, Zonghan u. a. (2020). „A comprehensive survey on graph neural networks“. In: *IEEE transactions on neural networks and learning systems* 32.1, S. 4–24.