



WISSENSCHAFTLICHE VERTIEFUNG

Automatic Music Transcription

Autor:

Benedikt Kolodziej

878007

benedikt.kolodziej@study.hs-duesseldorf.de

Medieninformatik (B. Sc.)

Betreuender Professor:

Prof. Dr. Dennis Müller

dennis.mueller@hs-duesseldorf.de

Zeitraum

28.05.2025 - xy

Inhaltsverzeichnis

1	Einleitung	1
1.1	Automatic Music Transcription	1
1.2	Herausforderungen und Hindernisse	1
1.3	AMT und Künstliche Intelligenz,	1
1.4	praktische Anwendungsfelder und Vorteile von AMT	2
1.5	Motivation und Zielsetzung dieser Arbeit	3
2	Geschichtliche Entwicklung von AMT-Systemen	3
2.1	Moorer und eines der ersten Musiktranskriptionssysteme	3
2.1.1	Grundlegende Probleme bei AMTs	3
2.1.2	Der Aufbau von Moorers AMT-Systems	4
2.1.3	Hidden Markov Models	4
2.2	MIDI-Dateien	5
2.3	Entwicklung von Datensätzen	6
2.4	Polyphone AMT-Systeme und neue Ansätze	6
2.4.1	Blackboard-System	6
2.4.2	RASTA-basiertes System	8
2.5	Einbindung von Künstlicher Intelligenz	9
3	Hindernisse Moderner AMT-Systeme	10
3.1	Onset Detection	10
3.2	Polyphonie und Notenzuordnung	10
3.3	Instrument spezifische Probleme	10
3.4	Notendauer	11
3.5	Reale Audioaufnahmen	11
3.6	Frame-basierte vs Event-basierte AMT-Systeme	11
3.7	Blackbox von KI-Modellen	12
4	AMT-Systeme heutzutage	12
4.1	beliebte KI-Module	12
4.1.1	Convolutional Neural Networks	13
4.1.2	Recurrent Neural Networks	14
4.1.3	Long Short-Term Memory	15
4.1.4	Transformers	15
4.1.5	Weitere Deep-Learning-Module und Entwicklungen	15
4.2	KI-basierende AMT-Systeme im Vergleich	15
5	Fazit	15

Abbildungsverzeichnis

- 1 Systemstruktur des AMT-Ansatzes von Keith D. Martin (1996), basierend auf [**Martin1996**]. 7

1 Einleitung

1.1 Automatic Music Transcription

Musik ist seit Jahrtausenden ein zentraler Bestandteil unserer Gesellschaft. Während etwa 2000 bis 0 v.Chr. musikalische Werke meist mündlich überliefert wurden, entwickelte sich in diesem Zeitraum auch eine Notenschrift. Diese Notenschrift ermöglichte es, Musikstücke einfacher zu erlernen und einem breiteren Publikum zugänglich zu machen. Durch die Digitalisierung erhielten Digital Audio Workstations zunehmend Einzug in die Musikproduktion, wodurch Notenblätter oft nicht mehr notwendig waren und es weniger Bedarf gab diese Lieder zu übersetzen in Notenschrift.

An dieser Stelle setzt Automatic Music Transcription (AMT) an. AMT ist ein Prozess, bei dem eine Audiospur als Input gegeben wird und diese durch Computerprogramme Notenblätter oder, was weiter verbreitet ist, MIDI-Dateien als Output wiedergeben. Dabei werden durch mehrere Prozesse die Eigenschaften der Noten, zum Beispiel Frequenz oder Lautstärke, analysiert und im Kontext des Musikstückes analysiert.

1.2 Herausforderungen und Hindernisse

Anstatt das man selber diese Lieder, alleine durchs Gehör, in Notenschrift überträgt würde diese Aufgabe eine Software für einen erledigen. Dieses Ziel ist jedoch schwer zu erreichen, da Musik mehrdimensional ist durch zum Beispiel Zeit, Tonhöhe und Polyphonie. Vor allem bei polyphonen Musikstücken haben herkömmliche Algorithmen viele Schwierigkeiten. In diesen Fällen müssen sie nämlich viele verschiedene Stimmen gleichzeitig analysieren und im späteren auch die jeweiligen Töne voneinander differenzieren und eindeutig einem Instrument zuordnen. Ein weiteres Problem ist die Individualität jedes Musikstückes. In realen Aufnahmen können leichtes Rauschen, kleine Spielfehler oder stilistische Mittel wie Vibrato auftreten, die je nach Interpreten unterschiedlich klingen. Zudem sind die meisten AMT-Modelle auf westliche Tonleiter trainiert. Dies kann zu Problemen führen, wenn man zum Beispiel arabische oder indische Musikstücke transkribieren möchte.

1.3 AMT und Künstliche Intelligenz,

Um diese Vielfalt zu bewältigen, ist ein neuer, oft genutzter Ansatz, die Nutzung von künstlicher Intelligenz und Machine Learning.

Im Gegensatz zu Algorithmen ist KI flexibler und kann sich besser einstellen auf kleine Abweichungen in Musikstücken. Reale Audiospuren besitzen immer eine gewisse Menge Rauschen. Das kann bei der AMT für Schwierigkeiten sorgen, da Algorithmen diese als zusätzliche Noten ansehen oder richtige Noten dadurch nicht erkennen könnten. KIs können sich besser an diese Begebenheiten anpassen, da Neuronale Netzwerke mit genau diesen unperfekten Audiosignalen trainiert werden können. Somit können AMT-Systeme besser angepasst werden für einen realistischen Gebrauch.

Auch die Mehrdimensionalität von Musik kann KI deutlich besser bewältigen als Algorithmen. Neuronale Netze besitzen eine mehrdimensionale Struktur, die es ihnen ermöglicht, verschiedene Muster, Stimmen und Eigenschaften zu erlernen. [graves2007multi] Auf der anderen Seite müssen klassische Algorithmen diese verschiedenen Dimensionen explizit modellieren und sind nicht in der Lage, Muster selbstständig zu erkennen. Sie folgen nur dem, was zuvor vom Menschen fest einprogrammiert wurde.

Um ein AMT-Modell mit KI zu kreieren, muss man sich auch für ein KI-Modell entscheiden. Hier werden meistens Recurrent Neural Networks (RNN) oder Convolutional Neural Networks (CNN), als einzelne Module, benutzt. [Boeck2012] Diese Module bilden keine eigenständigen Systeme, sondern lassen sich flexibel innerhalb eines Systems kombinieren. Da es keine objektiv richtigen oder falschen Notenfolgen gibt, ist der Einsatz von Reinforcement Learning nicht sinnvoll. Dementsprechend braucht man auch ein zuverlässiges Datenset aus Audiodateien und deren zugehörigen MIDI-Dateien.

CNNs können gut räumliche Strukturen erkennen. Das hilft uns bei der Analyse von Spektrogrammen. Meist werden die verschiedenen Frequenzen der Noten, die gespielt wurden, nach der Verarbeitung des Musikstückes in Spektrogrammen wiedergegeben. Durch die Analyse von dem Spektrogramm können gewisse Frequenzmuster erkannt werden, die dann einem bestimmten Instrument zugeordnet werden können. Das ist vor allem hilfreich dabei verschiedene Stimmen der jeweiligen Instrumente voneinander zu differenzieren. [han2016deep]

RNNs hingegen sind spezialisiert, um zeitliche Abläufe besser im Kontext zu verstehen. In der Musik werden viele Noten hintereinander gespielt, diese müssen harmonisch im Stück übereinstimmen. Das RNN verarbeitet die jeweiligen Sequenzen und merkt sich die Informationen der schon gespielten Noten, um die darauffolgenden Noten besser einordnen zu können. So lassen sich Tonfolgen harmonischen Strukturen zuordnen oder der Rhythmus des Stücks analysieren. [Boeck2012]

RNNs und CNNs werden auch häufig kombiniert in AMT-Modellen. Meist in folgender Reihenfolge:

1. **CNN:** Extrahiert folgende Merkmale aus dem Spektrogramm:
 - Frequenzverteilungen und spektrale Muster
 - Tonhöhenlage und damit verbundene Obertöne
 - Klangfarbe einzelner Instrumente
 - Energieverteilung, unter anderem zur Erkennung von Toneinsätzen
 - Harmonische Strukturen wie Akkordfolgen
2. **RNN:** Verarbeitet auf Basis dieser Merkmale die zeitliche Abfolge und erkennt dabei folgende Eigenschaften:
 - Reihenfolge und Übergänge musikalischer Ereignisse
 - Beginn und Ende einzelner Töne zur Bestimmung der Notendauer
 - Rhythmische Muster und zeitliche Gruppierungen
 - Musikalische Phrasen mit zusammenhängender Struktur
 - Wiederholungen, Themen oder längere Abhängigkeiten im Verlauf
3. **Output:** Gibt das transkribierte Musikstück in strukturierter Form aus:
 - Als MIDI-Datei mit exakten Noteninformationen

Nachdem man die KI diesen Prozess durchlaufen lassen hat, kann man mit einem eigenen oder externen Programm diese MIDI-Dateien zu standardisierter Notenschrift transkribieren.

Es gibt aber auch Projekte, wo nur ein bestimmter Teil dieser Kette mit KI-Modulen realisiert wird, oder andere KI-Module verwendet werden. Mehr zu diesen Modulen und CNNs und RNNs im Detail erläutere ich in dem Abschnitt-4.1.

1.4 praktische Anwendungsfelder und Vorteile von AMT

AMT kann auch bei vielen anderen Problemen helfen oder in vielen Bereichen Quality-of-Life-Changes bringen. Zum einen kann der Musikunterricht spannender und interaktiver gestaltet werden. Es gibt eine breitere Auswahl von Musikstücken, die man den Schülern anbieten kann, wodurch diese durch individuell angepasste Musikstücke mehr Spaß und Ehrgeiz beim lernen haben könnten. Zudem kann man die gespielten Musikstücke der Schüler direkt beim Spielen transkribieren und gezielt erkennen, wo der jeweilige Schüler noch Verbesserungsmöglichkeiten hat. Grundsätzlich können deutlich mehr Musikstücke transkribiert werden, wodurch sich große Archive aufbauen lassen. Ein größeres Interesse an Musik wird geweckt, da Musikstücke von beliebten Serien, Filmen oder Spielen leichter für deren Musikbegeisterte Zielgruppe zugänglich sind. Alleine dadurch, dass Computerprogramme Musikstücke besser verstehen, können darauf aufbauend weitere Tools für die

Musikproduktion entwickelt werden. Auch KI würde davon stark profitieren. KI-generierte Musik würde verbessert werden, da die KI selber ein besseres Verständnis der Musik entwickelt. Audio-basierte Suchmaschinen könnten gewünschte Musikstücke oder bestimmte Videos präziser finden. Musik könnte barrierefreier gestaltet werden, indem gehörlose Menschen sie lesen können und Musiker beim Spielen direktes Feedback erhalten, ob sie die Noten korrekt gespielt haben.

1.5 Motivation und Zielsetzung dieser Arbeit

(Noch nicht angefangen!) Was wird in der Arbeit behandelt, worauf liegt der Fokus (z.B. KI-Methoden für AMT), warum ist das Thema relevant (z.B. für Musiker, KI-Forschung, Musikpädagogik)?

2 Geschichtliche Entwicklung von AMT-Systemen

2.1 Moorer und eines der ersten Musiktranskriptionssysteme

2.1.1 Grundlegende Probleme bei AMTs

Einer der ersten Papers über Automatic Music Transcription wurde von James A. Moorer im Jahr 1977 geschrieben. [Moorer1977] In diesem beschreibt Moorer seinen Ansatz, polyphone Musik Audiospuren direkt über Computerprogramme in Notenschrift zu übertragen. Während dieses Prozesses fallen ihm schon sehr viele Schwierigkeiten auf, die auch in späteren Papern und Arbeiten eine ausschlaggebende Rolle spielen werden.

Eines dieser Probleme wird von ihm als das "Cocktail-Party-Problem" bezeichnet. Dieses stellt die Schwierigkeit dar, auf einer Party bestimmten Stimmen zu folgen, während viele verschiedene Stimmen gleichzeitig erklingen. Das gleiche Problem liegt in der Noten transkription. Die meisten Musikstücke haben mehrere Instrumente, welche gleichzeitig spielen. Öfter gibt es auch Musikstücke wo es für ein Instrument, wie zum Beispiel Violine, mehrere verschiedene Stimmen gibt. Dies erschwert die Zuordnung bestimmter Noten zu einer gewählten Stimme. Schon viele Menschen scheitern deshalb daran große Musikstücke richtig zu transkribieren. Noch schwieriger wird es hier für Computerprogramme. Anfangs identifizieren diese bestimmte Töne anhand der Frequenz des Tons. Leider reicht das, wie Moorer feststellt, nicht aus um genaustens zu bestimmen, welche Töne genau momentan gespielt werden.

Jeder Ton hat Obertöne. Diese Obertöne sind jeweils das Vielfache von dem Grundton, den man spielt. Heißt, wenn ich auf einem Klavier den Ton C3 mit 130,81 Hz spiele dann hat dieser die Obertöne C4 (261,62 Hz), G4 (392,42 Hz) usw. Wenn man nur C3 spielt erklingen für das Computerprogramm auch die jeweiligen Obertöne, was man Frequenzüberlagerung nennt. Diese Frequenzüberlagerung sorgt dafür, das zum Beispiel ein Klavier anders klingt als eine Violine. Daraus resultiert dann die Klangfarbe (Timbre) eines bestimmten Instrumentes. [goswami2013timbre] Leider konnte Moorer zu dieser Zeit noch nicht die Klangfarbe eines Instruments erkennen. Er konnte auch noch nicht das Problem der Obertöne lösen, da die damaligen Algorithmen und Verfahren noch nicht in der Lage waren die Grundfrequenz von den Obertönen zu trennen, weshalb er sich ausschließlich auf zweistimmige polyphone Musikstücke fokussierte.

Ein weiteres Problem war Rauschen in realistischen Audiospuren und Stilistische mittel in der Musik, wie zum Beispiel Vibrato. In real aufgenommenen Audiospuren gibt es immer ein gewisses Hintergrundrauschen. [iZotope2025noisefloor] Dieses kann von einem Computerprogramm auch als Note erkannt werden oder verhindern, das bestimmte Noten richtig vom Computerprogramm erkannt werden. Moorer hat ein Musikstück analog aufgenommen und dieses dann mit einem 14-Bit converter digitalisiert. Dadurch war das Rauschen nicht weg, aber da er das Musikstück selber aufgenommen hat und dieses konvertiert hat sorgte es für insgesamt geringeres Rauschen. Zudem konnte er so die Musiker davon abhalten bestimmte Stilistische mittel zu verwenden, um bessere Daten zur Transkription zu erhalten. Stilistische mittel, wie Vibrato, konnten nicht genutzt werden, da diese eine kleine aber kontinuierliche Veränderung der Frequenz verursachen. Dadurch kann das Computerprogramm

nicht korrekt erkennen, das eigentlich eine einzelne Note gespielt wurde. Somit war der Onset und Offset der Note komplett falsch.

Das letzte Problem, was Moorers angesprochen hat, ist das Nutzen von nicht harmonischen Instrumenten wie Trommeln oder einem Schlagzeug. Diese Instrumente haben keinen eindeutigen Pitch für deren Töne, sie sind eher abhängig von Rhythmus und Lautstärke. Da Moorers AMT sich jedoch auf das Frequenzmuster der Noten fokussiert, können diese Musikinstrumente nicht berücksichtigt werden.

2.1.2 Der Aufbau von Moorers AMT-Systems

Moorers automatische Musiktranskriptionssystem war eins der ersten seiner Art. Viele weiteren AMT-Systeme leiten sich von diesen ab.

Zunächst wird ein analoges Musiksignal mit einem 14-Bit converter digitalisiert. Dieses digitale Musiksignal wurden dann genutzt um mithilfe von Bandpassfiltern, ein Filter welcher nur bestimmte Frequenzen durchlässt, bestimmte Frequenzbereiche zu isolieren. Dadurch konnte Moorers die gespielte Note und deren Dauer, also zugleich auch deren Onset und Offset, feststellen.

Nun mussten die bestimmten Noten einer gewählten Stimme zugeordnet werden. Dies wurde durch melodische Gruppierung verwirklicht. Zunächst wurden Inseln gebildet. Inseln sind Noten die sich zeitlich vollständig überlappen. Wir gehen davon aus dass jede Stimme nur eine Note gleichzeitig spielt, wodurch diese Noten nicht der gleichen Stimme zugeordnet werden können. Als Nächstes müssen die anderen Noten auf verschiedene Kombinationen getestet werden. Desto kleiner die Frequenz sprünge je Note sind, desto wahrscheinlicher gehören sie einer Stimme zu. Zudem werden Gruppierungen von Noten erstellt, welche am wahrscheinlichsten harmonisch nacheinander gespielt worden.

Zum Schluss ließ Moorers die gewonnenen Daten durch ein Programm laufen, um diese dann mithilfe eines Plotters in eine Notenschrift umzuwandeln.

2.1.3 Hidden Markov Models

Hidden Markov Modelle (HMM) sind statische Modelle, welche sich sehr gut zur Analyse von Musikstücken eignen. Sie wurden erstmal in den 1960er Jahren erfunden [baum1970maximization] und sind ein zentraler bestandteil früherer AMT-Systeme. HMMs beschreiben eine Abfolge von "versteckten Zuständen", welche im Kontext von AMT-Systemen Noten im Audiosignal darstellen. Durch indirekt beobachtbare Daten, wie zum Beispiel die Spektraldaten des Audiosignals, können diese Noten erschlossen werden.

HMMs bestehen aus:

- Zustände (States)
- Übergangswahrscheinlichkeiten (Transition Probabilities)
- Emissionswahrscheinlichkeiten (Emission Probabilities)
- Beobachtungen (Observations)

Nehmen wir das Beispiel eines Klaviers. Ein Klavier hat 88 Tasten, und somit mindestens 88 Zustände. Durch Akkorde können zudem mehr Zustände generiert werden. Die Übergangswahrscheinlichkeit stellt dar, wie wahrscheinlich es ist von einem Zustand zu einem bestimmten anderen Zustand zu wechseln. Zum Beispiel könnte es wahrscheinlicher sein, dass auf die Note C4 der Ton G3 folgt statt D1, da diese Tonfolge harmonischer und musikalisch plausibler klingt. Dies ist jedoch nur eine Annahme anhand von gesammelten Testdaten, weshalb es nicht als Begründung ausreicht. Deshalb kommt als zweite Instanz die Emissionswahrscheinlichkeit hinzu. Diese gibt an, wie Wahrscheinlich ein bestimmter Zustand in der momentanen Beobachtung ist. Die Beobachtung wird dabei zusammengesetzt aus Eigenschaften, wie Frequenzverteilung, Spektrogramm oder anderen Merkmalen die

man aus anderen Modulen herleiten kann. Aus den gesammelten Daten kann nun mithilfe von zum Beispiel dem Viterbi-Algorithmus [takeda2002hidden] die wahrscheinlichste Abfolge von Zuständen berechnet werden.

In gewisser Weise lassen sich HMMs auf KI-Modelle übertragen. Beide arbeiten mit versteckten Zuständen und berechnen anhand von Testdaten die Wahrscheinlichste Kombination von Zuständen. Natürlich sind moderne KI-Modelle weitaus komplexer, doch HMMs spielten im Kontext automatischer Musiktranskriptionssysteme eine zentrale Rolle dabei, wie KI-Methoden in diesem Bereich später eingesetzt wurden. Sie beeinflussten insbesondere den Umgang mit zeitlichen Abfolgen und Unsicherheiten in der Tonerkennung, was bis heute relevante Konzepte in KI-basierten AMT-Systemen sind.

2.2 MIDI-Dateien

Notenschrift als Input für ein Computerprogramm, Synthesizer oder ähnliches ist unhandlich. Zunächst müsste man die gespielten Noten immer wieder zu Notenschrift konvertieren und danach diese auch noch in anderen Programmen analysieren, was sehr aufwändig werden würde. Eine bessere Lösung dafür wäre eine Datenschreibweise, bei der alle wichtigen Informationen bestimmter Noten übersichtlich aufgeschrieben sind. MIDI-Dateien sind dafür perfekt geeignet.

MIDI ist ein Standardprotokoll zur Kommunikation zwischen elektronischen Musikinstrumenten, Computern und anderen Geräten wie zum Beispiel Synthesizer. Dieses Protokoll wurde 1983 erstmals eingeführt und wurde schnell zu einem Standard in der digitalen Musikindustrie. [smith1983midi] In MIDI-Dateien werden Daten von Tönen gelagert, welche zum Beispiel zuvor von einem elektronischen Instrument gespielt wurden oder durch AMTs erfasst wurden.

In MIDI-Dateien werden folgenden Daten gespeichert:

1. **MIDI Header-Chunk (MThd):** Enthält grundlegende Informationen zur Struktur der Datei:
 - Formattyp (0 = eine Spur, 1 = mehrere synchrone Spuren, 2 = unabhängige Spuren)
 - Anzahl der folgenden MTrk-Blöcke (Tracks)
 - Zeitauflösung (Ticks pro Viertelnote)
2. **MIDI Track-Chunks (MTrk):** Jede Spur enthält eine zeitlich sortierte Liste von MIDI-Events:
 - **MIDI-Events:**
 - Note Onset / Offset
 - Control Change (Lautstärke)
 - Program Change (gibt das spielende Instrument an)
 - Pitch Bend (verändert die Tonhöhe)
 - Aftertouch / Polyphonic Key Pressure (Druckstärke pro Taste)
 - **Meta-Events:**
 - Set Tempo (Tempo in Mikrosekunden pro Viertelnote)
 - Time Signature (Taktart zum Beispiel 4/4 oder 3/4)
 - Key Signature (Tonart zum Beispiel C-Dur oder A-Moll)
 - Track Name
 - Lyrics
 - Markers
 - End of Track (Ende einer Spur)

- **System Exclusive Events (SysEx):**

- Herstellerspezifische Daten wie Synthesizer-Presets oder Spezialbefehle

3. **Delta-Time:** Gibt die Zeit (in Ticks) an, die seit dem letzten Event vergangen ist:

- Ermöglicht die genaue zeitliche Positionierung jedes MIDI-Events
- Grundlage für das Timing und die rhythmische Struktur der Datei

Am wichtigsten sind dabei die MTrk-Blöcke, in denen die Daten der einzelnen Noten gespeichert werden. Dabei stellt ein Track die Eventliste einer ganzen Stimme dar, wie zum Beispiel die Melodiestimme, eine Violine, die Pedalsteuerung eines Klaviers oder Metadaten. Es fällt auf, dass diese vier Beispiele alle sehr unterschiedliche Aufgaben und Bedeutungen haben. Das liegt daran, dass in MIDI-Dateien eher zusammenhängende Funktionen gespeichert werden und nicht nur Musiknoten.

MIDI-Dateien kamen auch der Forschung für AMT-Systemen sehr gelegen, da man nun ein standardisiertes Output-Format für diese Programme besaß. Später werden diese zudem sehr essenziell bei dem Training KI-basierter AMT-Systeme. [telila2025cnn]

2.3 Entwicklung von Datensätzen

Während der Forschung an neuen AMT-Systemen wurden immer wieder neue Datensätze genutzt, um das AMT-System zu bespielen oder heutzutage auch zu trainieren. In der Transkription von Musikstücken sind diese sehr relevant, da man nicht so leicht an nützliche Datensätze generieren kann und mit dem weiteren Einsatz von KI-Modellen genau diese sehr wichtig, in größeren Mengen, sind. Die ersten Datensätze, welche genutzt worden waren, selbst kreierte Datensätze, welche lediglich einige Eigenschaften der Noten beinhalten. In den AMT-Systemen von Moorer [Moorer1977] oder auch Martin [Martin1996] wurde solch ein Ansatz verfolgt. Durch die Einführung von MIDI-Dateien wurde ein Standard entwickelt, welcher jetzt in dem Großteil der AMT-Systeme eingebaut werden sollte. Auf der Grundlage von MIDI-Dateien wurden auch spezialisierte Datensätze erstellt. Zwei der größten und wichtigsten sind MAPS (MIDI Aligned Piano Sounds) und MAESTRO (MIDI and Audio Edited for Synchronous TRacks and Organization). Dabei ist MAPS ein Datensatz aus künstlich generierten Audiospuren, während MAESTRO ein ungefähr 200 Stunden langer Datensatz von realen isolierten Studioaufnahmen ist. Vor allem bei dem Training neuer KI-Modellen sind solche großen Datensätze sehr hilfreich. Ein weiterer wichtiger Datensatz ist ADTOF (Annotated Drum Transcription Onset Features). Dieser besteht ausschließlich aus unharmonischen Instrumenten. In Moorers und anderen AMT-Systemen ist die Erkennung von unharmonischen Instrumenten ein großes Problem. KI-Modelle können mithilfe von dem ADTOF Datensatz sich speziell auf diese Instrumente vorbereiten. Es gibt auch Methoden, schnell seine eigenen Datensätze zu generieren. Eine der neuesten Methoden nutzt HMM- und Viterbi-basierte Alignment-Verfahren, um synthetische Audiosignale zu kreieren, damit man mehr Daten hat, um sein KI-Modell zu trainieren. [joysingh2019development]

2.4 Polyphone AMT-Systeme und neue Ansätze

2.4.1 Blackboard-System

Moorer stellte, mit seinem AMT-System, viele grundlegende Bausteine für dieses Forschungsgebiet. Jedoch gab es noch viele offene Probleme, die noch überwunden werden mussten. Eines der ausschlaggebendsten Probleme stellte sich Keith D. Martin. [Martin1996] Zuvor wurden höchstens zwei verschiedene Stimmen gleichzeitig zur Musiktranskription verwendet. Ein großer Teil von Musikstücken verwendet jedoch mehr Stimmen. Um diese polyphonen Musikstücke zu transkribieren, baute Martin einen neuen Ansatz eines AMT-Systems mit innovativen Modulen und Ansätzen.

Nachdem das Input-Audiosignal in ein Correlogram verarbeitet wurde, spaltet sich Martins AMT-System auf, in einen Analysepfad und einen Rhythmuspfad. Dabei konzentriert sich der Analysepfad auf die Zusammenhänge der verschiedenen Noten, während der Rhythmuspfad sich mehr mit der

Lautstärke und den Notenanschlägen beschäftigt. Am Ende werden diese Kenntnisse zusammengeführt. Der Output besteht aus dem Onset, der Dauer und der Frequenz jeder gespielten Note. Martin gibt nicht explizit zurück, welcher Stimme jede Note zugeordnet ist. Durch das Blackboard-System, und vor allem nach sequentieller Analyse der Intervalle, kann man jedoch die erhaltenen Noten später bestimmten Stimmen nachträglich korrekt zuordnen.

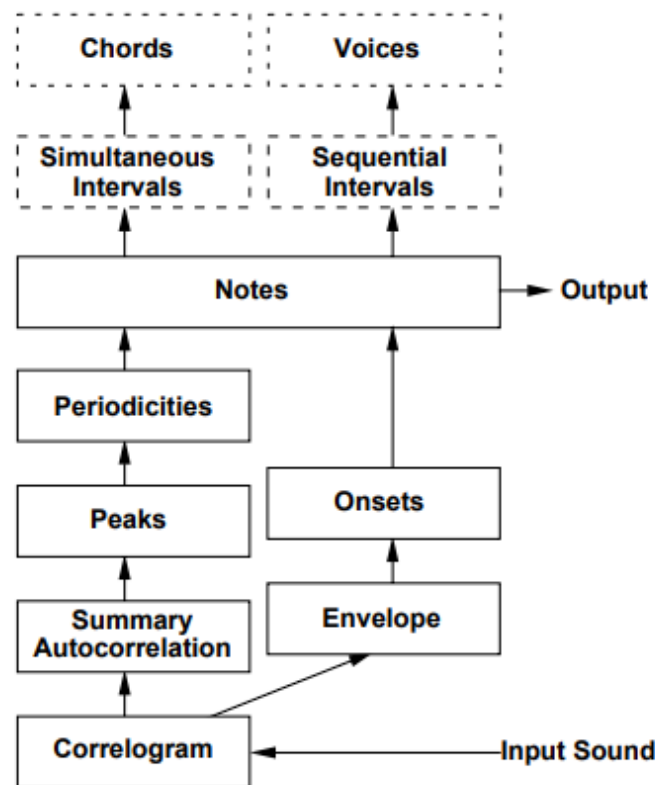


Abbildung 1: Systemstruktur des AMT-Ansatzes von Keith D. Martin (1996), basierend auf [Martin1996].

Martin nutzte ein Blackboard-System zur Notenerkennung und Hypothesenbildung. Unter anderem kann man dadurch Noten bestimmten Stimmen zuordnen. Ein Blackboard-System ist ein kollaboratives Problemlösungsmodell, welches aus verschiedenen Modulen besteht, die alle auf einem gemeinsamen Datenraum Hypothesen aufstellen können. Um diese Vermutungen aufstellen zu können müssen jedoch erst die dafür nötigen Daten erarbeitet werden. Dies erreicht Martin mithilfe von Sinuskurvenanalyse. Zur Sinuskurvenanalyse, in Martins Aufbau, gehören die Bestandteile Correlogram, Envelope, Summary Autocorrelation und Peaks. Durch diese können Eigenschaften der Noten ermittelt werden, auf denen aufbauend später Hypothesen entstehen. Die Module des Blackboard-Systems sind dementsprechend Onsets, Periodicities und Simultaneous, Sequential Intervals. Diese Module geben sich gegenseitig mehr Informationen über die gespielten Noten, sodass später gegebene Stimmen unterschieden werden können.

Der Analysepfad beginnt bei dem Correlogram. Hier wird der Input, ein reales Audiosignal, zunächst verarbeitet und dann in einem Correlogram dargestellt. Dieses Visualisiert die Korrelation der gegebenen Noten in Abhängigkeit der Zeit, Frequenz und Lag. Lag soll in diesem Fall darstellen, wann sich ein bestimmtes Signal wiederholt. Dabei ist die Wiederholung ein Signal, welches dem Ursprungssignal maximal selbst ähnelt. Heißt, wenn ich einen Ton mit der Frequenz x spiele und dieser sich nach zum Beispiel 10ms wiederholt wird das rechnerisch durch den Lag dargestellt. Als Nächstes wird mithilfe der Summary Autocorrelation das Correlogram komprimiert und die Datenstruktur normalisiert. Dadurch entsteht eine stabile Grundfrequenz, sodass die weiteren Schritte effizient das Correlogram untersuchen können. Nun werden basierend auf der normierten Struktur die Peaks gesucht. Diese


Peaks deuten darauf hin, wann periodische Komponenten auftreten. Dabei geben sie nicht den Onset der Noten zurück, sondern nur die generelle Frequenz zu einer bestimmten Zeit. Darauf werden mehrere Peaks, die regelmäßig wiederkehren, gruppiert. So kann man Muster in der gespielten Musik erkennen und kurzzeitige Störfaktoren ausschließen.

Im Rhythmuspfad wird wiederum die zeitliche Analyse der Noten durchgeführt. Zunächst wird mit dem Envelope die Lautstärke des Signals zu jedem Zeitpunkt festgelegt. Dies dient als Grundlage, um anschließend die Onsets der Noten zu bestimmen. Jeder Onset wird sehr präzise im Envelope dargestellt durch einen plötzlichen Anstieg der Lautstärke.

Nachdem die beiden Pfade durchgelaufen sind, hat man schon Noten, welche man grundsätzlich in Notenschrift transkribieren kann. Jedoch sind diese Noten musikalisch noch nicht verstanden worden. In der oben gegebenen Abbildung gibt es noch die Bestandteile Simultaneous und Sequential Intervals. In dem Modul Simultaneous Intervals wird ermittelt, welche Töne gleichzeitig erklingen. Diese können, wenn sie harmonisch zueinander sind, zu einem Chord gebunden werden. Sequential Intervals analysieren dahingegen, welche Töne nacheinander gespielt werden und möglicherweise eine Melodie bilden könnten. Dies erfolgt durch Tonhöhenverläufe, Pausen und Frequenzunterschiede. Dadurch können Melodien, Basslinien oder Begleitungen voneinander getrennt werden. Zum Schluss werden dadurch die verschiedenen Stimmen, in Martins Modell, aufgetrennt.

2.4.2 RASTA-basiertes System

Ende 1997 publizierte Kalpuris seine Masterarbeit "Automatic transcription of Music". [klapuri1998automatic] In seiner Arbeit benutzt er ein neues RASTA-basiertes Verfahren, zur Unterdrückung nicht harmonischer Signalkomponenten. Somit konnten auch Musikstücke mit nicht harmonischen Instrumenten, wie Trommeln, transkribiert werden. Zudem führte er ein Modul ein, zur Schätzung der Anzahl an gleichzeitigen Stimmen, die in dem Musikstück vorkommen. Kalpuris AMT-System konzentriert sich, gegenüber Martins AMT-System, viel mehr auf die robustheit gegenüber echten polyphonen Audioaufnahmen mit rauschen, Störgeräuschen und nicht harmonischen Instrumenten. Die Struktur des Systems ist linear aufgebaut und sehr präzise in dem Aufgabenfeld, für die es entwickelt wurde.



Kalpuris System ist sequentiell aufgebaut und besteht aus sechs Modulen. Als Input wird eine reale Audioaufnahme genutzt, welche in ein Monosignal umgewandelt wird. Dieses Monosignal wird mithilfe von STFT transformiert, sodass durch das entstandene Spektrogramm Zeit, Frequenz und Amplitude der gegebenen Noten ausgelesen werden kann. Anhand dieser Daten werden als Nächstes die Onsets der Noten bestimmt. Kalpuri nutzt, zur Onset erkennung, ein Schema von Eric D. Scheirer. [scheirer1998tempo] Bei diesem wird das Audiosignal in Frequenzbänder aufgeteilt und auf jedem Band die zeitliche Änderung der Energie analysiert. Daraufhin werden die resultierenden Energie-Deviante der verschiedenen Bänder summiert. Die nun entstehenden Peaks werden als Onsets der Noten interpretiert. Als Nächstes werden unharmonische Instrumente und transiente Geräusche, wie zum Beispiel Rauschen, entfernt. Dies erfolgt mithilfe der RASTA-Filterung, welches auf das spektrale Signal, vom gegebenen Spektrogramm, wirkt. Mehr zu der RASTA-Filterung werde ich in einem folgenden Absatz, im Detail, erläutern. Um mehrere Töne, die gleichzeitig im Signal erklingen, zu erkennen wird harmonic matching genutzt. Die Multipitch-Schätzung funktioniert so, dass zu einer bestimmten Zeit immer die dominanteste Tonhöhe, basierend auf der Energieverteilung im Signal, gesucht wird. Sobald man diese ermittelt hat, wird sie vom Signal subtrahiert und dieses Verfahren wird erneut eingesetzt, bis man jeden signifikanten Pitch untersucht hat. Jetzt werden die Stimmenanzahlen geschätzt. Dieses Modul werde ich ebenfalls ausführlich in einem folgenden Absatz detailliert wiedergeben. In dem Modul Note-Formation werden nun die gegebenen Daten zusammengeführt und in

eine MIDI-Datei zusammengefasst. Diese MIDI-Datei wäre jetzt bereit in Notenschrift transkribiert zu werden.

Die RASTA-Filterung ist eine der neuen Module von Klapuri. Sie bewirkt, dass nicht-harmonische Störsignale, wie Rauschen, unharmonische Instrumente und vom Musikstück unabhängige Geräusche ausgefiltert werden. Dadurch werden die harmonischen Komponenten des Stückes mehr herausgehoben, wodurch folgende Module einfacher weitere Eigenschaften den gegebenen Noten zuordnen können. Zudem stärkt dies die Robustheit der Multipitch-Schätzung, in der mehrere Töne zur gleichen Zeit im Audiosignal erkannt werden müssen. Dieses Verhalten wird erzielt, indem ein Filter gesetzt wird, der schaut, wie Laut jede Frequenz zu jedem Moment ist. Nach der Berechnung gibt der Filter eine Lautstärke-Kurve zurück. Alle Frequenzanteile, die entweder zu kurzzeitig sind, wie etwa Claps oder Hi-Hats, oder zu langanhaltend, wie dauerhaftes Rauschen, werden durch einen Bandpassfilter aus dem Audiosignal herausgefiltert. Dadurch bleiben vor allem die zeitlich stabilen, musikalisch relevanten Komponenten erhalten.

Auch die Stimmanzahlerkennung ist, von Klapuri, ein neu eingefügtes Modul. Vor allem bei der Multipitch-Schätzung ist dieses sehr wichtig, da das System dadurch ein Bild davon bekommt, wie viele Töne gleichzeitig erklingen können, zu einer bestimmten Zeit. Die Multipitch-Schätzung zieht den spektralen Abdruck eines Tons von dem Audiosignal ab, wenn dieser erkannt wurde. Jedoch kann diese nicht einschätzen, wann genau sie aufhören soll die Töne zu erkennen. Da hilft die Stimmanzahlschätzung. Diese analysiert das neue Audiosignal nach jeder Multipitch-Schätzung und gibt aus, ob in der spektralen Energie noch Noten zu erkennen sind. Dies ordnet die Stimmanzahlschätzung durch drei Eigenschaften ein. Gibt es in der spektralen Energie noch typische Muster von harmonischen Klängen? Wie viele Stimmen wurden schon erkannt? Tragen die weiteren extrahierten Stimmen noch groß etwas zur Erklärung des gesamten Musikstückes bei? Dadurch extrahiert die Multipitch-Schätzung nur die nötigen Noten und unnötig Störfaktoren werden ausgelassen. Zudem kann man eine ungefähre Einschätzung bekommen, wie viele Stimmen in dem jeweiligen Musikstück erklingen.

2.5 Einbindung von Künstlicher Intelligenz

Für eine lange Zeit basierten AMT-Systeme größtenteils auf signal verarbeitenden Algorithmen, wie zum Beispiel HMMs. Doch auch diese Systeme waren nicht verschont durch den stetigen Anstieg von KI basierten Lösungswegen. 2010 bis 2012 wurden die ersten Ansätze von AMT-Systemen erstellt, welche maschinelles Lernen nutzten. [eyben2010universal] Oft wurden KI-Modelle nur für bestimmte Teilprobleme genutzt wie Onset Detection, pitch estimation oder instrument classification. Dieser Trend zog sich durch, wodurch heutzutage so gut wie jedes AMT-System eine Art von KI-Modell nutzt.

Einige AMT-Systeme nutzen auch mehrere KI-Modelle gleichzeitig. Solch ein AMT-System wird auch in der, 2016 veröffentlichten, Arbeit von Sigtia Siddharth, Emmanouil Benetos und Simon Dixon beschrieben. [sigtia2016end] Es ist eins der ersten KI basierenden Ent-to-End AMT-Systeme, welches polyphone Musikstücke transkribieren kann. Der KI-Ablauf des AMT-Systems ist folgendermaßen aufgebaut. Ein CNN bekommt als Input ein Log-Mel-Spektrogramm des Audiosignals bereitgestellt und entzieht diesem bestimmte Merkmale der Noten. Diese Merkmale werden einem RNN weitergegeben, welches dadurch die zeitlichen Abhängigkeiten herausfiltert. Als Nächstes wird durch Frame-wise Multi-Label Classification vorhergesagt, welche Noten zu welcher Zeit aktiv sind. Somit bekommt man als Output eine Binärmatrix, wo der Pitch mit Abhängigkeit der Zeit angezeigt wird. Das System wird mit dem MAPS Datensatz durch Supervised Learning trainiert. Diese Arbeit stellt den drastischen Übergang von heuristischen, regelbasierten AMT-Systemen zu selbstlernenden AMT-Systemen dar. Heutzutage sind CNNs und RNNs, oder ähnliche KI alternativen, kaum wegzudenken aus der Struktur von AMT-Systemen.

Viele intelligente und erfindungsreiche Personen haben sich über die Jahre mit AMT-Systemen beschäftigt. Dadurch konnten nachfolgende Arbeiten neue Module und Ansätze für sich nutzen, um deren Entwicklung weiter voranzutreiben. Auch heutzutage ist dies immer noch der Fall, wodurch es

stets neue AMT-Systeme mit neuen Ansätzen gibt. Diese neuen, auf KI basierenden Systeme, haben alle jeweils ihre eigenen Stärken und Schwächen. Auch wenn die Forschung von AMT-Systemen in den letzten Jahren viele Fortschritte erfuhr, gibt es trotz dessen noch große Baustellen und ungelöste Aufgaben. Im folgenden Abschnitt werde ich weiter auf den momentanen Stand von AMT-Systemen eingehen und anhand einiger Beispiele verschiedene Strukturen darstellen. Zudem gehe ich auf momentan relevante Hindernisse in der automatischen Musiktranskription ein.

3 Hindernisse Moderner AMT-Systeme

Trotz der Einführung von KI-Modulen gibt es noch viele offene Probleme, die noch nicht gelöst werden konnten oder noch nicht perfekt gelöst sind. Auch wenn durch die Nutzung von KIs viele Fehler geringer oder sogar komplett behoben werden konnten, agieren diese völlig anders als normale Algorithmen. Dies führte, zum Teil, auch zu neuen Problemen, welche davor nicht mal bekannt waren.

3.1 Onset Detection

Die On-/Offset Erkennung von Noten wurde schon ausgiebig in vielen Arbeiten behandelt. Trotzdem ist diese noch nicht komplett akkurat. Das liegt daran, dass man On-/Offsets an Lautstärke sprüngen und spektralen Änderungen erkennt. Bei polyphonen Musikstücken mit vielen verschiedenen Noten kann man jedoch schwieriger diese Unterschiede erkennen. Lautstärke sprünge werden ungenauer, da viele andere Noten während des Onsets einer bestimmten Note spielen. Mit spektralen Änderungen sind hier Veränderungen der Energieverteilung gemeint. Einer der ausschlaggebendsten Anteile ist die Spektrale Fluktuation. Diese stellt den plötzlichen Anstieg von Energie in bestimmten Frequenzbändern dar. Wenn nun ein Ton auf einem Klavier gespielt wird kann somit der Onset sehr gut ermittelt werden. Bei Instrument wie einer Geige kann dies jedoch zu Problemen führen. Hier können Noten gebunden gespielt werden, was zu einem Unterschied in der Frequenz, jedoch nicht in dem Energie level führt. Zudem kann eine Note, durch Crescendo, zunächst leise gespielt werden und mit der Zeit an Lautstärke zunehmen. Dieser Onset hat keinen Energie-Peak und somit erkennt das System hier auch nur schwierig eine scharfe Kante. So welche Töne, welche keinen starken Einschlag haben, werden als nicht-perkussiv bezeichnet. Ein weiteres Problem der Onset Erkennung sind nachwirkende Geräusche oder störende Geräusche. Bleiben wir bei dem Beispiel einer Geige, so können einige Töne, sobald man aufhört andere Töne zu spielen, nachklingen. Dadurch könnten Töne von anderen Instrumenten verdeckt werden, wodurch das System den Onset nicht erkennt. Ähnlich kann dies auch der Fall sein, wenn im Audiosignal ein starkes Rauschen besteht.

3.2 Polyphonie und Notenzuordnung

Durch die Nutzung von polyphonen Musikstücken sind, wie schon bei der Onset Erkennung, viele Probleme schwerer und deutlicher geworden. Ein weiteres Problem, das gezielt von diesen Anwendungsfällen abhängt, ist die Verwechselung von Noten im Audiosignal. Einige Noten haben sehr ähnliche Frequenzen. Wenn diese Noten gleichzeitig gespielt werden, ist es schwieriger für das System, die korrekten Noten herauszuhören. Neuronale Netzwerke helfen hierbei deutlich, da diese nicht nur das Spektrum zur Analyse einbeziehen, sondern auch auf einer zeitlichen und harmonischen Ebene den Kontext besser zuordnen können und somit die wahrscheinlichsten nächsten Noten zurückgeben können. Trotz dessen scheitert auch KI an der Einordnung der richtigen Noten, wenn die gespielten Noten eine sehr ähnliche Frequenz besitzen oder die Akkorde zu unterschiedlich zu den Trainingsdaten sind. In der Arbeit von Lukas Samuel Martak werden diese Probleme nochmals deutlicher aufgegriffen. [martak2022balancing]

3.3 Instrument spezifische Probleme

Oft ist die Qualität der Transkription auch abhängig von den vertretenen Instrumenten in dem Audiosignal. Ethnische Instrumente zum Beispiel sind Instrumente die einer bestimmten Kultur angehören und in unserer westlichen Kultur weniger vertreten sind. Dadurch gibt es auch weniger Datensätze,

welche diese Instrumente beinhalten. KIs brauchen Trainingsdaten und ohne diese können sie bestimmte Instrumente nicht richtig zuordnen. Die meisten Datensätze zur Musiktranskription bestehen hauptsächlich aus Klavier und Geigen Noten. Instrumente wie Flöten oder Orgeln können von diesen Noten gut abgeleitet werden, da sich deren Struktur deutlich ähnelt. Eine weitere Gruppe von Instrumenten die Probleme bei der Transkription bereitet sind elektronische Instrumente. Wenn man zum Beispiel eine E-Gitarre spielt, kann diese Effekte nutzen, welche nicht üblich in klassischen Datensätzen von Klavieren vorkommen. Somit erkennt die KI diese Töne nicht korrekt an. Das letzte Instrument welches Schwierigkeiten bringt, ist der Gesang. Jede Stimme ist einzigartig und vor allem nicht statisch. Wenn man einen Ton auf dem Klavier spielt, besitzt dieser, wenn das Klavier richtig gestimmt ist, immer die gleiche Frequenz. Ein Mensch kann jedoch nicht jeden Ton immer komplett perfekt spielen, wodurch eine große Varianz an Tönen entsteht. Zudem verläuft der Klang einer Stimme von einer Note zur nächsten. Es gibt nicht immer starke Peaks zur Onset Erkennung. Gesang ist auch, wie die vorher genannten Instrumentgruppen, nicht sonderlich vertreten in größeren Datensätzen. Xiangming Gu hat sich in folgende Paper speziell auf das Thema des Gesangs in der Musiktranskription fokussiert [gu2023deep, gu2024automatic] und kam in seiner Arbeit sogar auf eine Onset Erkennungsgenauigkeit von ungefähr 80%, wenn Gesang genutzt wird.

3.4 Notendauer

Neben dem Onset einer Note muss man auch erkennen, wie lange eine bestimmte Note gespielt wird. Das kann schwierig sein, da man den Nachhall einer Note von der wirklich gespielten Zeit der Note trennen muss. Es gibt jedoch bei einigen Instrumenten, wie zum Beispiel dem Klavier, ein spezielles Problem. Wenn man während des Spielens einer Note das Pedal drückt, gibt es keinen klaren Punkt, an dem man den Übergang zwischen der Note und dem Nachhallen eindeutig erkennen kann. Die Lautstärke sinkt dabei nicht abrupt, sondern nur langsam ab. Natürlich ist dieses Problem in polyphonen Musikstücken nochmal deutlich stärker, da sich dort die verschiedenen Nachhallphasen überlappen. Fatemeh Jamshidi betont dies in seiner Arbeit als eins der grundlegendsten Probleme, zusammen mit der Onset Erkennung. [jamshidi2024machine]

3.5 Reale Audioaufnahmen

Ein perfektes AMT-System sollte sogar auf realen Audioaufnahmen 100% Genauigkeit besitzen. In der Realität klappt das aber nicht so gut, da Live-Audioaufnahmen mehr Hintergrundrauschen besitzen. Dies war schon vor der Einführung von KI ein Problem und wurde durch die Einbindung von KI-Modulen nicht sonderlich viel verbessert. Das liegt daran, dass KIs mit isolierten Studioaufnahmen, wie es im MAESTRO Datensatz der Fall ist, trainiert werden. Natürlich gibts auch Datensätze mit realen Audioaufnahmen, jedoch bräuchte man dafür viel mehr Trainingsdaten und vor allem auch viele unterschiedliche Hintergrundgeräusche, damit die KI auf alles trainiert wird. Um dem entgegenzuwirken, kann man Studio-Datensätze wie MAESTRO durch Data-Augmentation variieren, wodurch realistischere Audioaufnahmen entstehen. So setzte Yuta Kusaka dies auch in seiner Arbeit, für seine Trainingsdaten, ein. [kusaka2024mobile] Er variierte Timber, Reverb, Noise und veränderte die Qualität des Aufnahmegerätes zu der eines Smartphones. So bekommt er viele neue Datensätze, die passend auf seinen Anwendungsfall ausgelegt sind.

3.6 Frame-basierte vs Event-basierte AMT-Systeme

Die meisten AMT-Systeme sind Frame-basiert und nicht Event-basiert. Frame-basiert bedeutet, dass die Analyse des Audiosignals in Zeitfenster, ungefähr 20ms, aufgeteilt wird. Jedes Zeitfenster wird somit der momentane Stand des Audiosignals von den verschiedenen Modulen analysiert. Falls nun zum Beispiel ein Onset einer Note genau zwischen zwei Zeitfenstern liegt, wird dieser verschoben oder verzerrt, sodass dieser mit den gegebenen Zeitfenstern übereinstimmt. Event-basierte AMT-Systeme hingegen fragen immer ab, was das nächste musikalische Ereignis im Audiosignal ist und reagieren dementsprechend. Dadurch entspricht der Output viel mehr dem Input, in relation zu der zeitlichen Abfolge. Im Ergebnis sind Event-basierte AMT-Systeme somit Frame-basierten AMT-

Systemen überlegen. Jedoch ist in der Realität trotzdem fast jedes AMT-System Frame-basiert. Das liegt daran, dass Event-basierte AMT-Systeme eine sehr neue Entwicklung sind und zudem auch schwerer zu implementieren ist. Frame-basierte Methoden wurden ungefähr im Jahre 2000 entwickelt und haben sich seitdem in zahlreichen Arbeiten durchgesetzt. [Martin1996, klapuri1998automatic] Dahingegen sind Event-basierte Methoden erst ungefähr 15 Jahre später entwickelt worden. [performance_rnn2017event] Deshalb wurden Frame-basierte Methoden lange als der Standard angesehen. Zudem ist die Umsetzung von Event-basierten AMT-Systemen schwerer als Frame-basierte. Das System muss korrekt jedes Event einschätzen und zuordnen, ist es ein Onset ein Offset oder doch nur Rauschen? Wenn es nun einen Fehler macht, wird sich das, im Gegensatz zu Frame-basierten, auf das ganze weitere Audiosignal auswirken. Auch das Training kann nicht parallel verlaufen, sondern muss token weise abgearbeitet werden. Diese Gründe, und noch einige andere, machen Event-basierte AMT-Systeme zu einer viel größeren Herausforderung. Jedoch ist der Übergang von Frame zu Event mit der Zeit irgendwann nötig, da man somit den Inhalt der Musikstücke viel präziser wiedergeben kann. Die Forschung in dem Event-basierten Methoden steigt auch in den letzten Jahren immer mehr an.

3.7 Blackbox von KI-Modellen

Das letzte Problem betrifft KI im Allgemeinen. Ein neuronales Netz arbeitet mit sehr hochdimensionalen Räumen, die für uns Menschen nicht begreifbar sind. Selbst wenn wir uns die Millionen und mehr Gewichtungen anschauen würden in diesen keinen Zusammenhang feststellen. In der Musiktranskription ist dies auch ein Problem, da wir somit nicht erfassen können, welche Einstellungen unsere KI genau braucht damit sie alle Musikstücke perfekt transkribieren kann. Jedoch gibt es auch Methoden, welche die Blackbox ein wenig umgehen. Im Forschungsgebiet der Explainable AI gibt es einige Methoden, welche auch in KI-basierten AMT-Systemen verwendet werden. Unter diesen fallen Saliency Maps, Feature-Visualisierung und Attention-Mapping. Concept Activation Vectors, Layer-wise Relevance Propagation, Surrogat-Modelle sind andere Explainable AI Methoden, die zur Nutzung in AMT-Systemen diskutiert werden, aber noch nicht richtig integriert sind. Dies liegt an mehreren Gründen. Musikalische Konzepte wie Akkorde oder Onsets sind nicht direkt lablebar, wie zum Beispiel Katzen oder Hunde, da diese stark abhängig von spektralen und zeitlichen Mustern sind. AMT-Systeme sind zeitlich-sequenziell und besitzen pro Zeitfenster mehrere Outputs. Viele lokale Änderungen auf ein bestimmtes Zeitfenster, wie den dB-Wert ändern, haben einen globalen Einfluss. Methoden, welche in AMT-Systemen angewendet werden, haben dahingegen Eigenschaften, die durch die Struktur von AMT-Systemen profitieren. Saliency Maps stellen dar, wie stark jedes Zeitfenster im Spektrogramm beeinflusst hat, das zum Beispiel ein bestimmter Ton erkannt wurde. Dies basiert auf dem Gradienten und ist besonders hilfreich bei CNN-basierten Modellen. Feature-Visualisierung beobachtet konkret die einzelnen Neuronen jeder Ebene im neuronalen Netzwerk. Es wird geschaut, welche Neuronen sehr stark bei bestimmten Inputs reagieren. So kann man erkennen, welche Teile des Netzes für welche Aufgaben verantwortlich sind und ob vielleicht bestimmte Stellen des Netzes gar nicht genutzt werden. Attention-Mapping nimmt den gegebenen Input und gewichtet diesen, je nachdem welche Teile davon wichtig für eine bestimmte Vorhersage sind. So erkennt man, welche Zeitfenster den meisten Einfluss auf zum Beispiel einen bestimmten Onset hatten. Vor allem bei polyphonen Musikstücken kann man relevante zeitliche Zusammenhänge erkennen. Ein gutes Beispiel von Attention-Mapping findet man in der Arbeit von Kin Wai Cheuk. [cheuk2021revisiting]

4 AMT-Systeme heutzutage

4.1 beliebte KI-Module

KI-Systeme haben, in den letzten Jahren stark an Beliebtheit gewonnen. AMT-Systeme bilden da keine Ausnahmen. Vor allem durch die Integration von CNNs und RNNs konnten AMT-Systeme viele Prozesse deutlich verbessern und neue Errungenschaften in dem Forschungsgebiet erzielen. Es gibt jedoch auch weitere wichtige KI-Module die in AMT-Systemen häufig genutzt werden oder zur Integration in Planung stehen. In diesem Kapitel werde ich auf genau diese KI-Module stärker eingehen und deren Aufgaben in der automatischen Musiktranskription weiter erläutern.

4.1.1 Convolutional Neural Networks

CNNs sind neuronale Netze, welcher besonders gut räumlich strukturierte Daten analysieren können. Deshalb werden diese vor allem in der Analyse von Bildern genutzt. Sie können zum Beispiel erkennen, was auf einem Bild genau passiert oder welche Objekte in einem Bild zu erkennen sind. Auch KIs wie ChatGPT nutzen eine verbesserte Form von CNNs, um Bilder zu analysieren. Im Fall der Musiktranskription haben wir als Input Bild das Spektrogramm. Spektrogramme können ähnliche wie zweidimensionale Bilder gehandhabt werden, da auf diesen auch alle wichtigen Daten des Inputs Audiosignals zu finden sind. CNNs bestehen aus mehreren verschiedenen Layern. Einfache CNN Modelle bestehen nur aus 2 bis 5 Layern, wobei komplexere CNNs aus über tausende Layern bestehen können. In AMT-Systemen haben die meisten CNNs etwa drei bis zehn Layer. Diese Layer sind Convolutional Layer (Faltungsschicht), Activation Layer (ReLU), Pooling Layer, Batch Normalization, Dropout Layer und Upsampling. Mit jedem Layer kann ein CNN immer abstraktere Merkmale erkennen. Außer dem Convolutional Layer und Activation Layer sind die anderen Layer jedoch nicht unbedingt notwendig. Eine Arbeit, welche die Stärke von CNN-Modellen in AMT-Systemen, sehr gut darstellt ist die von Curtis Hawthorne. [hawthorne2017onsets] Er benutzt direkt zwei verschiedenen spezialisierte Teilnetzwerke für Onsets und Sustain der Noten. Mit diesem System illustriert er die Entwicklung des Forschungsgebietes, insbesondere für polyphone Klaviertranskription, ausgezeichnet. Im Folgenden werde ich die verschiedenen Layer eines CNNs, in einem AMT-System, erläutern.

In dem Convolution Layer werden Filter verwendet. Filter sind 2D-Matrizen, die aus trainierbaren Gewichten bestehen. Ein Filter deckt jeweils einen 3x3 Pixel Eingabebereich des Inputbildes ab. Jeden Filter, den man auf das Bild anwendet, wird über das gesamte Bild gezogen und analysieren dadurch erstmal jeden Eingabebereich einzeln. Ein Skalarprodukt aus Filter und Eingabebereich beschreibt dann einen Aktivierungswert. Aus allen Aktivierungswerten eines Filters entsteht eine Feature Map. Wenn man Aktivierungswerte miteinander vergleicht, können somit Patterns und Eigenschaften erkannt werden. In der Musiktranskription filtert man somit Onsets, Sustains oder harmonische Verläufe heraus. Zum Beispiel Onsets werden erkannt, wenn es eine plötzliche Energieänderung gibt. Am Ende bekommt man einen 3D-Tensor raus, welcher alle Feature Maps beinhaltet.

Die Batch Normalization sorgt dafür, dass die Aktivierungswerte normalisiert werden. Jede Feature Map wird dabei einzeln normalisiert. Dadurch wird Rechenleistung eingespart. Zudem kann man im Training durch Mini-Batches mehrere Spektrogramme gleichzeitig durch die CNN Struktur leiten. Dadurch wird das Training schneller und man kommt früher an Ergebnisse.

Es kann passieren, dass die Summe eines Convolution Layers negativ ist. Dies kann passieren, wenn stärker gewichtete Filter einen negativen Aktivierungswert herausgeben. Negative Werte können zu Informationsverlust, von Eigenschaften des Musikstückes, führen. Um das zu vermeiden werden im Activation Layer, meistens mit der ReLU Funktion, alle negativen Aktivierungswerte auf 0 gesetzt. So kann das Netz nichtlineare Beziehungen modellieren.

Als Nächstes wird mit dem Pooling Layer der Rechenaufwand verringert. Dieser nimmt jede Feature Map einzeln und reduziert deren Matrix zu einer kleineren, meistens 2x2, Matrix. Das erfolgt, indem sich der Pooling Layer zunächst eine gesamte Feature Map nimmt und diese dann in kleinere Blöcke aufteilt. Es gibt entweder Max-Pooling oder Average-Pooling. Je nachdem welche Methode man wählt, wird immer der höchste Wert oder der durchschnittliche Wert extrahiert. Der extrahierte Wert von jedem Block wird nun in die reduzierte Feature Map zurückgeführt. Dadurch reduziert man nicht nur Rechenaufwand, sondern vermeidet auch Überanpassung. Wenn das System jeden kleinsten Wert berücksichtigt passt es sich zu sehr an den Trainingsdaten an und kann womöglich andere Daten nicht mehr richtig analysieren.

Der Dropout Layer ist, im Gegensatz zu den anderen Layern, nur im Training relevant. Er schaltet zufällig bestimmte Neuronen aus, sodass sich Neuronen nicht ausschließlich auf bestimmte andere Neuronen verlassen können. Somit wird das gesamte neuronale Netzwerk robuster und vielseitiger.

Upsampling ist das Gegenteil von dem Pooling Layer. Anstatt die Feature Maps zu reduzieren, werden diese wieder hochskaliert. Dadurch kann man bestimmte Features wieder zeitlich präziser bestimmen,

da die Zeitfenster wieder genauer zum originellen Audiosignal sind. Meist wird dieser Layer jedoch weggelassen, da er meistens nicht sehr relevant für AMT-Systeme ist.

CNNs finden ihren Ursprung im Jahre 1979. Kunihiko Fukushima erfand damals die Architektur für CNNs unter dem Namen Neocognitron. [fukushima1980neocognitron] Dies sollte als Vorreiter für spätere CNN Modelle gelten. Es dauerte weitere 10 Jahre bis das erste richtige Convolutional Neural Network, von Yann LeCun, veröffentlicht wurde. [lecun1989backpropagation] Dieses CNN Modell unterscheidet sich speziell in drei bestimmten Punkten zu dem Vorgänger Neocognitron. LeCun integrierte Gradientenlernen durch Backpropagation, wodurch das gesamte Netzwerk erstmals auf ein gemeinsames Ziel zu trainieren konnte. Neocognitron besaß zudem, im Gegensatz zu LeCuns CNN, keine Gewichtsverteilung mithilfe von Filtern, wie es in heutigen CNN Modellen standard ist. Zudem hatte Fukushima keine praktische Anwendung. Er hatte die Idee und wie man diese umsetzt, doch durch damalige Verhältnisse war es für ihn schwierig diese umzusetzen. Für AMT-Systeme wurde CNN jedoch erst ungefähr im Jahre 2015 relevant. [sigtia2016end] In Siddharth Sigtia Arbeit transkribierte dieser erstmals polyphone Musikstücke mithilfe von CNNs, und weiteren KI-Modulen. Seitdem sind CNNs ein wichtiger Bestandteil der modernen automatischen Musiktranskription.

Ein CNN gibt als letzte Ausgabe einen 3D-Tensor zurück, welcher aus den Zeitfenster (Frames / T), der Frequenzachsenlänge (F) und der Anzahl der Filter (C) besteht.

$$\text{CNN-Ausgabe} \in \mathbb{R}^{T \times F \times C}$$

Meist schließt sich nach einem CNN, in einem AMT-System, ein RNN als Nächstes an. Dieses kann jedoch nur 1D-Vektoren verarbeiten und nicht einen 3D-Tensor. Deshalb wandeln wir vor der Übergabe diesen 3D-Tensor um. Jedes Zeitfenster aus dem 3D-Tensor wird einzeln zu einem 1D-Vektor umgewandelt. Dabei wird der Vektor eine Dimension von $F \times C$ erhalten. Diese Vektoren werden dann an das folgende RNN weitergeleitet.

4.1.2 Recurrent Neural Networks

RNNs sind neuronale Netze, welche entworfen wurden um Daten mit zeitlicher Struktur zu verarbeiten. Dabei ist die Besonderheit von RNNs das diese ein Gedächtnis haben. Wenn nun in unserem Fall von AMT-Systemen eine bestimmte Tonabfolge gespielt wurde, kann sich das RNN diese merken und dementsprechend die fortlaufenden Ausgaben anpassen. Dies passiert dank dem Hidden State. Dieser stellt das Gedächtnis des RNNs dar. Er wird in jeder Berechnung eines Zeitpunktes berücksichtigt und mit jeder neuen Ausgabe aktualisiert. Dieses Prinzip ist in der Musiktranskription sehr hilfreich, da jede Note stark von den vorherigen gespielten Noten abhängt. Takt, Rhythmus, Harmonie und die Melodie eines Musikstückes sind alles gute Beispiele, warum diese sequenzielle Abfolge so passend in AMT-Systemen ist.

RNNs haben in der automatischen Musiktranskription mehrere Aufgabenfelder. Je nachdem wie man das RNN trainiert bewältigt dieses alle Aufgaben oder nur einen Teil. Diese Aufgaben bestehen aus Frame-Glättung (Temporal smoothing), Kontext-Modellierung (Temporal context modeling), Feature-Zusammenführung (Sequential integration of acoustic features) und Ausgabevorbereitung (time-distributed output classification). Für einen 1D-Vektor laufen diese Aufgaben parallel zueinander ab.

Bei der Frame-Glättung bekommt das RNN als Input die Aktivierungswerte des Zeitfensters. Es betrachtet diese mit Kontext zu den vorherigen Zeitfenstern, um falsche Vorhersagen auszuschließen. Das CNN hat dem RNN schon Vorhersagen für bestimmte Noten gegeben. Diese könnten jedoch fehlerhaft. Zum Beispiel kann die Note C4 für den Frame 6 und 8 aktiv sein, aber bei dem Frame 7 hat das CNN diese Note nicht als aktiv angesehen. Es ist sehr unwahrscheinlich, dass eine Note für nur einen Frame ausfällt. Solche Arten von Fehlern verarbeitet das RNN und glättet dementsprechend die vorher vom CNN gelieferten Daten. Dadurch ist der Ton C4 auch im Frame 7 aktiv.

Die Kontext-Modellierung ist etwas komplizierter als die Frame-Glättung. Als Input bekommt diese auch die 1D-Vektoren des CNNs. In der Kontext-Modellierung werden größere zeitliche Zusammenhänge betrachtet. So kann die Kontext-Modellierung, mithilfe des Hidden States, den Notenverlauf

oder auch die Länge einer Note vorhersehen. Je nach den Trainingsdaten ist es zum Beispiel üblicher, dass auf C4 ein D3 folgt, was durch die Kontext-Modellierung angepasst wird. Dies ist aber immer stark von der Musikrichtung und Musikern abhängig, welche in den Trainingsdaten vorhanden sind. Jazz und Pop oder Bach und Taylor Swift unterscheiden sich in der Tonabfolge extremst. Zudem wird Onset, Sustain und Offset stabilisiert. Durch vorherige Beispiele weist die Kontext-Modellierung, wie lange eine bestimmte Note andauern wird und kann so das Offset der Note einschätzen. Als Output bekommt man kontextabhängige Vektoren. Sie haben die gleiche Struktur wie die 1D-Vektoren vom CNN, sind aber entsprechend dem Kontext angepasst. Um ein noch besseres Ergebnis zu erhalten, kann man auch ein bidirektionales RNN nutzen. Dieses besteht aus zwei RNNs. Eines liest den Kontext von vorne und das andere von hinten. Danach werden die gewonnenen Kontexte miteinander kombiniert, um das Ergebnis noch robuster zu machen. Auch in AMT-Systemen sind diese sehr hilfreich. Ein bidirektionales RNN kann man auch in der Arbeit von Curtis Hawthorne finden. [hawthorne2017onsets]

4.1.3 Long Short-Term Memory

4.1.4 Transformers

4.1.5 Weitere Deep-Learning-Module und Entwicklungen

4.2 KI-basierende AMT-Systeme im Vergleich

5 Fazit

Abschließende Bemerkungen, Reflexion und Ausblick.